

课程笔记

[LLM Agents SP25] Multimodal Autonomous AI Agents —Ruslan Salakhutdinov

基于公开课程资料整理

2025



视频作者/频道: Berkeley RDI

发布日期: 2025

视频时长: 约 60 分钟

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言：从语言模型到自主 Agent	2
2 VisualWebArena：多模态 Web Agent 评估	2
2.1 从 WebArena 到 VisualWebArena	2
2.2 环境设计	2
3 推理时搜索：Tree Search for LLM Agents	2
4 数据扩展：在线数据收集	3
5 总结与延伸	3
5.1 拓展阅读	3

1 引言：从语言模型到自主 Agent

本讲由 CMU/Meta 的 Ruslan Salakhutdinov 教授主讲，介绍多模态自主 AI Agent，重点讨论 Web Agent 的评估、推理时搜索算法和数据扩展。

LLM Agent 的本质

LLM Agent = 多轮 LLM + 工具使用。核心价值在于：

- **动态计算时间**：思考 token 让模型对困难问题投入更多计算
- **外部工具信息**：运行代码、查看结果、修正方案
- **假设检验**：Agent 可提出假设、测试、根据结果修正
- **外部世界交互**：真正执行任务

2 VisualWebArena：多模态 Web Agent 评估

2.1 从 WebArena 到 VisualWebArena

HTML 表示的问题

HTML 源码杂乱（CSS、JavaScript 混杂），交互元素显示不正确，空间布局信息丢失，页面轻易超过 100K token。纯文本 Agent 难以有效处理。

VisualWebArena 设计了需要**视觉理解**的任务：

- 根据图片找到对应商品
- 阅读倒置的地址图片填写表单
- 理解图表数据跨网站检索信息

2.2 环境设计

环境建模为 POMDP（部分可观测马尔可夫决策过程），具有确定性转移函数。动作空间包括点击、悬停、输入文本、切换标签页、滚动等。

3 推理时搜索：Tree Search for LLM Agents

Agent 搜索的核心思想

将 Web Agent 的决策建模为树搜索问题：

- 每个节点是一个网页状态
- 每条边是一个动作
- 搜索目标是找到完成任务的动作序列
- 利用 LLM 作为策略网络和价值网络指导搜索

由于 Web 环境的确定性，可以保存和恢复状态，使得树搜索实际可行。

4 数据扩展：在线数据收集

Agent 训练数据的瓶颈

Agent 训练数据极度稀缺。解决方案包括：

- 在模拟环境中自动收集交互轨迹
- 利用搜索算法生成高质量的成功轨迹
- 过滤和验证自动收集的数据

5 总结与延伸

多模态 Web Agent 是 2025–2026 年的热点方向。评估需要真实的交互环境，推理时搜索可显著提升性能，数据扩展是训练高效 Agent 的关键瓶颈。

5.1 拓展阅读

- VisualWebArena (CMU)
- WebArena
- OpenAI Operator
- Tree Search for LLM Agents