

课程笔记

[LLM Agents SP25] Open Training Recipes for Reasoning —Hanna Hajishirzi

基于公开课程资料整理

2025



视频作者/频道: Berkeley RDI

发布日期: 2025

视频时长: 约 60 分钟

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1	引言：开放科学推动 LLM 研究	2
2	后训练：Tulu 3 训练配方	2
2.1	三步训练流程	2
2.2	数据策略	2
2.3	可验证奖励强化学习 (RLVR)	2
2.4	实验结果	2
3	预训练：OLMo 2	3
4	推理时扩展	3
5	总结与延伸	3
5.1	核心信息	3
5.2	拓展阅读	3

1 引言：开放科学推动 LLM 研究

本讲由 UW/AI2 的 Hanna Hajishirzi 教授主讲，介绍开放训练配方如何改进语言模型的推理能力，涵盖预训练、后训练和推理时扩展三个阶段。

为什么需要完全开放的模型

为促进创新和加速 LLM 科学研究，模型需要：**完全开放**（代码和数据）、**透明**、**可获取**和**可复现**。AI2 的 OLMo 和 Tulu 项目正是这一理念的实践。

2 后训练：Tulu 3 训练配方

2.1 三步训练流程

Tulu 3 后训练管线

1. **指令微调 (SFT)**：在多样化的指令-回答数据上微调
2. **偏好调优 (DPO/PPO)**：利用人类偏好数据对齐模型
3. **可验证奖励强化学习 (RLVR)**：利用可自动验证的任务（数学、代码）进行 RL 训练

2.2 数据策略

数据混合的挑战

增加某类数据（如数学推理）可能导致其他能力（如创意写作）下降。需要精心平衡数据混合比例，这是一个活跃的研究方向。

数据来源：人工标注 + 合成生成的混合方案最优。关键步骤包括：去污染（与评估集去重）、许可证检查、质量过滤。

2.3 可验证奖励强化学习 (RLVR)

RLVR 的核心思想

对于数学和编程等可自动验证答案的任务：

- 模型生成解答
- 自动检查答案正确性作为奖励信号
- 使用 RL 算法（如 GRPO）优化

DeepSeek-R1 证明了这种简单方法的强大效果。

2.4 实验结果

Tulu 3 应用于 Llama 3.1 405B 后，性能接近 GPT-4o，优于 DeepSeek-V3。

3 预训练：OLMo 2

OLMo 2 在 7B 和 13B 规模上，使用更少的训练 token，达到与 Llama 3 和 Qwen 2.5 相当的性能，位于帕累托最优曲线上。

4 推理时扩展

测试时计算扩展

在推理阶段投入更多计算来提升性能，包括：

- 多次采样 + 验证器选择 (Best-of-N)
- 过程奖励模型 (PRM) 引导搜索
- 自我反思和迭代修正

5 总结与延伸

5.1 核心信息

开放、可复现的训练配方对于推动 LLM 科学至关重要。预训练、后训练和推理时扩展三个阶段各有改进推理能力的方法，且大部分正交可叠加。

5.2 拓展阅读

- OLMo / OLMo 2 (AI2)
- Tulu 3 训练配方 (AI2)
- DeepSeek-R1: RL 训练推理模型
- Self-Instruct / Supernatural Instructions