

课程笔记

[LLM Agents SP25] Learning to Reason with LLMs —Jason Weston

五道口纳什 & Codex

2026 年 3 月 28 日



视频作者/频道: Berkeley RDI

发布日期: 2025

视频时长: 约 60 分钟

视频链接: 未填写

目录

1 引言	2
2 推理的定义与挑战	2
3 训练推理能力的方法	2
3.1 监督微调 (SFT) 方法	2
3.2 强化学习方法	2
3.3 推理时扩展	2
4 开放问题	2
5 总结与延伸	3
5.1 拓展阅读	3

1 引言

本讲由 Meta 的 Jason Weston 主讲，探讨如何训练 LLM 学会推理。

2 推理的定义与挑战

什么是推理

推理是从已知信息得出新结论的过程。对 LLM 而言，挑战在于区分**记忆**（直接从训练数据中检索答案）和**推理**（组合已知事实得出新结论）。

3 训练推理能力的方法

3.1 监督微调 (SFT) 方法

在带详细推理步骤的数据上训练：Chain-of-Thought 数据、工具使用轨迹等。

3.2 强化学习方法

RL 驱动的推理训练

- 过程奖励模型 (PRM)：对每步推理给予奖励
- 结果奖励模型 (ORM)：仅对最终答案给予奖励
- RLHF / DPO：人类偏好对齐
- 可验证奖励 RL（如 DeepSeek-R1 方式）

3.3 推理时扩展

Test-Time Compute Scaling

在推理阶段投入更多计算：

- Best-of-N 采样 + 验证器
- 搜索算法（Beam Search、MCTS）
- 自我修正和迭代改进

4 开放问题

推理能力的上限

LLM 是否真正在“推理”还是在进行高级模式匹配？分布外泛化能力仍然有限，形式化验证可能是确保推理正确性的唯一可靠手段。

5 总结与延伸

训练 LLM 推理需要高质量的推理数据、有效的 RL 训练方法和推理时扩展策略的综合应用。可验证的推理任务（数学、代码）是最有效的训练信号。

5.1 拓展阅读

- OpenAI O1 / O3 系列
- DeepSeek-R1
- STaR / Self-Taught Reasoner
- 过程奖励模型研究