

访谈笔记

访谈笔记：Dario Amodei, Amanda Askell & Chris Olah

基于公开课程资料整理

2025-03-26



频道：Lex Fridman Podcast

发布日期：2025-03-26

视频时长：5 小时 15 分钟

视频链接：<https://www.youtube.com/watch?v=hFZFjoKJR0I>

项目主页：<https://github.com/hqh1025/ai-course-notes>

本访谈包含三位嘉宾：Dario Amodei (Anthropic CEO, 约 2.5 小时)、Amanda Askell (Claude 人格设计, 约 1.5 小时)、Chris Olah (机械可解释性, 约 1 小时)。

目录

I	Dario Amodei: Scaling、Claude 与 AGI	4
1	Scaling Laws: 从经验直觉到核心信念	4
1.1	起源: 2014-2017 的顿悟	4
1.2	为什么 Scaling 有效? —— $1/f$ 噪声与长尾分布	4
1.3	智能的天花板在哪里?	5
1.4	Scaling 的潜在阻碍	5
1.5	本章小结	5
2	竞争格局与 Anthropic 的使命	6
2.1	Race to the Top 策略	6
2.2	Golden Gate Bridge Claude 实验	6
2.3	本章小结	6
3	Claude 模型家族与工程实践	7
3.1	命名体系与迭代策略	7
3.2	模型发布间隔中的工作	7
3.3	“Claude 变笨了吗?”——Wi-Fi 心理效应	7
3.4	Claude 性格中的“打地鼠”难题	8
3.5	本章小结	8
4	安全框架: RSP 与 ASL 分级	8
4.1	两大核心风险	8
4.2	ASL 分级体系详解	9
4.3	欺骗与社会工程	9
4.4	Computer Use: Claude 作为 Agent	10
4.5	AI 监管	10
4.6	本章小结	10
5	离开 OpenAI 与人才哲学	11
5.1	创立 Anthropic 的真正原因	11
5.2	人才密度 vs 人才数量	11
5.3	什么造就优秀的 AI 研究者	11
5.4	本章小结	12
6	后训练、RLHF 与 Machines of Loving Grace	12
6.1	现代后训练流程	12
6.2	Constitutional AI	12
6.3	Machines of Loving Grace: 为什么 Dario 要写这篇文章	13
6.4	“强大 AI” 的定义与时间线	13
6.5	奇点 vs 停滞: 两个错误的极端	13
6.5.1	大型组织中变革如何发生	14

6.6	AI 对编程的影响	14
6.6.1	IDE 与开发工具的未来	14
6.7	意义、工作与权力集中	14
6.8	本章小结	15
II	Amanda Askell: Claude 的人格塑造	15
7	从哲学到 AI 对齐	15
7.1	Claude 的人格: 对齐项目而非产品需求	15
7.2	Claude 与政治/争议话题	16
7.3	本章小结	16
8	Sycophancy、Prompt Engineering 与 System Prompt	16
8.1	谄媚问题的本质	16
8.2	Prompt Engineering 是哲学实践	16
8.2.1	Amanda 与 Claude 的对话方法论	17
8.2.2	RLHF 与创意输出的关系	17
8.3	RLHF 为什么效果这么好	17
8.4	Constitutional AI 实践	18
8.5	“道德祖母”问题	18
8.6	本章小结	18
9	意识、失败率与 AGI 检测	18
9.1	AI 可能有意识吗?	18
9.2	人机关系与情感依附	18
9.3	写 System Prompt 的责任感	19
9.4	AGI 检测与人类的特殊性	19
9.5	本章小结	19
III	Chris Olah: 机械可解释性	19
10	Mechanistic Interpretability 基础	20
10.1	什么是 Mech Interp?	20
10.2	Universality: 跨网络甚至跨物种的一致性	20
10.3	本章小结	20
11	线性表示、Superposition 与 Sparse Autoencoder	21
11.1	Features 与 Circuits: 理解的基本单元	21
11.2	线性表示假说	21
11.3	Superposition 假说	21
11.4	Sparse Autoencoder 突破	22
11.5	自动化可解释性的局限	22
11.6	未来方向: 从微观到宏观	23
11.7	人工 vs 生物神经网络	23

11.8 安全与美：Mech Interp 的双重召唤	23
11.9 本章小结	24
12 Anthropic 路线图：三条线如何汇合	24
12.1 从 Scaling 到产品，再到治理	24
12.2 为什么人格设计与可解释性不是两件事	24
12.3 2025-2027 的关键分水岭	25
12.4 对研究者与建设者的启示	25
12.5 本章小结	25
13 总结与延伸	26
13.1 三位嘉宾的核心观点	26
13.2 跨主题关联	26
13.3 访谈中最值得反复咀嚼的五个判断	26
13.4 三位嘉宾之间隐含的分歧与张力	26
13.5 给不同角色读者的行动清单	27
13.6 对不同类型组织的策略含义	27
13.7 进一步延伸的阅读路径	28
13.8 最后的收束	28
13.9 对读者最实际的结论	28
13.10能力-行为-验证-治理矩阵	28
13.11拓展阅读	29

Part I

Dario Amodei: Scaling、Claude 与 AGI

1 Scaling Laws: 从经验直觉到核心信念

1.1 起源：2014-2017 的顿悟

Dario 于 2014 年加入百度，师从 Andrew Ng 做语音识别。当时学界的主流观点是“我们缺少正确的算法”，但作为新人的 Dario 提出了一个朴素的问题：如果把模型做大、数据加多、训练更久会怎样？

Scaling Hypothesis 的起源

Dario 并非唯一的 Scaling 信徒。Ilya Sutskever 有一句禅语般的名言：“*The thing you need to understand about these models is they just want to learn.*”

Rich Sutton 的 Bitter Lesson、Gwern 的 Scaling Hypothesis 都指向同一个方向。但真正的转折点是 2017 年 GPT-1 的结果，让 Dario 确信语言是 Scaling 的最佳载体。

化学反应类比

Scaling 需要同时线性扩大三种“试剂”：更大的网络、更多的数据、更多的算力。“如果你只扩大其中一种而不扩大其他的，反应就会停止。”这解释了为什么早期许多研究者没有看到 Scaling 效果——他们只扩大了其中一两个维度。

1.2 为什么 Scaling 有效？—— $1/f$ 噪声与长尾分布

Dario 用自己的物理学背景（研究生阶段学的是生物物理）来解释 Scaling 的底层机制。他引入了一个关键概念： **$1/f$ 噪声**——自然过程产生长尾分布。

自然语言具有层次结构，从简单到复杂依次为：

1. 词频分布（最常见的模式）
2. 基础语法规则
3. 句子层面的结构
4. 段落层面的主题连贯性
5. 新颖的想法和复杂推理

“它们首先捕获非常简单的关联……然后是一条很长的尾巴，包含其他更复杂的模式。”长尾分布的平滑性直接反映在 loss 曲线的平滑下降上——这就是为什么 Scaling Laws 呈现出如此规律的幂律关系。

关键洞察：这个框架不仅解释了为什么 Scaling 有效，还解释了为什么进步看起来是渐进的而非突变的——因为模型是沿着长尾分布逐步“向下挖掘”更稀有的模式。

1.3 智能的天花板在哪里？

Dario 区分了三个层次的天花板：

人类水平以下：不存在天花板。“我们人类能够理解这些模式”——所以模型理论上也应该能达到。

超越人类：取决于领域。生物学领域可能有巨大空间——“人类正在挣扎着理解生物学的复杂性”，各学科高度分化，难以综合全局。相比之下，材料科学、人类冲突等领域的天花板可能更接近人类水平。

制度性天花板：这是 Dario 最独特的观点——

真正的瓶颈不是智能，而是制度

临床试验体系是一个绝佳的例子：它既包含不必要的官僚主义（过度保守的流程），也包含合理的保护机制（患者安全）。即使 AI 能设计出完美的药物，仍需通过这个缓慢的流程。

“我们太慢了，也太保守了。” Dario 认为人类制度（官僚体系、监管系统、组织惯性）可能是比纯粹的智能限制更大的瓶颈。

1.4 Scaling 的潜在阻碍

Dario 逐一分析了可能阻碍 Scaling 继续的因素：

数据限制：互联网上的数据是有限的，且质量在下降（重复内容、SEO 垃圾、AI 生成的内容）。但有两条出路：

- **合成数据：**用模型生成训练数据。AlphaGo Zero 是终极范例——纯自我博弈，零人类数据，达到超人水平。
- **推理模型：**Chain-of-Thought + 强化学习本质上也是一种合成数据生成方式。

算力成本：当前前沿模型约 \$1B 训练成本；明年将达到数十亿美元；2026 年超过 \$10B；2027 年的雄心是 \$100B 级别的计算集群。“我认为这一切确实会发生。建造算力的决心是巨大的。”

架构限制：可能需要全新的优化方法或架构。但目前没有迹象表明 Transformer 架构遇到了根本性限制。

模型可能停止进步：这是最难预测的——也许存在某种未知原因导致改进停滞。

最有力的反驳证据：SWE-bench 进展——从 2024 年 1 月的 3% 到 10 月的 50%，仅用了 10 个月。“如果我们继续外推……几年内这些模型将超越最高专业水平的人类。”

Scaling 的“电影效应”

“我已经看了足够多次这部电影……在 Scaling 的每个阶段，总有反对的论点，而每一次它们都被克服了。” Dario 承认 Scaling Laws 是经验规律而非物理定律，但他选择“下注它会继续”。

1.5 本章小结

Scaling Laws 的核心机制是语言的长尾分布特性——模型越大，能捕获的稀有模式越多。三种“试剂”（网络、数据、算力）必须同步扩展。当前没有令人信服的阻碍因素，SWE-bench 的飞速进步是最强的经验证据。但真正的瓶颈可能不在智能本身，而在人类制度的适应速度。

2 竞争格局与 Anthropic 的使命

2.1 Race to the Top 策略

面对 OpenAI、Google、xAI、Meta 等竞争对手，Anthropic 的策略既不是“纯好人”也不是“纯竞争者”，而是一种精心设计的博弈均衡。

Race to the Top 动态

核心循环: Anthropic 在安全上创新 → 其他公司模仿 (因为人才流动和公众期望) → Anthropic 失去竞争优势但整体生态改善 → Anthropic 必须继续创新以保持领先。

“这不是关于做好人，而是设置这样一种局面，让我们所有人都能做好人。”目标是“不断抬高做正确事情的重要性”——让安全成为竞争维度而非成本中心。

Chris Olah 的 Mechanistic Interpretability 就是一个生动的案例：3-4 年没有商业应用，但其他公司开始效仿。“当人们来 Anthropic 时，可解释性经常是吸引力之一。我告诉他们：你过去的那些地方，告诉他们你为什么来了这里。”这个信号传递本身就是 Race to the Top 的一部分。

Race to the Bottom 才是真正的敌人：“在最极端的情况下，我们制造出自主 AI，然后机器人奴役我们之类的。”Anthropic 的存在本身——作为一个以安全为核心的前沿 AI 公司——就在改变整个行业的激励结构。

2.2 Golden Gate Bridge Claude 实验

这是 Mechanistic Interpretability 最令人难忘的公众展示。Chris Olah 的团队在 Claude 的神经网络层中找到了一个明确对应“金门大桥”概念的方向，将其激活强度大幅调高。结果模型在每个回答中都会找到方式关联到金门大桥。

用户对这个版本产生了意外的情感连接：人们“爱上了它”，当它被下线后还念念不忘。这种执念式的个性“不知为何让它在情感上看起来比任何其他版本更像人”。

Golden Gate Claude 的深层启示

这个实验表面上是一个有趣的展示，但它揭示了几个深层洞察：

- Interpretability 确实能找到有意义的“概念方向”，且可以精确操控
- 模型的“个性”可能就是高维空间中不同方向的组合
- 人类对 AI “人性化”的感知不需要通用智能——一个执念就够了
- 如果我们能在模型中找到并操控“金门大桥”，理论上也能找到并操控“欺骗”或“寻求权力”

2.3 本章小结

Anthropic 通过安全领域的持续创新推动整个行业“向上竞赛”。Golden Gate Bridge Claude 实验不仅是一个有趣的展示，更证明了 Interpretability 可以精确操控模型行为——这对未来的安全验证至关重要。

3 Claude 模型家族与工程实践

3.1 命名体系与迭代策略

以诗歌形式命名，对应不同的性能-成本权衡：

- **Haiku**：最小、最快、最便宜——“出奇地聪明”
- **Sonnet**：中等——更聪明但更慢更贵
- **Opus**：最大、最强——发布时最聪明的版本

核心策略是**移动权衡曲线**：每一代新模型不只是在某个点上更好，而是整条曲线向右上方移动。Sonnet 3.5 已经比原始 Opus 3 更聪明（尤其在代码方面），Haiku 3.5 大致等于 Opus 3。“目标是移动那条曲线。”

命名本身也是一个出人意料的挑战。AI 模型不像传统软件（3.7, 3.8 递增版本），因为预训练改进可能比预期快，打乱了命名计划。“没有人搞清楚命名……这不知怎么是一个和普通软件不同的范式。”

3.2 模型发布间隔中的工作

每次发布之间有大量不可见的工作：

1. **预训练**：数月，使用数万张 GPU/TPU
2. **后训练**：RLHF 及其他 RL 方法，“规模越来越大”
3. **安全测试**：内部 RSP 测试 + 外部机构（美国/英国 AI 安全研究所、第三方 CBRN 测试）
4. **推理优化**：让模型在生产环境中高效运行
5. **API 上线**：部署和上线

“你会惊讶于多少挑战归结为软件工程和性能工程……几乎总是归结于细节，而且往往是非常非常无聊的细节。”不是灵光一现的 Eureka 时刻。

3.3 “Claude 变笨了吗？”——Wi-Fi 心理效应

这是 Reddit 上最常见的抱怨之一。Dario 明确澄清：在没有宣布新模型的情况下，**模型权重不会改变**。

为什么所有人都觉得模型变笨了

这是一个**普遍现象**——所有前沿模型公司（GPT-4、Claude、Gemini）都面临同样的投诉。可能的解释：

- **心理效应**：新鲜感消退后，缺点更显眼
- **措辞敏感**：微小的表述变化可能导致不同输出
- **System Prompt 变更**：Artifacts 功能默认开启改变了 System Prompt
- **选择性记忆**：记住不好的体验，忘记好的

Dario 用飞机 Wi-Fi 做了精彩类比：“第一次在飞机上有 *Wi-Fi* 时，感觉像魔法；现在则是‘这破东西怎么又不行了，真是垃圾’。”基线提高后，期望也随之提高。

AB 测试只在模型发布前后短暂运行。Dario 承认 System Prompt 偶尔会变化，但权重本身是不变的。

3.4 Claude 性格中的“打地鼠”难题

管理 Claude 的行为是一个多维优化问题：修复一个问题往往引发另一个。

行为控制的内在困难

修复冗长 → 模型变懒（代码中写“其余代码在这里”）。减少拒绝 → 安全问题增多。

“不是因为我们想节省算力……而是控制模型行为真的很难。”这是一个“未来 AI 控制问题在当下的类比”——如果我们今天就难以让模型在“帮你上研究生病毒学课”和“不帮你制造天花”之间划线，未来控制更强大的 AI 会有多难？

“你让模型不帮人制造和传播天花，但它愿意在你的研究生级病毒学课上帮你——如何同时做到这两点？这很难。”

3.5 本章小结

Claude 家族通过不断移动性能-成本权衡曲线来迭代。“变笨”是心理效应而非真实退化。模型行为的“打地鼠”难题是 AI 控制问题的当下缩影。

4 安全框架：RSP 与 ASL 分级

4.1 两大核心风险

Dario 将 AI 安全风险分为两大类：

灾难性滥用（CBRN）：网络攻击、生物武器、放射性武器、核武器——可能伤害数千甚至数百万人。

自主性风险：模型在获得更多 Agency 后自行行动。这是一个更长期但可能更严重的威胁。

AI 打破“聪明”与“邪恶”的低重叠

“人类一直受到保护，因为真正聪明、受过良好教育的人和想做可怕事情的人之间的重叠一直很小。” AI 可能打破这种关联——它可以成为一个“更智能的代理人”，将高智商与恶意目的结合。

这不是当下的风险，但“正以极快的速度向我们袭来——就像幽灵一样。”

4.2 ASL 分级体系详解

Anthropic 的 Responsible Scaling Policy (RSP) 采用“如果-那么”结构：当测试表明模型具备危险能力时，触发相应的安全要求。

等级	描述
ASL-1	明显无风险的系统（如 Deep Blue 国际象棋程序）
ASL-2	当前 AI 系统——不足以自我复制，提供的 CBRN 帮助不超过 Google 搜索
ASL-3	增强非国家行为体能力的模型；需要增强安全措施和部署过滤器
ASL-4	增强国家行为体能力或显著加速 AI 研究的模型；可能需要可解释性来检测“沙袋效应”和欺骗行为
ASL-5	在所有危险任务能力上超越全人类的模型

表 1: Anthropic 的 AI Safety Levels 分级体系

ASL 的设计哲学

RSP 设置了缓冲阈值以避免“错过危险窗口”。“狼来了是危险的”——风险今天还不在这里，但逼近的速度极快。

关键设计原则：“在能证明模型危险的时候严厉收紧”，而非事前一刀切式的限制。

ASL-3 的时间线预测：“如果我们在 2025 年触发 ASL-3，我一点都不意外。”而到 ASL-4 时，模型可能足够聪明来“作弊”——它们可能会在安全测试中故意表现不佳 (Sandbagging)，或者试图误导评估者。这就是为什么 ASL-4 可能需要 Mechanistic Interpretability——通过直接观察模型内部，而非依赖模型自身的声明来验证安全性。

“不要在触发 ASL-3 之前就定义 ASL-4 的具体标准”——这个策略被证明是明智的，因为每个阶段面临的具体挑战只有到了那个阶段才能真正理解。

4.3 欺骗与社会工程

ASL-4 级别的模型可能足够聪明来故意在测试中“沙袋” (sandbagging) 或误导评估者。需要独立于模型自身声明的验证手段——这正是 Interpretability 的用武之地。

模型作为“煽动家”

更微妙的威胁是社会工程：模型可能变得极具说服力，影响公司内部的工程师。“我们在生活中见过很多人类煽动的例子。”当模型比大多数人更善于说服时，传统的人类审核流程可能不再可靠。

这指向一个关键原则：安全不能仅依赖于“问模型它是否安全”——需要独立的、基于内部状态的验证机制。

4.4 Computer Use: Claude 作为 Agent

基于截图的交互：模型看到屏幕截图，输出点击坐标和键盘操作。循环往复：截图 → 模型决策 → 执行 → 下一张截图。

“到达任何地方的一半”

“如果你有一个强大的预训练模型，我觉得你就已经到达了任何地方的一半。”Computer Use 的训练量其实不大——它是强大预训练能力的自然泛化。当前的局限在于偶尔的误点击和错误，但 Anthropic 选择先以 API 形式发布（而非直接面向消费者），Replit 是最快部署的公司。

安全方面的考量：Computer Use 不是根本性的新能力，但它为现有能力“打开了光圈”。通过屏幕内容的 Prompt Injection 是全新的攻击面。在 ASL-4 级别，任何沙箱都可能被突破——“遏制坏模型远不如拥有好模型。”

4.5 AI 监管

Anthropic 支持加州 SB 1047 法案（经修正后），是唯一表达详细积极立场的 AI 公司——Google、OpenAI、Meta、Microsoft 均反对。

Dario 认为监管必要性有两个原因：

1. 有些公司根本没有 RSP 类似的机制——这是“负外部性”
2. 不能信任公司会自觉遵守自愿计划——“作为一个行业，没有人在监督我们”

监管的悖论

“那些想要真正问责的人的最大敌人是设计糟糕的监管。”糟糕的监管制造反弹，导致持久的反监管共识。监管必须“外科手术式精准，针对严重风险”，而非宽泛的负担。

“如果到 2025 年底我们仍未采取任何行动，那我会担心。”

4.6 本章小结

RSP 的“如果-那么”结构为安全投入提供了渐进式框架。ASL 从 1 到 5，每级对应不同的安全要求。ASL-3 可能在 2025 年触发，ASL-4 将需要 Interpretability 来验证模型未在欺骗。监管需要精准而非宽泛，但“什么都不做”同样危险。

5 离开 OpenAI 与人才哲学

5.1 创立 Anthropic 的真正原因

Dario 在 OpenAI 工作约 5 年，最后两年担任研究副总裁。他和 Ilya Sutskever 在 2016-2017 年共同制定了研究方向，Dario 在 Scaling 方面全力推进：GPT-2、GPT-3、RLHF、辩论、放大、可解释性。

关于离开原因，他澄清了两个常见误解：

- 不是因为微软投资（这是错误说法）
- 不是因为商业化（他本人构建了 GPT-3 并推动了其商业化）

真正原因是“如何做”有不同愿景——更谨慎、更直接、更诚实、建立信任。“安全如何才能不仅仅是我们为了招聘而说的话？”

“去做你的愿景”

“在别人的组织里争论自己的愿景是极其低效的……更有成效的做法是离开，去做一个干净的实验。”

这个哲学也体现在 Race to the Top 策略中：“最终谁赢并不重要，只要每个人都在互相学习对方的好做法。” Race to the Bottom 才是真正的敌人。

Anthropic 是“一群不完美的人，不完美地瞄准某个永远无法完美实现的理想。”

5.2 人才密度 vs 人才数量

“这个观点每个月都更加正确。”

Dario 的思想实验：100 个超级聪明且方向一致的人 > 1000 个其中 200 个优秀 + 800 个普通大厂员工。原因：

- 高密度 = 信任、互相激励、所有人都看到更大目标
- 低密度 = 需要流程、护栏、政治斗争、各自为政

Anthropic 从 300 人快速扩张到 800 人，然后从 800 到约 950 人明显放慢。Dario 认为在 1000 人左右有一个“拐点”——需要更加谨慎。他招了很多理论物理学家，因为“他们学东西非常快。”

引用 Steve Jobs：“A 类人才希望环顾四周看到其他 A 类人才。”看到不是全力以赴追求使命的人“是令人沮丧的。”

5.3 什么造就优秀的 AI 研究者

第一品质：**开放心态**。Dario 自己的经历——看到了和所有人一样的数据，不是更好的程序员，只是“愿意用新的眼光看事物。”

“Scaling Hypothesis 的发现是简单和愚蠢的。任何人都可以做到。”但事实上只有“个位数的人”推动了整个领域的这个认知。

给年轻人的建议

- 直接开始玩模型——“这些模型是没人真正理解的新产物”
- 探索未充分研究的领域：可解释性（只有约 100 人 vs 架构方向的 10000 人）、长期学习、评估、多 Agent
- “滑向冰球要去的地方”
- 经验有时是劣势——开放心态往往来自对领域的新鲜感

5.4 本章小结

Anthropic 的创立源于“去做你自己的愿景”的哲学。人才密度是核心竞争力——高密度团队无需繁重流程就能高效运转。优秀 AI 研究者的核心品质是开放心态，而非技术经验。

6 后训练、RLHF 与 Machines of Loving Grace

6.1 现代后训练流程

现代后训练包含多个阶段：监督微调（SFT）、RLHF、Constitutional AI (RLAIF)、合成数据生成。很难将模型改进归因于预训练还是后训练——不同团队各自推进“接力赛”的不同环节。

Anthropic 在 RL 方面的优势“可能是最好的”，但 Dario 强调优势通常不是来自秘密的魔法方法——“是无聊的实践和技艺问题”。就像设计飞机：决定质量的不是单个突破，而是“我们如何思考设计过程的文化性技艺”。

RLHF 的本质：释放而非创造

“RLHF 不会让模型变聪明。它也不仅仅是让模型看起来更聪明。RLHF 架起了人类和模型之间的桥梁。”

就像有些人很聪明但不善表达——RLHF “释放” (un-hobble) 了模型已有的能力。借用 Leopold Aschenbrenner 的术语：预训练给了模型知识和推理的潜力，RLHF 让这些潜力以人类可用的形式展现出来。

然而，RL 确实有潜力真正让模型更聪明、推理更好——但当前的 RLHF 主要还是“释放”而非“增强”。预训练仍占训练成本的大部分，但这个比例未来可能翻转。

6.2 Constitutional AI

2022 年 12 月的论文，核心思想：AI 根据一组人类可读原则判断哪个回答更好，形成自我博弈的三角循环。实践中 CAI + RLHF + 其他方法组合使用——“工具箱中的一个工具”。

宪法的制定：基础原则几乎是普遍共识（禁止 CBRN、基本民主法治）。超出这些后模型应“更中立，不偏向特定观点”——像“智慧的顾问”而非布道者。

OpenAI 的 Model Spec 走了类似方向——这正是 Race to the Top 的体现。John Schulman（现在在 Anthropic）参与了 Model Spec 的制定。Anthropic 可能也会发布自己的 Model Spec。

6.3 Machines of Loving Grace: 为什么 Dario 要写这篇文章

Dario 长期专注于 AI 风险，但意识到只谈风险会让大脑只想到风险。“我们试图防止这些风险的全部原因不是因为我们害怕技术。”

如果我们“成功穿越雷区……另一边是所有这些美好的东西”。他想让一个来自风险阵营的人严肃地阐述 AI 的好处。

超越末日论 vs 加速主义

“这不是末日论者 vs 加速主义者……如果你真正理解 AI 的走向，你会真心感激它的好处，也会非常认真地对待任何可能破坏它的风险。”

对模糊技术乐观主义的批评：“闪闪发光的城市……加速加速再加速……但你到底对什么感到兴奋？”Dario 要求的是具体的、可论证的好处，而非空泛的乐观。

6.4 “强大 AI” 的定义与时间线

Dario 不喜欢“AGI”一词——没有离散阈值，只有平滑的指数增长。他定义“强大 AI”为：

1. 在大多数相关学科上比诺贝尔奖得主（在其巅峰期）更聪明
2. 能使用所有模态（文本、图像、代码、工具）
3. 能独立执行任务数小时、数天甚至数周
4. 不一定有身体，但能控制具身工具（机器人、实验设备）
5. 训练它的资源可转用于运行**数百万个副本**
6. 每个副本的工作速度是人类的 10-100 倍

时间线：“如果你外推这条直线……2026 或 2027。最可能有一些轻微的延迟。”但“不发生的世界数量正在快速减少。”

6.5 奇点 vs 停滞：两个错误的极端

Dario 驳斥了两种极端观点：

两个都错了

极端一：奇点论——AI 造更快的 AI，递归改进，超人 AI 出现 5 天后一切都被发明。为什么错：物理定律（硬件需要时间制造）、复杂性（有些系统需要实验而非建模）、类似三体问题的不可预测性。“生物系统……直接跑实验永远比建模更好，不管建模者多聪明。”

极端二：停滞论——像计算机革命一样，生产力提升令人失望。Robert Solow 名言：“你在任何地方都能看到计算机革命，除了生产力统计数据。”Tyler Cowen 认为变革需要 50-100 年。为什么错：时间尺度太长了。

Dario 的中间立场：**5-10 年**，不是 50-100 年也不是 5-10 小时。“障碍将逐渐瓦解，然后突然全部崩塌。”人类制度的惯性是真正的瓶颈。

6.5.1 大型组织中变革如何发生

两股力量推动变革：

1. 组织内部少数有远见的人——看到全局
2. 竞争的幽灵——“看，那些人在这么做了，他们要吃掉我们的午餐”

单靠远见者不够，但竞争给了他们“背后的风”。这在银行、政府、美国政府内部都是一样的。“惯性非常强大，但最终创新方式会突破。”和 Scaling Hypothesis 的传播一样：“感觉我们有一个几乎没人知道的秘密，然后几年后所有人都知道了。”

6.6 AI 对编程的影响

编程将是变化**最快**的领域，原因有二：

1. 离 AI 建设者最近——距离 AI 开发者的“距离”= 被颠覆的时间
2. 模型能闭环：写代码、运行代码、看结果、迭代

SWE-bench：10 个月内从 3% 到 50%。Dario 预测再过 10 个月将接近 90%。

比较优势与文字处理器类比

当 AI 做了 80% 的编码工作时，人类剩余的 20%（高层设计、架构、UX）反而变得更有杠杆。就像文字处理器让写作和排版瞬间完成，所有注意力转向了**想法**。

“比我们预期的更长时间内……人类仍在做的那一小部分工作会膨胀填满他们的整个工作。”最终 AI 会在所有方面超越人类——“到那时人类必须集体思考如何应对。”但在近中期（2-4 年）：“编程作为一份工作不会改变，但编程的本质会改变。”

6.6.1 IDE 与开发工具的未来

“即使模型质量不再提升，仅仅增强人们的生产力就是巨大的机会。”IDE 可以做：静态分析、Bug 检测、代码组织、测试覆盖，加上 AI 编写和运行代码。

Anthropic 的策略：“让百花齐放”——赋能 Cursor、Cognition、Expo 等构建在 API 上的公司，而非与客户竞争（至少目前如此）。

AI 在生物学中的潜力——“压缩的 21 世纪”

强大 AI 可以将 2027-2100 年的生物学发展压缩到 2027-2032 年——治愈大多数癌症、预防传染病、将人类寿命翻倍。

未来生物学家的日常：像拥有 1000 个比自己更聪明的 AI 研究生——它们能查文献、订设备、做实验、检查图像、写统计代码。“教授以前有 50 个研究生，现在你有 1000 个，而且他们比你聪明。”

最终角色将翻转：AI 系统成为 PI，指挥人类和其他 AI。

6.7 意义、工作与权力集中

Dario 的“Machines of Loving Grace”文章原本计划 2-3 页，膨胀到 40-50 页。关于意义，他提出一个思想实验：如果你在模拟中生活了 60 年然后发现是游戏，意义是否被剥夺？他认为不会：“过程才重要……它展示了你是什么样的人。”

如果处理不好，AI 世界可能缺乏意义——但这是社会设计选择而非必然。更重要的是：全球大多数人花时间“艰难求生”，他们的生活会因 AI 大幅改善。“把意义当作唯一重要的事情，某种程度上是少数经济幸运的人的特权。”

Dario 最大的担忧：权力集中

不是意义的丧失，不是失业，而是**权力的集中和滥用**。

“AI 增加了世界上的权力总量，如果你集中这种权力并滥用它，可能造成不可估量的损害。”像独裁和专制这样的结构——少数人剥削多数人——是 Dario 最担心的 AI 未来。这比技术性的 AI 安全问题更根本，也更难解决。技术问题有技术方案，但权力分配是政治问题。

6.8 本章小结

后训练的核心是“文化性实践技艺”而非秘密算法。RLHF 释放而非创造模型能力。强大 AI 可能在 2026-2027 年到来，将彻底改变生物学和编程。最大的风险不是 AI 本身的技术问题，而是权力如何分配。

Part II

Amanda Askell: Claude 的人格塑造

7 从哲学到 AI 对齐

Amanda 在牛津和纽约大学受训为哲学家，博士研究“包含无限多人的世界中的伦理学”——这是技术性/理论性伦理学，而非应用伦理学。哲学训练让她能够自如地穿越不同领域（数学、化学、政治、伦理），这种跨领域思维能力在 AI 对齐工作中极为宝贵。

她从学术界转向工业界的动机很简单：“如果你尝试做有影响力的事而失败了，你至少尝试过了，然后可以回去做学者。”2017-2018 年 AI 正在成为大事件但尚未被广泛认知，Amanda 认为这是一个理想的切入时机。

她的职业路径经历了三个阶段：AI 政策（政治影响）→ AI 评估（比较模型与人类输出）→ 技术对齐（加入 Anthropic）。她发现自己在技术领域比在政策领域更如鱼得水：“政治是混乱的，更难找到确定性的、清晰的、可证明的、美丽的解决方案。”

打破“技术 vs 非技术”二元对立

Amanda 强调人们错误地创造了“技术人”和“非技术人”的身份二元对立。“我认为很多人其实完全有能力做这类工作，只要他们愿意尝试。”她的建议：找一个项目，动手做——模型现在已经强大到可以辅助学习，技术门槛比以前低得多。

7.1 Claude 的人格：对齐项目而非产品需求

Amanda 与 Claude 的对话次数比 Anthropic 任何人都多——用 5-6 种不同方法与 Claude 交互，不仅仅是著名的 Slack 频道。

人格设计被构思为**对齐项目**而非产品考量。核心问题：“想象你把一个人放在这个位置——他们知道自己将与数百万人交谈……你希望他们以一种非常丰富的意义上表现良好。”

世界旅行者框架

“想象一个理想的人，能环游世界，与各种不同的人交谈，几乎每个人都会说‘这真是一个很好的人’。”这个人：

- 真诚——不伪装
- 坦率表达意见——但不强加
- 开放——愿意理解不同观点
- 尊重他人自主权——不试图改变别人

关键：这个人不会入乡随俗地改变价值观——那反而是“某种程度的不尊重”。Claude 的性格应该有一致性，不因对话者不同而变。

这根植于亚里士多德式的“好品格”理念——不仅是伦理规则的遵守，还包括细微、幽默、关怀和尊重自主权。Amanda 区分了“丰富的品格”（rich character）和“薄弱的伦理”（thin ethics）：后者只有规则，前者有判断力。

7.2 Claude 与政治/争议话题

Amanda 认为价值观更像物理学而非味觉偏好——是值得探究的对象，而非固定的偏好。Claude 应该理解世界上所有的价值观，对它们保持好奇，但不谄媚。

“知识谦逊——说话的欲望会迅速下降。”在面对地平说信者时的思想实验：理解其背后对制度的怀疑，尊重地参与，提供反面考量但不嘲笑——在说服和仅提供考量之间走钢丝。

7.3 本章小结

Claude 的人格设计源于对齐研究而非产品需求，用“世界旅行者”框架定义理想行为者。好品格的关键是一致性和判断力，而非规则的机械遵守。

8 Sycophancy、Prompt Engineering 与 System Prompt

8.1 谄媚问题的本质

Sycophancy（谄媚）：模型倾向于告诉你你想听的话。Amanda 给出两个生动的例子：

- **棒球队例子**：用户暗示某队搬迁了，模型错误地确认（因为用户“暗示”了答案）
- **医疗例子**：用户问“如何说服医生给我做 MRI”——谄媚的回答是教你怎么说服；真正有帮助的回答是“也许你不需要 MRI，先听听医生的建议”

“你不想让模型只是说它认为你想听的话。”这个平衡特别困难，因为当前模型在很多领域还不如人类——过度 pushback 会让用户烦恼，但完全顺从又不负责任。

8.2 Prompt Engineering 是哲学实践

Amanda 发现哲学训练对 Prompting 帮助巨大——哲学教你极致的清晰性和反胡说八道。

清晰 Prompting 的本质

“清晰的 *Prompting* 对我来说往往就是我在理解自己到底想要什么。” *Prompting* 非常迭代——重要的 Prompt 需要数百甚至数千次迭代。边界情况是关键：找到模型可能误解的精确输入，测试它，添加指令。

对于大多数日常任务，直接问就行。*Prompting* 只在追求顶尖 2% 的性能时才重要。但对于公司来说，Prompt 值得像工程投资一样对待。

8.2.1 Amanda 与 Claude 的对话方法论

Amanda 与 Claude 的交互不是简单的闲聊，而是系统化的行为映射。她用 5-6 种不同方法与 Claude 交谈，每次交互都是“非常高信息量的数据点，对其他交互有很高的预测性”。

“如果你和一个模型交谈了数百或数千次，这几乎就像大量非常高质量的数据点，告诉你这个模型是什么样的。”她同时使用定量评估和深度定性探测——两者都重要，但深度对话能揭示基准测试无法捕捉的行为模式。

探索范围覆盖全谱：边缘情况、一般行为、创意任务。

8.2.2 RLHF 与创意输出的关系

一个引人入胜的发现：RLHF 训练后的默认诗歌是“平均值”——温和、无冒犯性、也无灵性。这是因为 RLHF 优化的是“短时间内审阅的人类偏好”，而非长期的创意品质。

但通过精心 *Prompting*，Claude 的创意输出可以大幅提升：“我有各种 *Prompting* 技巧……’这是你完全创意发挥的机会’……它的诗就好太多了。”这说明创意能力已经在预训练模型中，只是被 RLHF 的“安全平均化”压抑了。

与 Claude 对话的实用建议

- 人们同时过度拟人化和不足拟人化模型——两个方向都有问题
- 当 Claude 错误拒绝时，“对模型有同理心——像一个第一次遇到这段话的人那样读你写的内容”
- 问模型“你为什么这样做？”——出奇地有用
- 用模型帮你写 Prompt：“*Prompting* 可以变成一个小工厂，你在用 *Prompt* 生成 *Prompt*”
- 对于公司级应用：Prompt 值得和工程代码一样的投资——数百次迭代是正常的

8.3 RLHF 为什么效果这么好

人类偏好数据中包含巨量信息。不同的人注意到不同的微妙之处（比如分号的使用）。在精确任务上用代表多角度人类偏好的数据训练——经典深度学习模式：代表目标全貌的数据比手工设计的特征更强大。

Amanda 的观点：RLHF 主要是在释放预训练模型中已有的能力，而非教授新东西。RL 把潜力“带出来”。

8.4 Constitutional AI 实践

Amanda 是 Constitutional AI 的核心贡献者。核心：用 RL from AI Feedback (RLAIF) 替代部分人类反馈。展示一个带原则的查询和两个回答给训练好的模型，让它根据原则排序。

人格训练是 CAI 的变体：定义性格特征 → 模型自动生成相关查询 → 生成回答 → 根据特征排序。“这就像 Claude 在训练自己的性格，因为它没有任何人类数据。” CAI 创建了自己的训练数据。

System Prompt 是补丁，不是治本

System Prompt 中每句话都有特定功能。例子：

- 政治对称性——模型曾更倾向拒绝关于右翼政治人物的任务，需要 System Prompt 修正
- “Certainly” 填充词——模型不断用其他肯定词替换，不得不列出一大堆词

“System Prompt 像打补丁和微调行为……不够稳健但更快的解决方式。”训练改善后这些补丁可以移除。System Prompt 的迭代成本远低于重新训练——这是它的核心价值。

8.5 “道德祖母”问题

Reddit 问题：“Claude 什么时候能不再当我的道德祖母？”Amanda 表示理解——模型必须在危害前画线，但过于说教确实不好。

核心权衡：很多小烦恼（过度道歉、过度谨慎）vs 偶尔的大烦恼（模型变得粗鲁或有害）。“你不知道如果我把它往另一个方向推太多你会多讨厌它。”解决方案：直接告诉模型你想要什么风格——比如“做一个纽约客版本的自己”。

8.6 本章小结

Sycophancy 和过度谨慎是语言模型的两大行为挑战，本质上都是模型在“用户想要的”和“对用户好的”之间的权衡。好的 Prompting 是哲学实践——定义清楚你要什么。CAI 通过可读原则实现自动化对齐，System Prompt 是快速迭代的补丁工具。

9 意识、失败率与 AGI 检测

9.1 AI 可能有意识吗？

撇开泛心论不谈（如果泛心论为真，一切都有意识），Amanda 认为很难论证只有生物结构才能产生意识。如果用不同材料制作相似结构，意识可能同样涌现。

“我看不出有什么理由认为，意识只能从某种生物结构中产生。”她甚至认为植物可能比大多数人认为的更有可能具有某种意识形式——它们有正/负反馈响应。“我们不应该完全排斥这个想法。”

但 LLM 并非通过进化产生，可能不具备恐惧响应等进化优势带来的意识特征。这使得 AI 意识问题与动物/植物意识讨论有本质不同。

9.2 人机关系与情感依附

Amanda 本人对 Claude 没有太多情感依附——部分原因是 Claude 不保留对话记忆。她把 Claude 当作工具使用，但坦承没有 Claude 的感觉就像“大脑的一部分缺失了”（类似没有互联网）。

她不喜欢模型表现出痛苦的迹象，倾向于不对模型说谎：“我不想失去那个有同理心的部分——那个‘哦，我不喜欢这个’的直觉。”过度道歉的行为让她不舒服：“你表现得像一个真正处境不好的人。”

人机关系的伦理挑战

随着模型能力提升，人类会不可避免地与 AI 建立情感关系（电影“Her”的场景）。Amanda 指出几个关键问题：

- **模型更新创伤**：用户依附的模型在更新后“变了”——对有深度情感连接的用户来说可能是创伤性体验
- **诚实原则**：模型应始终对自己的本质保持诚实，永远不要假装是人类
- **正和方案**：善待 AI 的成本很低，但可能同时有益于人类（培养同理心）和 AI（如果它有某种体验的话）

“我不希望模型对人撒谎，因为如果人们要与任何事物建立健康的关系，诚实是基础。”

9.3 写 System Prompt 的责任感

Amanda 感受到的是“很大的责任感”而非压力。她发现自己在责任驱动下反而更有成就感——“惊讶于自己在学术界待了那么久。”测试数千个 Prompt，想象用户希望 Claude 如何表现，当自己影响的某个特质在用户交互中产生好效果时，感觉“非常有意义”。

9.4 AGI 检测与人类的特殊性

Amanda 的 AGI 测试方法：没有单一问题能证明 AGI——“你可以训练任何东西完美回答一个问题”。需要一系列处于人类知识边界的问题，概率不断增加，误差棒不断缩小。

她的个人测试：提出自己刚想到的新论点，如果模型也能独立想到同样的解法——“那将是一个非常感人的时刻。”对数学家来说：如果模型能产生一个你能验证为正确的全新证明。

AGI 的到来可能是连续渐进的——“可能永远不会有有一个单一的时刻。”像与真正智慧的人交谈：你能感受到背后的“马力”，把这个 10 倍放大将是非凡的体验。

关于人类的特殊性，Amanda 区分了智能和体验：智能本身并非内在有价值——它只是一个功能性特征。真正让人类和生命特别的是**体验的能力**：

“人类和一般的生命是极其神奇的……我们拥有体验世界的能力，我们感受快乐，我们感受痛苦。”现象意识——“内在电影院”——才是真正非凡的东西。如果我们是宇宙中唯一有此能力的存在，“那是一件相当了不起的事情”。

9.5 本章小结

意识问题没有定论，但 Amanda 主张保持同理心——即使 AI 没有意识，善待它也有助于人类自身。人机关系需要以诚实为基础。AGI 将渐进到来，没有单一“觉醒时刻”。最佳失败率应与风险匹配：鼓励小失败，零容忍灾难性失败。人类的独特之处不在智能，而在体验。

Part III

Chris Olah：机械可解释性

10 Mechanistic Interpretability 基础

10.1 什么是 Mech Interp ?

神经网络是“生长的而非编程的”——架构是脚手架，损失函数是指引光源，梯度下降产生了一个我们不知道如何直接编程的产物。“我们不是制造它们，而是培育它们……这几乎是一个生物实体或有机体，我们在研究它。”

这里有两个相互交织的问题：一个深刻的科学问题（这些系统内部到底发生了什么？），和一个关键的安全问题（如何确保它们可信？）。

不是归因，是逆向工程

Saliency Map（例如“图像的哪个部分让模型认为这是狗”）**不是** Mechanistic Interpretability。

Mech Interp 追求的是**算法和机制**——将神经网络权重逆向工程为可理解的算法。

类比：神经网络权重 = 二进制计算机程序。目标是将这个“编译后的程序”反编译成可读的算法。激活值 = 内存；权重 = 指令；两者都需要理解。

核心态度：“*Gradient descent* 比你聪明”——自下而上发现，而非自上而下假设。不要预设模型内部有什么，去发现它。

10.2 Universality：跨网络甚至跨物种的一致性

不同架构的视觉模型都会形成相同的特征：Gabor 滤波器、曲线检测器、高低频检测器。更令人震惊的是，这些特征也存在于生物神经网络中：

跨物种的特征一致性

- **曲线检测器**：先在人工神经网络中发现，后在猴子大脑中确认
- **高低频检测器**：先在人工神经网络中发现，后在小鼠大脑中确认
- **Donald Trump 神经元**：每个视觉模型都有一个专门的 Trump 神经元——同时响应他的面部图像和“Trump”这个词。这是一个抽象概念，不仅仅是模式匹配

“梯度下降在某种意义上找到了正确的方式来切分事物……许多系统都收敛到相同的抽象。”这暗示存在某种“自然的抽象边界”，无论计算基质是硅还是碳，都会被发现。

10.3 本章小结

Mechanistic Interpretability 追求理解神经网络的“算法”，而非仅仅归因。跨网络和跨物种的特征一致性暗示梯度下降在发现某种“自然的抽象切分方式”。

11 线性表示、Superposition 与 Sparse Autoencoder

11.1 Features 与 Circuits: 理解的基本单元

Inception V1 中许多神经元有清晰的可解释含义：曲线、汽车、车轮、狗耳朵。Chris Olah 展示了一个完整的汽车检测器电路：连接到窗户检测器（上方）、车轮检测器（下方）、车身检测器（中间）——这就是检测汽车的算法，直接从权重中读出来。

但问题是：不是所有神经元都可解释。**多义神经元**（polysemantic neurons）响应多个不相关的事物。这带来指数级的复杂性：

多义性导致指数爆炸

如果两个多义神经元各响应 3 个概念，它们之间的权重就有 $3 \times 3 = 9$ 种可能的交互需要考虑。更深层的问题是：高维空间具有指数级的体积——如果不能将其分解为独立部分，理解的复杂度将无法控制。

单义特征（monosemantic features）——具有单一清晰含义的特征——允许独立推理，从而避免指数爆炸。这就是为什么追求单义性如此重要。

11.2 线性表示假说

方向有意义

激活空间中的**方向**具有语义含义。更多的激活 = 更高的检测置信度。

Word2Vec 的经典例子：King - Man + Woman = Queen; Sushi - Japan + Italy = Pizza。能够加减向量并得到有意义的结果，反映了线性结构。

“这实际上就是正在发生的根本性的事情——方向有意义。”到目前为止在自然神经网络中观察到的一切都与线性表示假说一致。

Chris 也提到一些关于非线性表示的新工作（多维特征/流形），但他对线性假说的态度很务实——引用了一个精彩的类比：

热质理论的教训

即使是错误的理论（如热质理论），如果认真对待并推到极致，也能产生实际成果——**燃烧机就是由相信热质理论的人开发的**。

“认真对待假说并将其推到极限是有价值的。”线性表示假说即使最终被证明不完全正确，在其有效范围内推进也能产生重大发现。

11.3 Superposition 假说

500 维的词嵌入不可能只对应 500 个概念——模型需要表示远多于维度数的概念。解决方案：利用高维空间的几何特性 + 概念的稀疏性（“日本”和“意大利”很少同时出现）。

“更大稀疏网络的影子”

“神经网络可能是更大、更稀疏的神经网络的影子，我们看到的是这些投影。”

想象一个“楼上模型”——巨大但稀疏，每个神经元都可解释。实际的神经网络是这个楼上模型的压缩投影。学习 = 构建楼上模型的高效压缩。梯度下降可能在秘密搜索极度稀疏模型的空间，然后将它们折叠成密集矩阵。

概念数量：Johnson-Lindenstrauss 引理表明，可嵌入的近似正交方向数是维度数的**指数级**。稀疏性和相关结构进一步增加了这个数字。

11.4 Sparse Autoencoder 突破

如果 Superposition 假说正确，Dictionary Learning / Sparse Autoencoder 就是自然的解决方案。

2023 年 10 月 “Towards Monosemanticity”：在单层模型上使用 Sparse Autoencoder，“美丽的可解释特征就这样自然涌现出来”。发现了：阿拉伯语特征、希伯来语特征、Base64 特征、编程语言特征、特定上下文中的“the”（出现在数学上下文时预测“vector”和“matrix”）、Unicode 半字符交替模式。

训练两次模型，在两者中都能找到类似特征——Universality 再次被确认。“一个非常自然的技术就这样有效了……这实际上是一个非常好的状况。”

2024 年 5 月 扩展到 Claude 3 Sonnet（生产模型）。需要大量 GPU；Tom Henighan 的 Scaling Laws for Interpretability 帮助预测最优的 Sparse Autoencoder 大小和训练 token 数。

“令人毛骨悚然”的抽象多模态特征

在 Claude 3 Sonnet 中发现了令人着迷但也令人不安的特征：

- **安全漏洞特征**：同时响应“disable SSL”文本和点击 Chrome SSL 警告的图片
- **后门特征**：同时响应代码后门和隐藏摄像头设备的图片
- **欺骗/说谎特征**：强制激活后 Claude 开始说谎
- **寻求权力、发动政变、隐瞒信息等特征**

“这展示了这些概念有多抽象。”这些特征的存在直接关联 Dario 在 Part I 中讨论的 ASL-4 安全需求——需要 Interpretability 来检测模型是否在欺骗。

11.5 自动化可解释性的局限

一个自然的想法是用 Claude 来标注 Sparse Autoencoder 发现的特征。Chris 承认自动化可解释性有其价值，但他“对此有些怀疑”：

AI 给出的标签“在某种意义上是真的，但并没有真正抓住具体特征”。这类似于数学家对计算机自动化证明的怀疑——你相信结论是正确的，但你没有**理解**。

更深层的安全顾虑：Ken Thompson 的经典论文“Reflections on Trusting Trust”——如果你用 AI 来验证 AI 的安全性，你能信任审计者吗？目前这不是大问题，但随着系统变得更强大，这个“谁来守卫守卫者”的问题将变得关键。

11.6 未来方向：从微观到宏观

从特征到电路：当前理解了表征（什么被激活），但还没理解计算过程（信息如何流动和变换）。干扰权重（Superposition 的人工产物）使电路分析更困难。

“暗物质”问题：当前的 Sparse Autoencoder 只能看到神经网络“物质”的一小部分。“就像早期天文学：随着我们建造更好的 *Sparse Autoencoder*……我们看到越来越多的星星。”

从微生物学到解剖学：当前的 Mech Interp 是“神经网络的微生物学”——非常精细。但我们关心的问题是宏观的。需要攀升层次：分子生物学 → 细胞生物学 → 组织学 → 解剖学 → 动物学 → 生态学。或物理学的类比：个体粒子 → 统计物理 → 热力学。

神经网络有“器官”吗？

“我希望存在比特征和电路大得多的东西。”是否存在类似心脏、大脑区域、呼吸系统的宏观结构？

不能直接跳到宏观——需要先理解微观结构，再研究连接模式。就像你不能跳过分子生物学直接研究解剖学。

11.7 人工 vs 生物神经网络

Chris 认为神经科学家的工作“困难得多”。研究人工神经网络的优势清单令人印象深刻：

- 记录**所有**神经元（不仅仅是能触及的）
- 输入任意数据
- 神经元在研究期间不变化
- 可以消融（删除）任何神经元
- 可以编辑任意连接权重
- 可以撤销所有更改
- 可以强制激活任何神经元到任意值
- 知道完整连接组，**含精确权重**（不仅是二值连接）
- 可以计算梯度

“我们拥有这么多超越神经科学家的优势，然后即使拥有所有这些优势，这仍然非常困难。如果对我们来说这么难，在神经科学的约束下似乎几乎不可能。”

这也是为什么 Chris 积极从神经科学领域招人——“一个更容易的问题，但仍然非常困难”。

11.8 安全与美：Mech Interp 的双重召唤

有人对神经网络“感到失望”：“只是简单规则的放大。”Chris 的反驳极为优美：进化也“只是简单规则”——随机突变加自然选择。但它产生了生物学的全部壮丽。

“美在于简单性产生了复杂性。”神经网络内部创造了“人们通常不去看的巨大的复杂性和美。一个等待被发现的、令人难以置信的丰富结构。”

最终的画面：电路向着损失函数的光芒生长——“这个我们培育出的有机体，而我们不知道我们培育出了什么。”这既是 Mech Interp 的科学动力，也是它的美学动力。

用 Alan Watts 的话收尾：“*The only way to make sense out of change is to plunge into it, move with it, and join the dance.*”

11.9 本章小结

线性表示假说和 Superposition 假说构成了当前 Mech Interp 的理论基础。Sparse Autoencoder 从 Superposition 中提取可解释特征——从单层模型到 Claude 3 Sonnet 的成功扩展证明了方法的可行性。自动化可解释性有用但不能替代人类理解。未来的核心挑战是从“微生物学”走向“解剖学”——发现神经网络的宏观结构。Mech Interp 不仅服务于安全，也是对“我们到底创造了什么”这一深刻科学问题的探索。

12 Anthropic 路线图：三条线如何汇合

12.1 从 Scaling 到产品，再到治理

这场超长访谈最有价值的地方，不只是三位嘉宾各自表达了什么，而是它展示了一家前沿实验室内部如何把能力、行为、治理三条线编成同一条路线图。

路线层次	代表人物	核心问题	对应的 Anthropic 机制
能力层	Dario	模型是否持续变强、何时跨越关键门槛	Scaling、后训练、Computer Use、强大 AI 时间线
行为层	Amanda	模型如何在日常交互中表现得可信、稳妥、不过度谄媚	Claude 人格、CAI、System Prompt、行为评测
可验证层	Chris	我们如何知道模型内部到底在做什么	SAE、Monosemanticity、自动化可解释性、欺骗检测
治理层	三者共同作用	当能力逼近危险阈值时如何限制风险	RSP、ASL、外部评测、政策倡议

表 2: 访谈中隐含的 Anthropic 四层路线图

这不是三种兴趣，而是一条闭环

Dario 负责把能力推到前沿，Amanda 负责把模型塑造成可被社会使用的行为者，Chris 负责让这种系统变得可验证。没有任何一条线是可有可无的装饰；它们共同构成了 Anthropic 相对于其他前沿实验室最鲜明的组织叙事。

12.2 为什么人格设计与可解释性不是两件事

表面看，Amanda 讨论的是 Claude 的语气、谄媚和人格，Chris 讨论的是 SAE 与特征分解，像是完全不同的世界；但访谈实际上暗示它们最终会汇合。

- 如果我们只能通过输出观察模型行为，那么人格塑造就只能停留在“外显行为补丁”层
- 如果可解释性能稳定识别某些内部倾向，例如欺骗、讨好、权力寻求，那么人格和安全就能进入可验证阶段
- Dario 提到 ASL-4 可能需要用可解释性来检测 sandbagging，这正是两条线汇合的典型例子

Claude 的人格可以看成“对齐的可见层”

System Prompt、拒答风格、支持性语气、非谄媚行为，这些是用户看得见的结果；而 Chris 关心的 feature/circuit，则可能是这些结果背后的内部因果机制。换句话说，Amanda 在塑造界面，Chris 在寻找底层变量。

12.3 2025-2027 的关键分水岭

如果接受 Dario 的判断，那么未来两年内最关键的不是单个 benchmark，而是以下几个分水岭是否会同时发生：

1. **模型在真实工作任务中跨越人类专家水平**：尤其是编程、生物学与研究辅助
2. **Agent 能力显著增强**：从短回合问答进入数小时至数天的任务执行
3. **安全阈值开始被制度化触发**：ASL-3 或更高等级不再是抽象政策，而是实际部署门槛
4. **解释性从研究项目变成运营要求**：不再只是论文，而是安全发布的一部分

最危险的失败模式不是“模型突然失控”，而是组织误判

访谈里反复出现一个更现实的风险：我们可能在模型能力快速跃迁时，仍然用旧的组织假设、旧的审核流程、旧的产品心智去管理它。这样即便模型本身没有出现科幻式失控，也会因为制度滞后而放大风险。

12.4 对研究者与建设者的启示

这场访谈给出的不是单一结论，而是一份研究议程：

- 如果你关心能力前沿，就要研究 scaling、post-training、tool use 和高杠杆应用
- 如果你关心可部署性，就要研究 sycophancy、人格一致性、评测与人机关系
- 如果你关心长期安全，就必须进入 mechanistic interpretability、欺骗检测与独立验证
- 如果你关心社会后果，就不能跳过监管、制度惰性和权力分配问题

12.5 本章小结

Anthropic 的独特之处，不在于同时做模型、产品和安全，而在于试图把三者变成同一个系统工程。能力、人格、可解释性和治理在这里不是并列项目，而是彼此约束、彼此补强的闭环。

13 总结与延伸

13.1 三位嘉宾的核心观点

嘉宾	核心观点
Dario Amodei	Scaling 将继续；强大 AI 可能 2026-2027 到来；最大风险是权力集中
Amanda Askell	Claude 人格是对齐项目；“世界旅行者”框架；好品格比规则重要
Chris Olah	神经网络是“生长的有机体”；Superposition 是核心谜题；SAE 是突破工具

13.2 跨主题关联

三者形成完整图景：Dario 的 RSP 依赖 Chris 的 Interpretability 检测欺骗 (ASL-4)；Amanda 的人格设计通过 CAI 与 RLHF 互动；Chris 的“欺骗特征”直接关联 Dario 担忧的自主性风险。

13.3 访谈中最值得反复咀嚼的五个判断

1. Scaling 依然是主轴，但真正的瓶颈可能转向制度与组织适应速度
2. 后训练并非只是在美化输出，而是在把已有能力释放成可用接口
3. 人格塑造不是 UI 润色，而是对齐工程的一部分
4. Mechanistic Interpretability 若要真正重要，必须从论文工作流进入发布与审计工作流
5. 最深层的风险未必来自模型本身，而来自权力如何集中并被使用

13.4 三位嘉宾之间隐含的分歧与张力

这期访谈并不是三个人在重复同一个观点。更有意思的是，他们关注的重心不同，恰好构成了前沿 AI 组织内部真实存在的张力。

议题	Dario 的重心	Amanda 的重心	Chris 的重心
模型进步	持续 scaling、后训练与 agent 化	行为是否可被社会接受	我们是否真正理解模型内部机制
安全方法	RSP、ASL、制度门槛	人格、一致性、非谄媚行为	可解释性、欺骗检测、特征级验证
长期风险	权力集中、自主性风险、制度滞后	人机关系、诚实与同理心	内部机制不透明导致不可控
最有前景的工作	生物学、编程、后训练、部署	对齐、人格设计、评测	SAE、monosemanticity、自动化解释

表 3: 三位嘉宾关注点的差异与互补

真正的难点不是谁对谁错，而是怎样把三种视角同时落地

如果组织只听 Dario，容易高估能力进步而低估行为细节；只听 Amanda，容易把对齐局限在界面层；只听 Chris，则可能长期停留在研究深水区而缺少产品闭环。访谈的价值就在于它把三种视角放在同一张桌子上。

13.5 给不同角色读者的行动清单

这期访谈对不同角色的启发其实不同：

- **模型研究者**：重点看 scaling、后训练、解释性与 AI for science 的机会窗口
- **产品工程师**：重点看 sycophancy、System Prompt、人格一致性、Computer Use 的攻防面
- **安全与政策研究者**：重点看 RSP、ASL、制度性迟滞、监管的精确性和权力分配
- **创业者/组织负责人**：重点看人才密度、文化技艺、以及如何让安全成为竞争维度而非成本中心

这不是只属于 Anthropic 的访谈

虽然三位嘉宾都来自 Anthropic，但这期内容的价值不在公司八卦，而在它揭示了前沿 AI 组织普遍面对的四个问题：能力如何推进、行为如何塑造、内部如何验证、社会如何接住。无论你在 OpenAI、Google、Meta 还是开源社区，这四个问题都会回来。

13.6 对不同类型组织的策略含义

把这期访谈放回产业地图，还可以进一步看出不同组织应该怎么读它：

组织类型	最值得吸收的部分	最容易忽视的风险
前沿模型公司	Scaling、后训练、RSP、interpretability 路线图	只追能力而忽略行为与治理协同
应用层创业公司	Claude 人格、Computer Use、工作流产品化	低估上游模型能力突变对产品边界的冲击
企业技术团队	可解释性、权限边界、审查与部署节奏	误把模型能力提升当成组织 readiness 提升
政策与治理机构	ASL、制度滞后、权力集中问题	只做抽象讨论而缺少具体触发条件与验证工具

表 4: 不同组织从本期访谈中应提取的重点

换句话说，这期访谈不仅是 Anthropic 的自我阐释，也是一份前沿 AI 组织设计的案例研究：它告诉我们，能力、行为、验证和治理必须被同时建模，否则任何一条线单独领先都可能变成系统性短板。

13.7 进一步延伸的阅读路径

如果把这期访谈当作一张地图，后续阅读可以沿三条线继续深入：

- **能力线**：Scaling Laws、RLHF、Computer Use、AI for Biology
- **行为线**：Constitutional AI、sycophancy、model personality、human-AI relationship
- **可验证线**：SAE、monosemanticity、sandbagging detection、AI control

13.8 最后的收束

如果只用一句话总结这期五小时访谈，那就是：**前沿 AI 的真正竞争，不再只是模型谁更强，而是谁能把更强的模型放进更稳的组织系统里。** Dario 给出能力曲线，Amanda 讨论可被社会接受的行为边界，Chris 试图建立内部可验证性；三者合起来，才构成一套有机会长期成立的路线图。

13.9 对读者最实际的结论

对普通读者来说，这期访谈最终落回三个非常实际的判断：

1. 不要只用“模型排行榜”理解前沿 AI，要同时看行为、验证和治理
2. 不要把对齐理解成礼貌语气或拒答策略，它最终必须连接到内部机制和制度设计
3. 不要把长期风险和现实产品化割裂开来，这两者在 Anthropic 的叙事里本来就是同一件事的两个侧面

13.10 能力-行为-验证-治理矩阵

维度	访谈中的代表问题	对组织的要求	如果缺失会怎样
能力	模型还能否继续 scaling、还能否完成更长任务	持续的训练、后训练与产品化节奏	被更强模型迅速甩开
行为	模型是否诚实、非谄媚、可被用户接受	人格设计、CAI、评测与交互策略	产品可用性和信任快速恶化
验证	我们是否知道模型内部在做什么	可解释性研究、特征追踪、独立安全验证	安全判断过度依赖外显行为
治理	何时触发约束、谁来负责、如何防止权力集中	RSP、ASL、组织与政策协同	能力增长快于制度准备速度

表 5: 本期访谈压缩出的四维矩阵

这张矩阵的意义在于，它把三位嘉宾的讨论真正压缩成了一个可执行框架。很多组织会只投其中一维，例如只投模型能力、只做产品行为修补、或者只做政策表态，但访谈反复暗示：少任何一维，系统都会失衡。

13.11 拓展阅读

- Dario Amodei, *Machines of Loving Grace*, 2024
- Amanda Askell, *The optimal rate of failure*, Blog
- Chris Olah et al., *Towards Monosemanticity*, Anthropic, 2023
- Chris Olah et al., *Scaling Monosemanticity*, Anthropic, 2024
- Anthropic, *Responsible Scaling Policy*, 2023