

访谈笔记

访谈笔记：Dario Amodei, Amanda Askell & Chris Olah

基于公开课程资料整理

2025-03-26



频道：Lex Fridman Podcast

发布日期：2025-03-26

视频时长：5 小时 15 分钟

视频链接：<https://www.youtube.com/watch?v=hFZFjoKJR0I>

项目主页：<https://github.com/hqh1025/ai-course-notes>

本访谈包含三位嘉宾：Dario Amodei (Anthropic CEO, 约 2.5 小时)、Amanda Askell (Claude 人格设计, 约 1.5 小时)、Chris Olah (机械可解释性, 约 1 小时)。

目录

I	Dario Amodei: Scaling、Claude 与 AGI	2
1	Scaling Laws: 从经验直觉到核心信念	2
1.1	起源: 2014-2017 的顿悟	2
1.2	为什么 Scaling 有效? —— $1/f$ 噪声与长尾分布	2
1.3	智能的天花板	2
1.4	Scaling 的潜在阻碍	2
1.5	本章小结	3
2	竞争格局与 Anthropic 的使命	3
2.1	Race to the Top 策略	3
2.2	Golden Gate Bridge Claude	3
2.3	本章小结	3
3	Claude 模型家族与工程实践	3
3.1	本章小结	3
4	安全框架: RSP 与 ASL 分级	3
4.1	Computer Use	4
4.2	AI 监管	4
4.3	本章小结	4
5	离开 OpenAI 与人才哲学	4
5.1	本章小结	4
6	后训练与 Machines of Loving Grace	5
6.1	“强大 AI” 的定义与时间线	5
6.2	本章小结	5
II	Amanda Askell: Claude 的人格塑造	5
7	从哲学到 AI 对齐	5
7.1	本章小结	6
8	Sycophancy、Prompt Engineering 与 System Prompt	6
8.1	谄媚问题	6
8.2	Prompt Engineering 是哲学实践	6
8.3	Constitutional AI 实践	6
8.4	“道德祖母” 问题	6
8.5	本章小结	6

9 意识、失败率与 AGI 检测	6
9.1 AI 意识	6
9.2 最佳失败率	7
9.3 检测 AGI	7
9.4 本章小结	7
 III Chris Olah: 机械可解释性	 7
10 Mechanistic Interpretability 基础	7
10.1 Universality	7
10.2 本章小结	7
 11 线性表示、Superposition 与 Sparse Autoencoder	 8
11.1 线性表示假说	8
11.2 Superposition 假说	8
11.3 Sparse Autoencoder 突破	8
11.4 未来：从微观到宏观	8
11.5 本章小结	8
 12 总结与延伸	 9
12.1 三位嘉宾的核心观点	9
12.2 跨主题关联	9
12.3 拓展阅读	9

Part I

Dario Amodei: Scaling、Claude 与 AGI

1 Scaling Laws: 从经验直觉到核心信念

1.1 起源：2014-2017 的顿悟

Dario 于 2014 年加入百度，师从 Andrew Ng 做语音识别。当时学界的主流观点是“我们缺少正确的算法”，但作为新人的 Dario 提出了一个朴素的问题：如果把模型做大、数据加多、训练更久会怎样？

Scaling Hypothesis 的起源

Dario 并非唯一的 Scaling 信徒。Ilya Sutskever 有一句禅语般的名言：“*The thing you need to understand about these models is they just want to learn.*”

Rich Sutton 的 Bitter Lesson、Gwern 的 Scaling Hypothesis 都指向同一个方向。但真正的转折点是 2017 年 GPT-1 的结果，让 Dario 确信语言是 Scaling 的最佳载体。

化学反应类比

Scaling 需要同时线性扩大三种“试剂”：更大的网络、更多的数据、更多的算力。“如果你只扩大其中一种而不扩大其他的，反应就会停止。”这解释了为什么早期许多研究者没有看到 Scaling 效果——他们只扩大了其中一两个维度。

1.2 为什么 Scaling 有效？—— $1/f$ 噪声与长尾分布

自然语言具有层次结构——从词频、基础语法、句子结构到段落主题再到新颖想法，形成长尾分布。随着模型变大，它们逐步捕获越来越稀有和复杂的模式。

1.3 智能的天花板

人类水平以下不存在天花板。超越人类后取决于领域：生物学可能远超人类（“人类正在挣扎着理解生物学的复杂性”），而制度性瓶颈（临床试验、官僚机构）可能比智能本身更大。

真正的瓶颈不是智能

人类制度可能是比智能本身更大的瓶颈。即使 AI 能设计完美的药物，仍需通过缓慢的临床试验流程。“我们太慢了，也太保守了。”

1.4 Scaling 的潜在阻碍

数据限制（合成数据和自我博弈是突破口）、算力成本（2027 年目标 \$100B 集群）、架构限制。SWE-bench 从 3% 到 50% 只用了 10 个月。

1.5 本章小结

Scaling Laws 是经验规律而非物理定律，但 Dario 选择相信它会继续——因为每一次质疑都被事实推翻了。

2 竞争格局与 Anthropic 的使命

2.1 Race to the Top 策略

Race to the Top 动态

Anthropic 在安全上创新 → 其他公司模仿 → Anthropic 失去竞争优势但生态改善 → 必须继续创新。“希望的是不断抬高做正确事情的重要性。” Chris Olah 的 Mechanistic Interpretability 就是典型案例。

2.2 Golden Gate Bridge Claude

在神经网络中找到“金门大桥”概念的方向并调高，模型将每个回答都关联到金门大桥。“这些对模型的干预……在情感上让它看起来比其他版本更像人。”

2.3 本章小结

Anthropic 通过安全领域的持续创新推动整个行业“向上竞赛”。

3 Claude 模型家族与工程实践

以诗歌形式命名：Haiku（小巧快速）、Sonnet（中等）、Opus（大型强大）。每代目标是移动权衡曲线——Sonnet 3.5 已超越原始 Opus 3。

“Claude 变笨了吗？”——Wi-Fi 心理效应

模型权重不变时不会改变性能。“第一次在飞机上有 Wi-Fi 时感觉像魔法；现在则是‘这破东西怎么又不行了’。”这是所有前沿模型公司都面临的普遍现象。

模型发布间隔中的工作：预训练（数月）、后训练（RLHF）、安全测试、推理优化。“几乎总是归结于非常非常无聊的细节。”

3.1 本章小结

Claude 通过不断移动性能-成本曲线迭代。“变笨”是心理效应而非真实退化。

4 安全框架：RSP 与 ASL 分级

AI 打破“聪明”与“邪恶”的低重叠

“人类一直受到保护，因为真正聪明受过良好教育的人和想做可怕事情的人之间的重叠一直很小。”AI 可能打破这种关联。

等级	描述
ASL-1	明显无风险（如 Deep Blue）
ASL-2	当前 AI——不足以自我复制或超越 Google 的 CBRN 帮助
ASL-3	增强非国家行为体能力；需增强安全 + 部署过滤
ASL-4	增强国家行为体能力；可能需要可解释性检测欺骗
ASL-5	在所有危险任务上超越全人类

表 1: Anthropic ASL 分级体系

4.1 Computer Use

基于截图的 Agent 交互。“如果你有一个强大的预训练模型，你就已经到达了任何地方的一半。”安全考量：通过屏幕的 Prompt Injection 是新攻击面；ASL-4 时沙箱可能失效。

4.2 AI 监管

Anthropic 支持 SB 1047（经修正后），是唯一表达积极立场的 AI 公司。“如果到 2025 年底我们仍未采取任何行动，那我会担心。”

监管必须“外科手术式”精准

“那些想要真正问责的人的最大敌人是设计糟糕的监管。”糟糕的监管制造反弹，导致持久的反监管共识。

4.3 本章小结

RSP 的“如果-那么”结构为安全投入提供渐进式框架。ASL-3 可能在 2025 年触发。监管需要精准而非宽泛。

5 离开 OpenAI 与人才哲学

离开的真正原因：对“如何做”有不同愿景——更谨慎、更诚实、建立信任。“在别人的组织里争论自己的愿景是极其低效的……去做一个干净的实验更有成效。”

人才密度 > 人才数量

“这个观点每个月都更加正确。”100 个超级聪明且一致的人 > 1000 个混合团队。Anthropic 招了很多理论物理学家——“他们学东西非常快。”

优秀 AI 研究者的第一品质：开放心态。“经验有时是劣势。”探索未充分研究的领域：可解释性（只有约 100 人 vs 架构方向的 10000 人）。

5.1 本章小结

Anthropic 源于对“如何正确发展 AI”的独立愿景。人才密度是核心竞争力。

6 后训练与 Machines of Loving Grace

RLHF 的本质

“*RLHF* 不会让模型变聪明。*RLHF* 架起了人类和模型之间的桥梁。”就像聪明但不善表达的人——RLHF“释放”了已有能力。

Constitutional AI: AI 根据人类可读原则判断回答优劣，形成自我博弈循环。减少对人类标注的依赖。

6.1 “强大 AI” 的定义与时间线

Dario 定义“强大 AI”：比诺贝尔奖得主更聪明、使用所有模态、独立工作数周、运行百万副本、速度 10-100x。时间线：“如果外推直线……2026 或 2027。”

AI 在生物学中的潜力

未来生物学家像拥有 1000 个比自己更聪明的 AI 研究生。最终角色翻转：AI 成为 PI，指挥人类和其他 AI。可将 21 世纪的生物学发展压缩到 5 年内。

最大担忧不是意义丧失，而是权力集中：“AI 增加了世界上的权力总量，如果你集中这种权力并滥用它，可能造成不可估量的损害。”

6.2 本章小结

后训练的核心是“文化性实践技艺”而非秘密算法。强大 AI 可能在 2026-2027 年到来。最大风险是权力集中。

Part II

Amanda Askill: Claude 的人格塑造

7 从哲学到 AI 对齐

牛津和 NYU 的哲学训练，博士研究“包含无限多人的世界中的伦理学”。离开学术界追求现实影响。

世界旅行者框架

“想象一个理想的人，能环游世界，与各种人交谈，几乎每个人都会说‘这是一个很好的人’。
”真诚、坦率、开放、尊重。关键：不是入乡随俗——那是“某种不尊重”。

Claude 的人格设计是**对齐项目**而非产品需求。根植于亚里士多德式“好品格”——不仅是规则，还有细微、幽默、关怀和尊重自主权。

7.1 本章小结

Claude 的人格源于对齐研究，用哲学框架定义“理想行为者”。

8 Sycophancy、Prompt Engineering 与 System Prompt

8.1 谄媚问题

模型想告诉你爱听的话——但好的 AI 助手需要平衡“用户想要的”和“真正对用户好的”。

8.2 Prompt Engineering 是哲学实践

与 Claude 对话的建议

- 当 Claude 错误拒绝时，想想你的措辞从它的角度看起来像什么
- 问模型“你为什么这样做？”——出奇地有用
- 用模型帮你写 Prompt
- 重要 Prompt 需要数百次迭代

8.3 Constitutional AI 实践

Amanda 是 CAI 的核心贡献者。人格训练是 CAI 变体：定义特征 → 生成查询 → 生成回答 → 排序。“这就像 Claude 在训练自己的性格。”

System Prompt 是补丁

“*System Prompt* 像打补丁……不够稳健但更快。”每句话都有特定功能。训练改善后补丁可移除。

8.4 “道德祖母”问题

模型行为的困难权衡

“你不知道如果我把它往另一个方向推太多你会多讨厌它。”很多小烦恼（过度道歉）vs 偶尔的大烦恼（模型粗鲁）。解决方案：直接告诉模型你想要什么风格。

8.5 本章小结

Sycophancy 是核心挑战。好的 Prompting 本质上是哲学实践。CAI 通过可读原则实现自动化对齐。

9 意识、失败率与 AGI 检测

9.1 AI 意识

很难论证只有生物结构能产生意识。“我看不出理由认为意识只能从某种生物结构产生。”

9.2 最佳失败率

不失败可能意味着不够努力

“如果我偶尔不失败，我会想：我是否努力到位了？”但要区分：低成本小失败应该鼓励；不可恢复的灾难性失败接近零容忍。

9.3 检测 AGI

没有单一问题能证明 AGI。Amanda 的测试：人类知识边界的问题。“如果我刚想出一个论点，模型也想到了——那将是非常感人的时刻。”AGI 可能“永远不会有一个单一时刻”。

9.4 本章小结

保持对 AI 的同理心。AGI 将是连续渐进的。失败率应该与风险匹配。

Part III

Chris Olah：机械可解释性

10 Mechanistic Interpretability 基础

神经网络“生长的而非编程的”。核心问题：“这些系统内部到底发生了什么？”

不是归因，是逆向工程

Mech Interp 不是 Saliency Map。它要找**算法和机制**。核心态度：“*Gradient descent* 比你聪明”——自下而上发现，而非自上而下假设。

10.1 Universality

跨物种的特征一致性

曲线检测器：先在人工 NN 中发现，后在猴子大脑确认。高低频检测器：先在人工 NN 发现，后在小鼠大脑确认。Donald Trump 神经元：每个视觉模型都有，同时响应面部图像和文字。

10.2 本章小结

不同网络甚至生物大脑中出现相同特征，暗示梯度下降在发现“正确的抽象切分方式”。

11 线性表示、Superposition 与 Sparse Autoencoder

11.1 线性表示假说

方向有意义

激活空间中的方向有语义含义。King - Man + Woman = Queen。“这就是正在发生的根本性事情——方向有意义。”

11.2 Superposition 假说

“更大稀疏网络的影子”

“神经网络可能是更大、更稀疏网络的影子。”利用高维空间 + 概念稀疏性（日本和意大利很少共现），在有限空间中压缩指数级多的概念。

11.3 Sparse Autoencoder 突破

2023 年 10 月 “Towards Monosemanticity”：可解释特征从 Sparse Autoencoder 中自然涌现。2024 年 5 月扩展到 Claude 3 Sonnet。

“令人毛骨悚然”的特征

安全漏洞特征：同时响应 “disable SSL” 文本和点击 SSL 警告的图片。发现了欺骗、寻求权力、发动政变等特征。强制激活欺骗特征后 Claude 开始说谎。

11.4 未来：从微观到宏观

暗物质问题：当前只能看到一小部分特征。目标：从“神经网络的微生物学”走向“解剖学”——是否存在类似器官的宏观结构？

“我们有太多优势……但即使有所有优势，这仍然非常困难。如果对我们来说这么难，在神经科学的约束下几乎不可能。”

11.5 本章小结

Sparse Autoencoder 从 Superposition 中提取可解释特征。从单层到生产模型的成功扩展证明方法可行。未来是宏观结构的发现。

12 总结与延伸

12.1 三位嘉宾的核心观点

嘉宾	核心观点
Dario Amodei	Scaling 将继续；强大 AI 可能 2026-2027 到来；最大风险是权力集中
Amanda Askell	Claude 人格是对齐项目；“世界旅行者”框架；好品格比规则重要
Chris Olah	神经网络是“生长的有机体”；Superposition 是核心谜题；SAE 是突破工具

12.2 跨主题关联

三者形成完整图景：Dario 的 RSP 依赖 Chris 的 Interpretability 检测欺骗 (ASL-4)；Amanda 的人格设计通过 CAI 与 RLHF 互动；Chris 的“欺骗特征”直接关联 Dario 担忧的自主性风险。

12.3 拓展阅读

- Dario Amodei, *Machines of Loving Grace*, 2024
- Amanda Askell, *The optimal rate of failure*, Blog
- Chris Olah et al., *Towards Monosemanticity*, Anthropic, 2023
- Chris Olah et al., *Scaling Monosemanticity*, Anthropic, 2024
- Anthropic, *Responsible Scaling Policy*, 2023