

课程笔记

DeepSeek、中国 AI、OpenAI、NVIDIA、 xAI、TSMC 与 AI 超级集群

五道口纳什 & Codex

2026 年 3 月 29 日



视频作者/频道: Lex Fridman

发布日期: 2025

视频时长: 5h 6m

视频链接: <https://www.youtube.com/watch?v=DeepSeek-China-AI>

目录

1 引言：DeepSeek 时刻	2
1.1 本章小结	2
2 DeepSeek 技术剖析	2
2.1 Mixture of Experts (MoE) 架构	2
2.2 底层优化：CUDA 层以下	2
2.3 低成本训练的技术栈	3
2.4 本章小结	3
3 The Bitter Lesson 与 Scaling	3
3.1 Rich Sutton 的 Bitter Lesson	3
3.2 DeepSeek 是否违反了 Bitter Lesson?	3
3.3 本章小结	3
4 美国对华芯片出口管制	4
4.1 从 A100 到 H800 到 H20	4
4.2 互连带宽的关键性	4
4.3 DeepSeek 如何适应受限硬件	4
4.4 本章小结	4
5 中美 AI 竞争	5
5.1 人才因素	5
5.2 基础设施与能源	5
5.3 开源/开放权重的地缘意义	5
5.4 本章小结	5
6 TSMC 与半导体制造	5
6.1 TSMC 的不可替代性	5
6.2 本章小结	6
7 Transformer、Attention 与 KV Cache	6
7.1 Attention 机制回顾	6
7.2 KV Cache 的角色	6
7.3 Multi-Head Latent Attention (MLA)	7
7.4 本章小结	7
8 AI 数据中心与超级集群	7
8.1 现代 AI 数据中心的物理形态	7
8.2 Stargate 等超级项目	7
8.3 本章小结	8

9 推理与 RL 的前沿	8
9.1 从 RLHF 到 RLVR	8
9.2 泛化拐点假说	8
9.3 软件工程作为关键测试场	8
9.4 本章小结	9
10 开源/开放权重的生态	9
10.1 DeepSeek 开源的战略意义	9
10.2 AI2 的开源实践	9
10.3 本章小结	9
11 AI 对认知与社会的影响	9
11.1 互联网、社交媒体与认知主权	9
11.2 AI 与自我驯化	10
11.3 本章小结	10
12 AI 产业格局：主要玩家	10
12.1 各公司定位	10
12.2 xAI 的 Colossus 集群	10
12.3 本章小结	11
13 总结与延伸	11
13.1 拓展阅读	11

1 引言：DeepSeek 时刻

2025 年初，DeepSeek 的发布震动了整个 AI 行业。Lex Fridman 借此机会邀请了两位重量级嘉宾——Dylan Patel (SemiAnalysis 创始人) 和 Nathan Lambert (AI2 研究员)，进行了一场 5 小时的深度对话，覆盖了从 DeepSeek 技术细节到中美 AI 竞争、从 NVIDIA 到 TSMC、从开源模型到 AI 超级集群的全景分析。

嘉宾背景

- **Dylan Patel**: SemiAnalysis 创始人，专注于半导体、GPU、CPU 和 AI 硬件的研究分析，被 AI 领域的专家和工程师广泛阅读
- **Nathan Lambert**: Allen Institute for AI (AI2) 研究员，Interconnects 博客作者，专注于 RLHF、开源模型等方向

1.1 本章小结

DeepSeek 的出现打破了”只有美国顶尖实验室才能训练前沿 LLM”的假设，引发了关于计算效率、开源策略和地缘政治的广泛讨论。

2 DeepSeek 技术剖析

2.1 Mixture of Experts (MoE) 架构

DeepSeek 实现低成本训练的第一个关键技术是 Mixture of Experts (MoE)。

MoE 的核心机制

MoE 架构将 Transformer 的 FFN 层替换为多个”专家”(expert)子网络。对于每个 token，只有少数几个专家被激活：

- **总参数量大**：模型拥有大量参数（如 671B），但每个 token 只激活其中一部分（如 37B）
- **Router**：一个门控网络决定每个 token 被路由到哪些专家
- **训练效率**：大模型的表达能力 + 小模型的计算成本
- **推理效率**：每个 token 的计算量（FLOPs）远低于等参数量的 dense model

2.2 底层优化：CUDA 层以下

DeepSeek 的另一个显著特点是其工程团队在极底层进行了优化——在 CUDA 层甚至更低的层级对 NVIDIA GPU 进行定制化编程。

极少数人掌握的技能

Dylan 指出，能在 CUDA 层以下做高效训练优化的人在全世界非常稀少。这些人需要同时理解 GPU 微架构、内存层次、指令调度和分布式计算。DeepSeek 拥有这样的人才，美国前沿实验室也有，但全球范围内这是一个极其稀缺的技能集。

2.3 低成本训练的技术栈

DeepSeek 训练效率的来源

DeepSeek 实现低成本训练的完整技术栈：

1. **MoE 架构**：减少每个 token 的计算量
2. **底层 GPU 优化**：在 CUDA 层以下最大化硬件利用率
3. **多项工程优化**：包括通信优化、内存管理、混合精度训练等
4. **FP8 训练**：使用更低精度的浮点格式来提升吞吐量

这些技术的叠加效果使得 DeepSeek 能用约 2000 颗 H800 GPU 训练出前沿水平的模型。

2.4 本章小结

DeepSeek 的技术创新不在于发明全新的理论，而在于将已知技术（MoE、底层优化、高效训练）极致地组合和工程化实现。

3 The Bitter Lesson 与 Scaling

3.1 Rich Sutton 的 Bitter Lesson

对话深入讨论了 Rich Sutton 的著名文章“The Bitter Lesson”。

Bitter Lesson 的核心观点

Bitter Lesson 的核心论点是：在深度学习中，最终胜出的方法是那些在学习和搜索方面可规模化（scalable）的方法。Nathan 的解读是：应该避免在学习过程中添加人类先验（human priors），让模型通过纯计算来发现规律。历史上，研究者反复尝试用巧妙的手工方案来解决问题，但最终都被更简单、更可扩展的方法击败。

3.2 DeepSeek 是否违反了 Bitter Lesson？

一个有趣的问题是：DeepSeek 的 MoE 和各种工程优化是否违反了 Bitter Lesson？因为这些都是“聪明的”设计选择，而非简单的 scaling。

Bitter Lesson 的细微之处

Bitter Lesson 反对的是添加 domain-specific 的人类先验（如手工特征、规则系统），而非反对通用的系统优化。MoE 是一种通用的架构选择，其核心思想（稀疏激活）适用于各种任务，因此并不违反 Bitter Lesson。真正的问题是：在给定计算预算下，如何最高效地利用这些计算资源——而 DeepSeek 在这方面做到了极致。

3.3 本章小结

Bitter Lesson 仍然是 AI 领域的指导原则，但“可扩展的计算”不仅意味着使用更多 GPU，也包括更高效地使用现有 GPU。

4 美国对华芯片出口管制

4.1 从 A100 到 H800 到 H20

对话详细梳理了美国对华芯片出口管制的演变过程及其对 DeepSeek 的影响。

芯片管制时间线

1. **2022 年 10 月**：美国禁止向中国出口 A100 GPU
2. **H800**：NVIDIA 为中国市场推出的“阉割版”，互连带宽被限制（NVLink 降级）
3. **2023 年末**：H800 也被禁止出口
4. **H20**：进一步降规格的版本，计算能力和带宽都大幅缩减

DeepSeek 的约 2000 颗 H800 GPU 是在禁令生效前采购的，之后他们需要在更受限的硬件上继续研究。

4.2 互连带宽的关键性

Dylan 解释了为什么芯片管制特别针对互连带宽：

为什么带宽比算力更重要

大模型训练需要在数千颗 GPU 之间频繁交换数据（梯度同步、all-reduce 操作等）。单颗 GPU 的浮点性能再强，如果 GPU 之间的通信带宽不够，训练效率就会急剧下降。这就是为什么美国的管制重点从限制 FLOPs 转向限制互连带宽——限制一颗 GPU 的能力容易绕过（通过堆数量），但限制 GPU 间的通信直接影响集群的训练能力。

4.3 DeepSeek 如何适应受限硬件

受限硬件下的创新

DeepSeek 团队早在 2022 年 10 月就了解到互连带宽限制，并开始研究如何在带宽受限的条件下高效训练。他们的核心策略：

- 在 CUDA 层以下优化通信模式，最大化利用有限带宽
- 设计适合低带宽环境的并行化策略
- 通过 MoE 减少需要同步的参数量

这种“在约束中创新”反而产生了通用的高效训练技术。

4.4 本章小结

芯片管制迫使 DeepSeek 在受限硬件上寻找效率极致化的方法，某种意义上反而催生了技术创新。但长期来看，计算资源的差距仍然是中美 AI 竞争的重要变量。

5 中美 AI 竞争

5.1 人才因素

Nathan 指出了—个常被忽视的事实：美国顶尖 AI 实验室的很多核心研究人员是没有美国护照的人——其中很大一部分是来自中国的研究者。

人才流动的双面性

中国研究者移居美国为美国 AI 发展做出了巨大贡献，但这也意味着：(1) 中国本土不缺乏 AI 人才储备，(2) 人才政策的变化可能迅速改变竞争格局，(3) 将”人才”视为美国的独有优势是危险的。Nathan 认为，中美 AI 竞争的真正决定性因素不是人才，而是计算资源 (compute)。

5.2 基础设施与能源

Dylan 从硬件和基础设施角度分析了中国的能力：

中国的基础设施优势

- **电力建设**：中国具有快速建设大规模电力基础设施的能力
- **钢铁和水泥**：数据中心建设所需的原材料供应充足
- **制造能力**：大规模建设和部署基础设施的速度远超大多数国家

但中国在先进 GPU 获取上受到限制，这在短期内仍是瓶颈。

5.3 开源/开放权重的地缘意义

Nathan 讨论了 DeepSeek 开放模型权重的战略意义——这与 OpenAI 等公司关于”中国可能利用美国公司的数据训练模型”的叙事形成了有趣的对比。

数据与开源的复杂关系

OpenAI 曾声称有证据表明 DeepSeek 使用了其模型输出来训练。Nathan 的回应很直接：无论如何，OpenAI 的数据已经在互联网上（如 Reddit 上分享 ChatGPT 最佳输出的帖子），这些数据自然会进入任何人的预训练数据集。OpenAI 试图控制这种叙事更多是在保护自己的商业利益，而非真正的知识产权问题。

5.4 本章小结

中美 AI 竞争是多维度的——人才、计算、基础设施、政策。芯片管制是当前最显性的博弈工具，但长期竞争格局取决于更多因素的综合作用。

6 TSMC 与半导体制造

6.1 TSMC 的不可替代性

Dylan 深入解释了为什么 TSMC 是全球半导体供应链中最关键的单一节点。

TSMC 的技术护城河

TSMC 的先进制程制造涉及极其专业化的知识和技能：

- 工人像蚁群一样高度专业化——每个人专注于制造流程中的一个微小环节
- 每个任务涉及特定的化学工艺加纳米制造，在一条特定的工具线上持续迭代
- 例如：一个人可能终其职业生涯只做一种特定的等离子蚀刻（plasma etching），用于去除二氧化硅
- 这种极度专业化的知识是”进了 Fab 就知道该怎么修”的默会知识（tacit knowledge）

TSMC 的地缘风险

TSMC 的核心产能集中在台湾，这使其成为地缘政治中的关键变量。虽然 TSMC 在美国和日本建设新的 Fab，但先进制程的量产能力在短期内仍集中在台湾。这意味着任何影响台湾的地缘事件都可能直接冲击全球 AI 硬件供应链。

6.2 本章小结

TSMC 的竞争优势来自于数十年积累的默会知识和极度专业化的人才，这是最难被复制的。但其地理集中度也是全球供应链最大的风险点之一。

7 Transformer、Attention 与 KV Cache

7.1 Attention 机制回顾

Nathan 在 Dylan 的引导下解释了 Transformer 中 attention 机制的工作原理：

Attention 的计算本质

Attention 机制使模型能够理解上下文中所有 token 之间的关系。这个计算与模型参数本身是分离的：

- **参数**：存储在 FFN 层的权重中，代表模型的”知识”
- **Attention**：计算 token 之间的关系，是一个动态的、依赖输入的计算
- 计算复杂度为 $O(n^2 \cdot d)$ ，其中 n 是序列长度， d 是 embedding 维度

7.2 KV Cache 的角色

在推理（inference）过程中，KV Cache 是一个关键的优化：

KV Cache 解释

在 autoregressive 生成中，每生成一个新 token，都需要计算它与之前所有 token 的 attention。如果不缓存，就需要重新计算所有之前 token 的 Key 和 Value 向量。KV Cache 将之前计算过的 K、V 向量存储起来，使得每步生成只需要计算新 token 的 Q、K、V 并与缓存做 attention。代价是：KV Cache 的内存占用随序列长度线性增长，对于长上下文推理（如 128K+ tokens），KV Cache 可能成为 GPU 内存的主要瓶颈。

7.3 Multi-Head Latent Attention (MLA)

DeepSeek 在 attention 机制上的一个创新是 Multi-Head Latent Attention (MLA)，它通过压缩 KV 的表示来减少 KV Cache 的内存占用。

MLA 的设计思路

传统 Multi-Head Attention (MHA) 为每个 head 独立存储完整的 K 和 V 向量。MLA 的核心思想是：将多个 head 的 KV 信息压缩到一个低维的 latent 空间中，推理时再解压。这大幅减少了 KV Cache 的内存占用，使得在相同硬件上能处理更长的上下文。这个设计与 DeepSeek 面临的硬件约束高度一致——在有限的 GPU 内存中，更高效地利用每一个字节。

7.4 本章小结

Transformer 的 attention 机制是 LLM 的核心，KV Cache 是推理效率的关键优化。DeepSeek 的 MLA 创新展示了在硬件约束下如何通过架构创新来突破瓶颈。

8 AI 数据中心与超级集群

8.1 现代 AI 数据中心的物理形态

Dylan 介绍了现代 AI 数据中心的物理架构，它们与传统数据中心有着本质的不同。

AI 数据中心的构成

- **核心计算区**：存放 GPU 机架的区域，物理面积相对较小
- **冷却系统**：水冷管道和冷却塔，占地面积可能超过计算区本身
- **备用电源**：大量柴油发电机组作为备用电力
- **关键观察**：实际的芯片计算区域比水冷系统小得多——散热比计算本身更占空间

8.2 Stargate 等超级项目

对话提到了以 Stargate 为代表的 AI 超级集群项目——这些项目规模达到 GW 级功率，投资额度数百亿到数千亿美元。

超级集群的风险

如此大规模的基础设施投资面临多重风险：

- **技术迭代风险**：当数据中心建成时，GPU 可能已经换代
- **能源约束**：GW 级电力供应在很多地区需要数年来建设
- **投资回报不确定**：AI 模型的商业价值能否支撑如此巨大的基础设施投入
- **地缘政治风险**：跨国供应链中的任何一环断裂都可能影响项目进度

8.3 本章小结

AI 数据中心已经从 IT 设施演变为类似于发电站的大型工业系统。散热和电力供应正在成为比计算本身更具挑战性的工程问题。

9 推理与 RL 的前沿

9.1 从 RLHF 到 RLVR

Nathan 详细解释了强化学习在 LLM 训练中的演进。

RL 训练的演进路径

1. **RLHF**：使用人类偏好训练 reward model，再用 RL 优化 LLM
2. **RLVR**：直接使用可验证的正确性信号（如代码执行结果、数学证明验证器）作为 reward
3. **多领域 RL**：在越来越多的可验证领域训练，探索泛化边界

9.2 泛化拐点假说

Nathan 提出了一个令人兴奋的假说：在 instruction tuning 的文献中，当训练的任务类型数量超过某个阈值时，模型突然能泛化到从未见过的任务类型。类似的现象可能也存在于 RLVR 中。

泛化拐点的含义

如果 RLVR 也存在泛化拐点，那么当你在足够多的可验证领域（数学、代码、逻辑推理、科学计算等）上训练后，模型可能“突然”也能在不可验证的领域（如战略分析、创意写作）展现出更强的推理能力。这将是 AI 能力的一个质的飞跃。但目前我们不知道这个拐点是否存在，以及在哪里。

9.3 软件工程作为关键测试场

对话提到软件工程是当前 AI 推理能力最重要的测试场之一。代码具有天然的可验证性（能否编译、能否通过测试），同时又需要复杂的推理和规划能力。

9.4 本章小结

RLVR 正在快速推动 AI 推理能力的提升，泛化拐点假说如果成立将是 AI 能力的重大突破。软件工程是验证这些进展的最佳领域之一。

10 开源/开放权重的生态

10.1 DeepSeek 开源的战略意义

DeepSeek 选择开放模型权重，这在地缘政治的语境下具有多重含义。

开放权重 vs 开源

需要区分“开放权重”（open weights）和“开源”（open source）：

- **开放权重**：公开模型参数，允许推理和微调，但不公开训练数据和完整训练流程
- **完全开源**：公开所有训练代码、数据、配置，允许完全复现
- DeepSeek 属于开放权重，这已经足以让社区在其基础上构建

10.2 AI2 的开源实践

Nathan 来自 AI2，这是一个致力于开放 AI 研究的机构。他们不仅开放模型权重，还尝试开放更多的训练细节。

AI2 的立场

AI2 认为开放 AI 研究对于以下目标至关重要：

- 推动科学进步：可复现的研究才是好的研究
- 防止垄断：确保 AI 能力不被少数公司独占
- 安全研究：只有理解模型才能有效地研究安全性

10.3 本章小结

开源/开放权重是 AI 生态的重要组成部分。DeepSeek 的开放策略展示了即使在地缘政治紧张背景下，技术开放也可以是一种有效的竞争策略。

11 AI 对认知与社会的影响

11.1 互联网、社交媒体与认知主权

对话中有一段引人深思的讨论：Lex 分享了他关于断开互联网连接时的体验。他观察到，当他进行几天的户外活动（如背包旅行）并完全断开互联网后，大约在第三天会感到一种认知上的“重置”——打破成瘾周期，重新获得对自己思维的控制。

认知主权的挑战

Lex 提出了一个深刻的观察：

- 使用互联网和社交媒体越多，你的思维就越受他人控制
- 断开连接后，你能感到一种“智力主权”（sovereignty of intelligence）的回归
- AI 的广泛使用可能进一步加剧这种现象——如果我们依赖 AI 做决策，我们是否在放弃认知自主权？

这不仅是个人问题，也是社会层面的问题。

11.2 AI 与自我驯化

对话触及了一个跨学科的话题：人类的“自我驯化”（self-domestication）假说。Lex 用 AI 工具探索了这个概念——人类不仅仅是社会动物，更是深度自我驯化的猿类（self-domesticated apes），这种自我驯化是理解我们独特认知和社会能力的关键。

11.3 本章小结

AI 技术的影响远不止于技术和商业层面。它正在深刻地改变人类的认知模式和社会互动方式，这些影响值得更多的关注和反思。

12 AI 产业格局：主要玩家

12.1 各公司定位

对话覆盖了 AI 产业的主要参与者：

AI 产业主要玩家

- **OpenAI**：闭源前沿模型，最大的商业化 AI 公司
- **Google DeepMind**：Gemini 系列，拥有独特的 TPU 硬件优势
- **Anthropic**：Claude 系列，注重安全和对齐
- **Meta**：Llama 开放权重系列，推动开放 AI 生态
- **xAI**：Elon Musk 的 AI 公司，Grok 系列
- **DeepSeek**：中国最具影响力的开放 AI 公司
- **NVIDIA**：AI 硬件和软件栈的基础设施提供商
- **TSMC**：所有先进 AI 芯片的制造商

12.2 xAI 的 Colossus 集群

Dylan 提到了 xAI 的 Colossus 超级集群——这是当时世界上最大的 AI 训练集群之一，展示了 Elon Musk 在基础设施建设上的激进策略。

12.3 本章小结

AI 产业格局正在快速演变，竞争不仅发生在模型层面，还发生在基础设施、生态系统和战略定位等多个维度。

13 总结与延伸

这场 5 小时的深度对话提供了 AI 领域最全面的快照之一。核心要点包括：

1. **DeepSeek 的启示**：计算效率的极致优化可以部分弥补原始计算资源的不足
2. **MoE 架构**：成为大模型训练的重要范式，减少计算成本的同时保持模型容量
3. **芯片管制的双刃剑**：限制了中国获取先进 GPU，但也催生了替代性的技术创新
4. **TSMC 的不可替代性**：先进制程制造的默会知识是最难复制的竞争壁垒
5. **RLVR 的潜力**：可验证领域的 RL 训练可能是通向更强推理能力的关键路径
6. **开放生态**：开放权重模型在推动创新和防止垄断方面发挥了不可替代的作用
7. **基础设施竞赛**：AI 超级集群正在成为国家级别的基础设施项目

核心洞察

DeepSeek 时刻揭示的最深层信息是：AI 竞争不仅仅是“谁有更多 GPU”的竞赛。工程效率、架构创新、人才密度和组织执行力同样关键。这意味着 AI 领域的竞争格局远比“美国 vs 中国”的简单叙事更加复杂和多元。

13.1 拓展阅读

- DeepSeek 技术报告：<https://arxiv.org/abs/2401.06066>
- SemiAnalysis 博客：<https://semianalysis.com/>
- Nathan Lambert, Interconnects: <https://www.interconnects.ai/>
- Rich Sutton, "The Bitter Lesson" (2019)
- "Attention Is All You Need", Vaswani et al., 2017