

课程笔记

DeepSeek、中国 AI、OpenAI、NVIDIA、 xAI、TSMC 与 AI 超级集群

基于公开课程资料整理

2025



视频作者/频道: Lex Fridman

发布日期: 2025

视频时长: 5h 6m

视频链接: <https://www.youtube.com/watch?v=DeepSeek-China-AI>

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言：DeepSeek 时刻	3
1.1 本章小结	3
2 DeepSeek 技术剖析	3
2.1 Mixture of Experts (MoE) 架构	3
2.2 底层优化：CUDA 层以下	3
2.3 低成本训练的技术栈	4
2.4 本章小结	4
3 The Bitter Lesson 与 Scaling	4
3.1 Rich Sutton 的 Bitter Lesson	4
3.2 DeepSeek 是否违反了 Bitter Lesson?	4
3.3 本章小结	4
4 美国对华芯片出口管制	5
4.1 从 A100 到 H800 到 H20	5
4.2 互连带宽的关键性	5
4.3 DeepSeek 如何适应受限硬件	5
4.4 本章小结	5
5 中美 AI 竞争	6
5.1 人才因素	6
5.2 基础设施与能源	6
5.3 开源/开放权重的地缘意义	6
5.4 本章小结	6
6 TSMC 与半导体制造	6
6.1 TSMC 的不可替代性	6
6.2 本章小结	7
7 Transformer、Attention 与 KV Cache	7
7.1 Attention 机制回顾	7
7.2 KV Cache 的角色	7
7.3 Multi-Head Latent Attention (MLA)	8
7.4 本章小结	8
8 AI 数据中心与超级集群	8
8.1 现代 AI 数据中心的物理形态	8
8.2 Stargate 等超级项目	8
8.3 本章小结	9

9 推理与 RL 的前沿	9
9.1 从 RLHF 到 RLVR	9
9.2 泛化拐点假说	9
9.3 软件工程作为关键测试场	9
9.4 本章小结	10
10 开源/开放权重的生态	10
10.1 DeepSeek 开源的战略意义	10
10.2 AI2 的开源实践	10
10.3 本章小结	10
11 AI 对认知与社会的影响	10
11.1 互联网、社交媒体与认知主权	10
11.2 AI 与自我驯化	11
11.3 本章小结	11
12 AI 产业格局：主要玩家	11
12.1 各公司定位	11
12.2 xAI 的 Colossus 集群	11
12.3 本章小结	12
13 总结与延伸	12
13.1 拓展阅读	12

1 引言: DeepSeek 时刻

2025 年初, DeepSeek 的发布震动了整个 AI 行业。Lex Fridman 借此机会邀请了两位重量级嘉宾——Dylan Patel (SemiAnalysis 创始人) 和 Nathan Lambert (AI2 研究员), 进行了一场 5 小时的深度对话, 覆盖了从 DeepSeek 技术细节到中美 AI 竞争、从 NVIDIA 到 TSMC、从开源模型到 AI 超级集群的全景分析。

嘉宾背景

- **Dylan Patel:** SemiAnalysis 创始人, 专注于半导体、GPU、CPU 和 AI 硬件的研究分析, 被 AI 领域的专家和工程师广泛阅读
- **Nathan Lambert:** Allen Institute for AI (AI2) 研究员, Interconnects 博客作者, 专注于 RLHF、开源模型等方向

1.1 本章小结

DeepSeek 的出现打破了”只有美国顶尖实验室才能训练前沿 LLM”的假设, 引发了关于计算效率、开源策略和地缘政治的广泛讨论。

2 DeepSeek 技术剖析

2.1 Mixture of Experts (MoE) 架构

DeepSeek 实现低成本训练的第一个关键技术是 Mixture of Experts (MoE)。

MoE 的核心机制

MoE 架构将 Transformer 的 FFN 层替换为多个”专家”(expert)子网络。对于每个 token, 只有少数几个专家被激活:

- **总参数量大:** 模型拥有大量参数 (如 671B), 但每个 token 只激活其中一部分 (如 37B)
- **Router:** 一个门控网络决定每个 token 被路由到哪些专家
- **训练效率:** 大模型的表达能力 + 小模型的计算成本
- **推理效率:** 每个 token 的计算量 (FLOPs) 远低于等参数量的 dense model

2.2 底层优化: CUDA 层以下

DeepSeek 的另一个显著特点是其工程团队在极底层进行了优化——在 CUDA 层甚至更低的层级对 NVIDIA GPU 进行定制化编程。

极少数人掌握的技能

Dylan 指出, 能在 CUDA 层以下做高效训练优化的人在全世界非常稀少。这些人需要同时理解 GPU 微架构、内存层次、指令调度和分布式计算。DeepSeek 拥有这样的人才, 美国前沿实验室也有, 但全球范围内这是一个极其稀缺的技能集。

2.3 低成本训练的技术栈

DeepSeek 训练效率的来源

DeepSeek 实现低成本训练的完整技术栈：

1. **MoE 架构**：减少每个 token 的计算量
2. **底层 GPU 优化**：在 CUDA 层以下最大化硬件利用率
3. **多项工程优化**：包括通信优化、内存管理、混合精度训练等
4. **FP8 训练**：使用更低精度的浮点格式来提升吞吐量

这些技术的叠加效果使得 DeepSeek 能用约 2000 颗 H800 GPU 训练出前沿水平的模型。

2.4 本章小结

DeepSeek 的技术创新不在于发明全新的理论，而在于将已知技术（MoE、底层优化、高效训练）极致地组合和工程化实现。

3 The Bitter Lesson 与 Scaling

3.1 Rich Sutton 的 Bitter Lesson

对话深入讨论了 Rich Sutton 的著名文章“The Bitter Lesson”。

Bitter Lesson 的核心观点

Bitter Lesson 的核心论点是：在深度学习中，最终胜出的方法是那些在学习和搜索方面可规模化（scalable）的方法。Nathan 的解读是：应该避免在学习过程中添加人类先验（human priors），让模型通过纯计算来发现规律。历史上，研究者反复尝试用巧妙的手工方案来解决问题，但最终都被更简单、更可扩展的方法击败。

3.2 DeepSeek 是否违反了 Bitter Lesson？

一个有趣的问题是：DeepSeek 的 MoE 和各种工程优化是否违反了 Bitter Lesson？因为这些都是“聪明的”设计选择，而非简单的 scaling。

Bitter Lesson 的细微之处

Bitter Lesson 反对的是添加 domain-specific 的人类先验（如手工特征、规则系统），而非反对通用的系统优化。MoE 是一种通用的架构选择，其核心思想（稀疏激活）适用于各种任务，因此并不违反 Bitter Lesson。真正的问题是：在给定计算预算下，如何最高效地利用这些计算资源——而 DeepSeek 在这方面做到了极致。

3.3 本章小结

Bitter Lesson 仍然是 AI 领域的指导原则，但“可扩展的计算”并不意味着使用更多 GPU，也包括更高效地使用现有 GPU。

4 美国对华芯片出口管制

4.1 从 A100 到 H800 到 H20

对话详细梳理了美国对华芯片出口管制的演变过程及其对 DeepSeek 的影响。

芯片管制时间线

1. **2022 年 10 月**：美国禁止向中国出口 A100 GPU
2. **H800**：NVIDIA 为中国市场推出的“阉割版”，互连带宽被限制（NVLink 降级）
3. **2023 年末**：H800 也被禁止出口
4. **H20**：进一步降规格的版本，计算能力和带宽都大幅缩减

DeepSeek 的约 2000 颗 H800 GPU 是在禁令生效前采购的，之后他们需要在更受限的硬件上继续研究。

4.2 互连带宽的关键性

Dylan 解释了为什么芯片管制特别针对互连带宽：

为什么带宽比算力更重要

大模型训练需要在数千颗 GPU 之间频繁交换数据（梯度同步、all-reduce 操作等）。单颗 GPU 的浮点性能再强，如果 GPU 之间的通信带宽不够，训练效率就会急剧下降。这就是为什么美国的管制重点从限制 FLOPs 转向限制互连带宽——限制一颗 GPU 的能力容易绕过（通过堆数量），但限制 GPU 间的通信直接影响集群的训练能力。

4.3 DeepSeek 如何适应受限硬件

受限硬件下的创新

DeepSeek 团队早在 2022 年 10 月就了解到互连带宽限制，并开始研究如何在带宽受限的条件下高效训练。他们的核心策略：

- 在 CUDA 层以下优化通信模式，最大化利用有限带宽
- 设计适合低带宽环境的并行化策略
- 通过 MoE 减少需要同步的参数量

这种“在约束中创新”反而产生了通用的高效训练技术。

4.4 本章小结

芯片管制迫使 DeepSeek 在受限硬件上寻找效率极致化的方法，某种意义上反而催生了技术创新。但长期来看，计算资源的差距仍然是中美 AI 竞争的重要变量。

5 中美 AI 竞争

5.1 人才因素

Nathan 指出了—个常被忽视的事实：美国顶尖 AI 实验室的很多核心研究人员是没有美国护照的人——其中很大一部分是来自中国的研究者。

人才流动的双面性

中国研究者移居美国为美国 AI 发展做出了巨大贡献，但这也意味着：(1) 中国本土不缺乏 AI 人才储备，(2) 人才政策的变化可能迅速改变竞争格局，(3) 将”人才”视为美国的独有优势是危险的。Nathan 认为，中美 AI 竞争的真正决定性因素不是人才，而是计算资源 (compute)。

5.2 基础设施与能源

Dylan 从硬件和基础设施角度分析了中国的能力：

中国的基础设施优势

- **电力建设**：中国具有快速建设大规模电力基础设施的能力
- **钢铁和水泥**：数据中心建设所需的原材料供应充足
- **制造能力**：大规模建设和部署基础设施的速度远超大多数国家

但中国在先进 GPU 获取上受到限制，这在短期内仍是瓶颈。

5.3 开源/开放权重的地缘意义

Nathan 讨论了 DeepSeek 开放模型权重的战略意义——这与 OpenAI 等公司关于”中国可能利用美国公司的数据训练模型”的叙事形成了有趣的对比。

数据与开源的复杂关系

OpenAI 曾声称有证据表明 DeepSeek 使用了其模型输出来训练。Nathan 的回应很直接：无论如何，OpenAI 的数据已经在互联网上（如 Reddit 上分享 ChatGPT 最佳输出的帖子），这些数据自然会进入任何人的预训练数据集。OpenAI 试图控制这种叙事更多是在保护自己的商业利益，而非真正的知识产权问题。

5.4 本章小结

中美 AI 竞争是多维度的——人才、计算、基础设施、政策。芯片管制是当前最显性的博弈工具，但长期竞争格局取决于更多因素的综合作用。

6 TSMC 与半导体制造

6.1 TSMC 的不可替代性

Dylan 深入解释了为什么 TSMC 是全球半导体供应链中最关键的单一节点。

TSMC 的技术护城河

TSMC 的先进制程制造涉及极其专业化的知识和技能：

- 工人像蚁群一样高度专业化——每个人专注于制造流程中的一个微小环节
- 每个任务涉及特定的化学工艺加纳米制造，在一条特定的工具线上持续迭代
- 例如：一个人可能终其职业生涯只做一种特定的等离子蚀刻（plasma etching），用于去除二氧化硅
- 这种极度专业化的知识是”进了 Fab 就知道该怎么修”的默会知识（tacit knowledge）

TSMC 的地缘风险

TSMC 的核心产能集中在台湾，这使其成为地缘政治中的关键变量。虽然 TSMC 在美国和日本建设新的 Fab，但先进制程的量产能力在短期内仍集中在台湾。这意味着任何影响台湾的地缘事件都可能直接冲击全球 AI 硬件供应链。

6.2 本章小结

TSMC 的竞争优势来自于数十年积累的默会知识和极度专业化的人才，这是最难被复制的。但其地理集中度也是全球供应链最大的风险点之一。

7 Transformer、Attention 与 KV Cache

7.1 Attention 机制回顾

Nathan 在 Dylan 的引导下解释了 Transformer 中 attention 机制的工作原理：

Attention 的计算本质

Attention 机制使模型能够理解上下文中所有 token 之间的关系。这个计算与模型参数本身是分离的：

- **参数**：存储在 FFN 层的权重中，代表模型的”知识”
- **Attention**：计算 token 之间的关系，是一个动态的、依赖输入的计算
- 计算复杂度为 $O(n^2 \cdot d)$ ，其中 n 是序列长度， d 是 embedding 维度

7.2 KV Cache 的角色

在推理（inference）过程中，KV Cache 是一个关键的优化：

KV Cache 解释

在 autoregressive 生成中, 每生成一个新 token, 都需要计算它与之前所有 token 的 attention。如果不缓存, 就需要重新计算所有之前 token 的 Key 和 Value 向量。KV Cache 将之前计算过的 K、V 向量存储起来, 使得每步生成只需要计算新 token 的 Q、K、V 并与缓存做 attention。代价是: KV Cache 的内存占用随序列长度线性增长, 对于长上下文推理 (如 128K+ tokens), KV Cache 可能成为 GPU 内存的主要瓶颈。

7.3 Multi-Head Latent Attention (MLA)

DeepSeek 在 attention 机制上的一个创新是 Multi-Head Latent Attention (MLA), 它通过压缩 KV 的表示来减少 KV Cache 的内存占用。

MLA 的设计思路

传统 Multi-Head Attention (MHA) 为每个 head 独立存储完整的 K 和 V 向量。MLA 的核心思想是: 将多个 head 的 KV 信息压缩到一个低维的 latent 空间中, 推理时再解压。这大幅减少了 KV Cache 的内存占用, 使得在相同硬件上能处理更长的上下文。这个设计与 DeepSeek 面临的硬件约束高度一致——在有限的 GPU 内存中, 更高效地利用每一个字节。

7.4 本章小结

Transformer 的 attention 机制是 LLM 的核心, KV Cache 是推理效率的关键优化。DeepSeek 的 MLA 创新展示了在硬件约束下如何通过架构创新来突破瓶颈。

8 AI 数据中心与超级集群

8.1 现代 AI 数据中心的物理形态

Dylan 介绍了现代 AI 数据中心的物理架构, 它们与传统数据中心有着本质的不同。

AI 数据中心的构成

- **核心计算区:** 存放 GPU 机架的区域, 物理面积相对较小
- **冷却系统:** 水冷管道和冷却塔, 占地面积可能超过计算区本身
- **备用电源:** 大量柴油发电机组作为备用电力
- **关键观察:** 实际的芯片计算区域比水冷系统小得多——散热比计算本身更占空间

8.2 Stargate 等超级项目

对话提到了以 Stargate 为代表的 AI 超级集群项目——这些项目规模达到 GW 级功率, 投资额度数百亿到数千亿美元。

超级集群的风险

如此大规模的基础设施投资面临多重风险：

- **技术迭代风险**：当数据中心建成时，GPU 可能已经换代
- **能源约束**：GW 级电力供应在很多地区需要数年来建设
- **投资回报不确定**：AI 模型的商业价值能否支撑如此巨大的基础设施投入
- **地缘政治风险**：跨国供应链中的任何一环断裂都可能影响项目进度

8.3 本章小结

AI 数据中心已经从 IT 设施演变为类似于发电站的大型工业系统。散热和电力供应正在成为比计算本身更具挑战性的工程问题。

9 推理与 RL 的前沿

9.1 从 RLHF 到 RLVR

Nathan 详细解释了强化学习在 LLM 训练中的演进。

RL 训练的演进路径

1. **RLHF**：使用人类偏好训练 reward model，再用 RL 优化 LLM
2. **RLVR**：直接使用可验证的正确性信号（如代码执行结果、数学证明验证器）作为 reward
3. **多领域 RL**：在越来越多的可验证领域训练，探索泛化边界

9.2 泛化拐点假说

Nathan 提出了一个令人兴奋的假说：在 instruction tuning 的文献中，当训练的任务类型数量超过某个阈值时，模型突然能泛化到从未见过的任务类型。类似的现象可能也存在于 RLVR 中。

泛化拐点的含义

如果 RLVR 也存在泛化拐点，那么当你在足够多的可验证领域（数学、代码、逻辑推理、科学计算等）上训练后，模型可能“突然”也能在不可验证的领域（如战略分析、创意写作）展现出更强的推理能力。这将是 AI 能力的一个质的飞跃。但目前我们不知道这个拐点是否存在，以及在哪里。

9.3 软件工程作为关键测试场

对话提到软件工程是当前 AI 推理能力最重要的测试场之一。代码具有天然的可验证性（能否编译、能否通过测试），同时又需要复杂的推理和规划能力。

9.4 本章小结

RLVR 正在快速推动 AI 推理能力的提升，泛化拐点假说如果成立将是 AI 能力的重大突破。软件工程是验证这些进展的最佳领域之一。

10 开源/开放权重的生态

10.1 DeepSeek 开源的战略意义

DeepSeek 选择开放模型权重，这在地缘政治的语境下具有多重含义。

开放权重 vs 开源

需要区分“开放权重”（open weights）和“开源”（open source）：

- **开放权重**：公开模型参数，允许推理和微调，但不公开训练数据和完整训练流程
- **完全开源**：公开所有训练代码、数据、配置，允许完全复现
- DeepSeek 属于开放权重，这已经足以让社区在其基础上构建

10.2 AI2 的开源实践

Nathan 来自 AI2，这是一个致力于开放 AI 研究的机构。他们不仅开放模型权重，还尝试开放更多的训练细节。

AI2 的立场

AI2 认为开放 AI 研究对于以下目标至关重要：

- 推动科学进步：可复现的研究才是好的研究
- 防止垄断：确保 AI 能力不被少数公司独占
- 安全研究：只有理解模型才能有效地研究安全性

10.3 本章小结

开源/开放权重是 AI 生态的重要组成部分。DeepSeek 的开放策略展示了即使在地缘政治紧张背景下，技术开放也可以是一种有效的竞争策略。

11 AI 对认知与社会的影响

11.1 互联网、社交媒体与认知主权

对话中有一段引人深思的讨论：Lex 分享了他关于断开互联网连接时的体验。他观察到，当他进行几天的户外活动（如背包旅行）并完全断开互联网后，大约在第三天会感到一种认知上的“重置”——打破成瘾周期，重新获得对自己思维的控制。

认知主权的挑战

Lex 提出了一个深刻的观察：

- 使用互联网和社交媒体越多，你的思维就越受他人控制
- 断开连接后，你能感到一种“智力主权”（sovereignty of intelligence）的回归
- AI 的广泛使用可能进一步加剧这种现象——如果我们依赖 AI 做决策，我们是否在放弃认知自主权？

这不仅是个人问题，也是社会层面的问题。

11.2 AI 与自我驯化

对话触及了一个跨学科的话题：人类的“自我驯化”（self-domestication）假说。Lex 用 AI 工具探索了这个概念——人类不仅仅是社会动物，更是深度自我驯化的猿类（self-domesticated apes），这种自我驯化是理解我们独特认知和社会能力的关键。

11.3 本章小结

AI 技术的影响远不止于技术和商业层面。它正在深刻地改变人类的认知模式和社会互动方式，这些影响值得更多的关注和反思。

12 AI 产业格局：主要玩家

12.1 各公司定位

对话覆盖了 AI 产业的主要参与者：

AI 产业主要玩家

- **OpenAI**：闭源前沿模型，最大的商业化 AI 公司
- **Google DeepMind**：Gemini 系列，拥有独特的 TPU 硬件优势
- **Anthropic**：Claude 系列，注重安全和对齐
- **Meta**：Llama 开放权重系列，推动开放 AI 生态
- **xAI**：Elon Musk 的 AI 公司，Grok 系列
- **DeepSeek**：中国最具影响力的开放 AI 公司
- **NVIDIA**：AI 硬件和软件栈的基础设施提供商
- **TSMC**：所有先进 AI 芯片的制造商

12.2 xAI 的 Colossus 集群

Dylan 提到了 xAI 的 Colossus 超级集群——这是当时世界上最大的 AI 训练集群之一，展示了 Elon Musk 在基础设施建设上的激进策略。

12.3 本章小结

AI 产业格局正在快速演变，竞争不仅发生在模型层面，还发生在基础设施、生态系统和战略定位等多个维度。

13 总结与延伸

这场 5 小时的深度对话提供了 AI 领域最全面的快照之一。核心要点包括：

1. **DeepSeek 的启示**：计算效率的极致优化可以部分弥补原始计算资源的不足
2. **MoE 架构**：成为大模型训练的重要范式，减少计算成本的同时保持模型容量
3. **芯片管制的双刃剑**：限制了中国获取先进 GPU，但也催生了替代性的技术创新
4. **TSMC 的不可替代性**：先进制程制造的默会知识是最难复制的竞争壁垒
5. **RLVR 的潜力**：可验证领域的 RL 训练可能是通向更强推理能力的关键路径
6. **开放生态**：开放权重模型在推动创新和防止垄断方面发挥了不可替代的作用
7. **基础设施竞赛**：AI 超级集群正在成为国家级别的基础设施项目

核心洞察

DeepSeek 时刻揭示的最深层信息是：AI 竞争不仅仅是“谁有更多 GPU”的竞赛。工程效率、架构创新、人才密度和组织执行力同样关键。这意味着 AI 领域的竞争格局远比“美国 vs 中国”的简单叙事更加复杂和多元。

13.1 拓展阅读

- DeepSeek 技术报告: <https://arxiv.org/abs/2401.06066>
- SemiAnalysis 博客: <https://semianalysis.com/>
- Nathan Lambert, Interconnects: <https://www.interconnects.ai/>
- Rich Sutton, "The Bitter Lesson" (2019)
- "Attention Is All You Need", Vaswani et al., 2017