

课程笔记

Jensen Huang: NVIDIA ——四万亿美元公 司与 AI 革命

基于公开课程资料整理

2025



视频作者/频道: Lex Fridman Podcast

发布日期: 2025

视频时长: 2h 25m

视频链接: <https://www.youtube.com/watch?v=Jensen-Huang-NVIDIA>

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言：NVIDIA 与 AI 革命	2
1.1 本章小结	2
2 CUDA：从赌注到护城河	2
2.1 CUDA 的诞生	2
2.2 将 CUDA 放上 GeForce 的艰难决策	2
2.3 CUDA 生态的飞轮效应	2
2.4 本章小结	3
3 Rack Scale 设计与 NVLink	3
3.1 从芯片到机架	3
3.2 供应链中的超级计算机制造	3
3.3 复杂性管理哲学	4
3.4 本章小结	4
4 AI 基础设施：能源、供应链与规模	4
4.1 AI 工厂的崛起	4
4.2 NVIDIA 的商业天花板	4
4.3 本章小结	5
5 领导力与管理哲学	5
5.1 信息透明与全员对齐	5
5.2 倾听行业的低语	5
5.3 公开犯错与谦逊	5
5.4 本章小结	5
6 AI 作为个人工具	6
6.1 消除初学者摩擦	6
6.2 本章小结	6
7 竞争格局与未来展望	6
7.1 NVIDIA 的竞争优势	6
7.2 AI 基础设施投资的可持续性	6
7.3 本章小结	6
8 总结与延伸	7
8.1 拓展阅读	7

1 引言：NVIDIA 与 AI 革命

Jensen Huang 是 NVIDIA 的创始人兼 CEO，他将 NVIDIA 从一家图形芯片公司推动成为 AI 革命的核心引擎。在本次 Lex Fridman 播客中，Jensen 深入讨论了 NVIDIA 的技术战略、从 chip scale 到 rack scale 的设计演进、CUDA 生态系统的构建、AI 基础设施的未来、以及他的领导力哲学。

NVIDIA 的核心转型

NVIDIA 已经从”制造最好的 GPU”转型为端到端 AI 基础设施公司。赢得竞争不再仅靠单芯片性能，而是通过 GPU、CPU、内存、网络、存储和供电系统的极致协同设计 (co-design) 来实现。

1.1 本章小结

NVIDIA 的成功不仅在于其硬件能力，更在于 Jensen Huang 将公司从一个单一产品公司重新定义为 AI 时代的全栈计算平台公司。

2 CUDA：从赌注到护城河

2.1 CUDA 的诞生

在 GPU 计算的早期，Jensen 注意到科学家们在 GPU 上使用图形 API 进行通用计算 (GPGPU)。他们把浮点运算包装成”像素”来利用 GPU 的并行能力。这启发了 NVIDIA 创建一个真正的通用计算平台。

从 CG 到 CUDA

早期的 GPU 计算经历了一个渐进过程：科学家们首先在 GPU 上通过 CG (C for Graphics) 编程路径来执行 FP32 运算，NVIDIA 在此基础上逐步发展出了 CUDA (Compute Unified Device Architecture)，将 GPU 变成了真正的通用并行计算设备。

2.2 将 CUDA 放上 GeForce 的艰难决策

将 CUDA 架构扩展到消费级 GeForce 显卡是一个代价巨大的战略决策。这意味着每一颗消费级 GPU 都需要承载额外的计算逻辑面积，直接侵蚀了公司的利润。

不可忽视的战略成本

Jensen 明确指出，当时 NVIDIA 负担不起将 CUDA 放上 GeForce 的成本，但他坚持执行。原因是：一家计算公司必须拥有统一的计算架构，而这个架构必须在所有芯片上保持兼容。这是一个典型的”短期亏损换长期护城河”的战略决策。

2.3 CUDA 生态的飞轮效应

NVIDIA 最重要的资产不是某一代 GPU 的性能领先，而是 CUDA 的 installed base (安装基础)。Jensen 强调，即使有人创造出”GUDA”或”TUDA”，也无法撼动 NVIDIA 的地位，因为 CUDA

的价值不仅仅在于技术本身。

CUDA 护城河的本质

CUDA 的真正护城河包含三个维度：

1. **开发者生态**：数百万开发者掌握 CUDA 编程
2. **软件栈深度**：从底层驱动到 cuDNN、TensorRT 等上层库的完整工具链
3. **持续演进**：CUDA 已经迭代到 13.2，持续与时俱进

CUDA 的灵活性使其既能做极致加速（specialization），又能适应不断变化的算法（generalization），这种平衡是其韧性的来源。

2.4 本章小结

CUDA 的故事揭示了一个核心商业逻辑：在平台级竞争中，生态系统的网络效应远比单一技术指标重要。NVIDIA 通过在消费级 GPU 上统一 CUDA 架构、持续投入开发者工具和库，构建了一个几乎不可替代的计算平台。

3 Rack Scale 设计与 NVLink

3.1 从芯片到机架

NVIDIA 的竞争范围已经从设计单颗 GPU 扩展到了整个机架（rack）的协同设计。NVLink 72 是这一战略的集中体现——它将 72 颗 GPU 紧密互连在一个机架中，构成一台超级计算机。

NVLink 72 的规模

单个 NVLink 72 机架包含：

- 约 130 万个组件
- 1300 颗芯片
- 重达 4000 磅（约 1.8 吨）
- 压缩在标准 19 英寸宽的机架中
- 提供 PB/s 级别的内部互连带宽

3.2 供应链中的超级计算机制造

Jensen 描述了一个重要的范式转变：过去，超级计算机是在数据中心内组装的——零部件运到现场再拼装。而 NVLink 72 的密度使这种方式不再可行。

制造模式的变革

NVLink 72 机架如此之密集，以至于必须在供应链中就完成超级计算机的组装和测试，然后整体运输到数据中心。NVIDIA 每周可以产出约 200 个这样的 pod。这意味着供应链本身需要具备巨大的电力和测试能力——每周需要 GW 级别的功率来制造和测试。

3.3 复杂性管理哲学

面对如此复杂的系统，Jensen 的原则是：“As complex as necessary, but as simple as possible”（尽可能复杂到必要程度，但尽可能简单）。所有复杂性都必须是必要的，团队需要不断审视和挑战每一层复杂性。

3.4 本章小结

从 chip scale 到 rack scale 的演进反映了 AI 计算需求的爆炸式增长。NVIDIA 的竞争力不仅在于芯片设计，还在于系统级集成能力和对供应链的深度掌控。

4 AI 基础设施：能源、供应链与规模

4.1 AI 工厂的崛起

Jensen 提出了一个重要概念：数据中心正在从“信息存储和检索”转变为“AI 工厂”——它们的核心功能是生产智能（intelligence）。

AI 基础设施的规模

Jensen 描述了 AI 基础设施建设的惊人规模：

- 50 GW 级别的超级计算机同时运行
- 供应链每周需要制造相当于 1 GW 功率的超级计算机
- 200 家供应链合作伙伴共同承担制造负担
- Jensen 亲自飞往供应链与合作伙伴协调产能

4.2 NVIDIA 的商业天花板

在被问及 NVIDIA 能否成为年收入 3 万亿美元的公司时，Jensen 给出了肯定的回答。他认为没有物理上的限制阻碍这一目标，因为：

- AI 计算需求仍在指数增长
- 供应链负担由 200 多家公司共同分担，可以扩展
- 能源供给最终是可以解决的

规模扩张的真正瓶颈

尽管 Jensen 对收入增长持乐观态度，但他也承认能源是当前最大的约束因素。GW 级数据中心的电力需求正在挑战全球能源基础设施，这不仅是技术问题，更是政治和社会问题。

4.3 本章小结

AI 基础设施的规模已经超出了传统 IT 行业的范畴，正在成为一个涉及能源、制造、供应链管理的超大型工业体系。NVIDIA 在其中扮演的角色越来越像一个“AI 时代的台积电”。

5 领导力与管理哲学

5.1 信息透明与全员对齐

Jensen 的管理风格以极致的信息透明著称。他几乎会与公司内所有层级分享战略信息，通过持续的沟通来塑造团队的信念系统。

Jensen 的领导力方法论

Jensen 描述了他的决策宣布策略：在正式宣布重大决策之前，他已经通过长时间的沟通让公司上下理解了背景和逻辑。当决策最终宣布时，员工的反应不是震惊，而是“Jensen 终于宣布了”。这看起来像是“从后方领导”，但实际上是通过提前塑造共识来确保 100% 的 buy-in。

5.2 倾听行业的低语

Jensen 强调了“listening to the whispers”（倾听低语）的重要性——在行业趋势尚未明朗之前，从各方面收集微弱信号。从学术界的论文、客户的反馈、合作伙伴的动向中捕捉变化的早期迹象。

关键领导力原则

- **信息对称**：让所有人了解战略背景，而不仅仅是执行指令
- **前瞻性共识**：在决策之前塑造团队认知，而不是事后解释
- **微弱信号捕捉**：从行业“低语”中判断技术方向
- **灵活架构**：保持 CUDA 等核心架构的灵活性，以便“随风而动”

5.3 公开犯错与谦逊

在被问及财富和权力是否影响了他保持谦逊的能力时，Jensen 给出了一个出人意料的回答：由于他的大量工作是公开进行的，当他犯错时几乎所有人都能看到，这反而让他持续保持谦逊。

5.4 本章小结

Jensen 的领导力哲学可以概括为：通过信息透明构建共识，通过倾听微弱信号保持前瞻，通过公开犯错保持谦逊。这种风格在一定程度上解释了 NVIDIA 为何能在技术路线上屡次做出正确的赌注。

6 AI 作为个人工具

6.1 消除初学者摩擦

Jensen 分享了他个人使用 AI 的体验。他认为 AI 最大的价值之一是消除了”成为初学者”的摩擦。无论面对什么新领域——学习 Excel、规划旅行、了解一种新技术——AI 都能提供即时的引导。

AI 降低学习门槛

Jensen 用了一个生动的例子：过去你不会用 Excel，你就完了。而现在，你可以向 AI 询问”我需要迈出的第一步是什么？”，AI 提供的这种 handholding（手把手引导）消除了所有体验的初始摩擦。这适用于生活的各个方面——从编程到旅行规划。

6.2 本章小结

AI 正在将过去需要专门学习才能使用的工具和知识民主化。Jensen 认为这是 AI 对人类日常生活最直接的影响之一。

7 竞争格局与未来展望

7.1 NVIDIA 的竞争优势

当被问及 NVIDIA 最大的”护城河”时，Jensen 明确指出了 CUDA 的 installed base。这不是某个单一技术特性，而是一个自我强化的生态系统：

- 开发者投入时间学习 CUDA → 更多软件基于 CUDA 开发
- 更多 CUDA 软件 → 更多用户选择 NVIDIA GPU
- 更多用户 → 更多开发者投入

竞争对手的困境

即使竞争对手在某些硬件指标上超越 NVIDIA，也很难打破 CUDA 生态系统的飞轮。这类似于 x86 在 CPU 领域的地位——技术上有更好的选择（如 ARM），但生态系统的惯性是巨大的。但这并不意味着 NVIDIA 可以松懈——持续创新是维持这个飞轮的前提。

7.2 AI 基础设施投资的可持续性

Jensen 对 AI 基础设施投资的持续增长持乐观态度。他认为关键问题不是”是否有需求”，而是”是否有足够的能源”。AI 计算需求的增长远超当前基础设施的扩展速度，这个缺口就是 NVIDIA 的增长空间。

7.3 本章小结

NVIDIA 的竞争优势来源于一个多层面的飞轮效应：CUDA 生态、系统级设计能力、供应链掌控力、以及持续的技术迭代。但能源供给和地缘政治仍是潜在的风险因素。

8 总结与延伸

本次对话揭示了 Jensen Huang 和 NVIDIA 成功的多个关键维度：

1. **技术远见**：在 CUDA 上的早期投入，在 AI 浪潮到来前就建好了平台
2. **系统思维**：从芯片设计扩展到 rack scale，再到整个 AI 基础设施生态
3. **战略魄力**：在公司负担不起的时候做出正确但昂贵的决策
4. **领导力**：通过信息透明和前瞻性共识驱动大规模组织
5. **规模运营**：管理 200+ 供应链合作伙伴，每周产出数百台超级计算机

核心洞察

Jensen Huang 的故事本质上是关于“平台思维”的胜利。NVIDIA 的护城河不是某一代 GPU 的性能指标，而是一个自我强化的计算生态系统。在 AI 时代，控制计算平台（hardware + software + ecosystem）可能比控制任何单一 AI 模型更有价值。

8.1 拓展阅读

- NVIDIA CUDA 官方文档：<https://docs.nvidia.com/cuda/>
- NVLink 与 NVSwitch 技术白皮书：<https://www.nvidia.com/en-us/data-center/nvlink/>
- Jensen Huang GTC Keynote 历年演讲
- Lex Fridman Podcast 原始视频