

访谈笔记

Jensen Huang 的未来愿景：从 GPU 到 AI 革命

基于公开课程资料整理

2025



视频作者/频道: Cleo Abram

嘉宾: Jensen Huang (NVIDIA CEO)

视频时长: 1h 3m

项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 从游戏 GPU 到通用并行计算	2
1.1 CUDA 的诞生	2
1.2 本章小结	2
2 AlexNet 时刻：深度学习的大爆发	2
2.1 本章小结	3
3 Scaling Laws 与深度学习的可扩展性	3
3.1 跨模态的统一框架	3
3.2 本章小结	4
4 Physical AI：从数字世界到物理世界	4
4.1 World Foundation Model	4
4.2 Omniverse 与虚拟训练	4
4.3 本章小结	5
5 AI Safety：工程问题而非哲学问题	5
5.1 本章小结	5
6 能效革命与计算的物理极限	5
6.1 本章小结	6
7 Transformer 不是终点	6
7.1 本章小结	6
8 AI 时代的个人建议	7
8.1 本章小结	7
9 总结与延伸	7
9.1 拓展阅读	8

1 从游戏 GPU 到通用并行计算

Jensen Huang 回顾了 NVIDIA 的起源故事。NVIDIA 最初是一家为电子游戏打造图形处理器 (GPU) 的公司，但 GPU 的并行计算架构具有远超游戏的潜力。

并行计算的本质

CPU 擅长**串行处理**——按步骤依次执行指令，适合逻辑复杂但数据量小的任务。GPU 擅长**并行处理**——同时处理大量简单运算，适合数据密集型任务。游戏渲染需要同时计算数百万个像素的颜色，天然就是并行问题。

早在 2000 年代初期，一些研究者发现可以“欺骗”GPU，让它认为科学计算问题是图形问题，从而利用 GPU 的并行能力加速模拟。例如，Massachusetts General Hospital 的研究者使用 GPU 进行 CT 重建。

1.1 CUDA 的诞生

Jensen 意识到，需要让 GPU 的并行计算能力对所有程序员开放，而不仅仅是图形程序员。于是 NVIDIA 创建了 **CUDA**——一个让程序员用 C 等通用编程语言为 GPU 编程的平台。

CUDA 的战略逻辑

Jensen 解释 CUDA 背后的推理：

1. GPU 是世界上产量最大的并行处理器（因为游戏市场巨大）
2. 高产量意味着低成本和广泛可及性
3. 如果让更多人使用这种计算能力，他们可能创造出令人难以置信的东西
4. “如果你不建造它，他们就无法来”——这是一个基于“理性希望”的战略

1.2 本章小结

NVIDIA 的核心战略洞察是：游戏市场提供了并行计算硬件的规模化基础，CUDA 提供了通用编程接口，两者结合让并行计算从游戏领域扩展到了整个科学计算和 AI 领域。

2 AlexNet 时刻：深度学习的大爆发

2012 年，Toronto 大学的 Ilya Sutskever、Alex Krizhevsky 和 Geoffrey Hinton 提交了 AlexNet 参加 ImageNet 竞赛，使用两块 GeForce GTX 580 GPU 训练深度神经网络，以压倒性优势击败了所有竞争对手。

计算范式的根本转变

AlexNet 标志着从**指令式编程**到**学习式编程**的根本转变：

- 传统方法：人类编写步骤，告诉计算机如何做
- 新方法：给计算机大量示例数据，让它自己学习如何做

这不仅仅是一个算法改进，而是整个计算范式的革命。

Jensen 描述了 NVIDIA 内部看到 AlexNet 时的反应：一方面是出于兴趣，另一方面是因为 NVIDIA 自己在计算机视觉方面的努力遇到了瓶颈。AlexNet 用一种全新的方法取得了巨大突破，这让 NVIDIA 意识到深度学习可能是计算行业的下一次革命。

NVIDIA 的关键判断

看到 AlexNet 后，NVIDIA 问了自己一个关键问题：“如果深度学习架构可以 scale，那么大多数机器学习问题都可以用深度神经网络来表示。它能解决的问题范围如此之广，有潜力**重塑整个计算机行业**。”这一判断促使 NVIDIA 重新设计了整个计算栈，催生了 DGX 系列 AI 超级计算机。

2.1 本章小结

AlexNet 不仅是一个技术突破，更是一个战略信号。NVIDIA 正确地识别出深度学习的可扩展性意味着整个计算行业需要重新定义，并迅速转型为 AI 基础设施公司。

3 Scaling Laws 与深度学习的可扩展性

Jensen 在访谈中反复强调了深度学习架构的**可扩展性**——模型越大、数据越多，学到的知识就越丰富。

Scaling 的三个维度

深度学习的 scaling 在三个维度上被验证为经验性真理：

1. **模型大小**：更大的模型（更深或更宽）可以学习更复杂的特征
2. **数据大小**：更多的数据让模型学到更丰富的知识
3. **计算量**：更多的计算资源支持更大的模型和更多的数据

Jensen 指出：“没有找到物理极限、架构极限或数学极限”来阻止这种 scaling。

这一判断是 NVIDIA 所有战略决策的基石。如果 scaling 有上限，那么 GPU 的需求将趋于饱和；但如果 scaling 没有上限，那么对算力的需求将持续指数增长。

3.1 跨模态的统一框架

Jensen 描绘了深度学习的另一个关键能力：**跨模态翻译**。

万物皆可翻译

深度学习可以学习任何模态的数据，并在模态之间翻译：

- 文本 → 文本：摘要、翻译
- 文本 → 图像：图像生成
- 图像 → 文本：图像描述
- 氨基酸序列 → 蛋白质结构：AlphaFold
- 蛋白质 → 文本：药物靶点识别
- 文本 → 动作 token：机器人控制

从计算机的角度看，所有这些任务的本质都是相同的——学习输入与输出之间的映射。

3.2 本章小结

Scaling laws 是当前 AI 繁荣的理论基础。深度学习的通用性和可扩展性意味着算力投资的回报曲线没有明显的拐点，这支撑了 NVIDIA 对 AI 基础设施的持续大规模投入。

4 Physical AI：从数字世界到物理世界

Jensen 用大量篇幅讨论了 **Physical AI**——让 AI 理解和操作物理世界的技术。他用 ChatGPT 的发展轨迹来类比机器人学的未来。

4.1 World Foundation Model

从语言模型到世界模型

类比关系：

- ChatGPT = 语言 Foundation Model（理解文字的常识）
- **Cosmos** = 世界 Foundation Model（理解物理世界的常识）

世界模型需要理解：重力、摩擦力、惯性、空间几何、物体永久性 (object permanence)、因果关系等“物理常识”。

4.2 Omniverse 与虚拟训练

传统机器人训练面临数据瓶颈：在真实世界中训练成本高、速度慢、风险大。NVIDIA 的解决方案是 **Omniverse**——用于创建高保真 3D 虚拟世界的平台，让机器人在虚拟环境中以远超现实的速度训练。

虚拟训练的优势

在虚拟世界中训练机器人的好处：

- 每天可以进行远超现实世界的训练次数
- 可以模拟极端条件（不同光照、天气、时间）
- 机器人不会在训练中损坏或磨损
- **Cosmos** 生成更逼真的虚拟场景，进一步提升训练数据的质量和多样性

Jensen 认为我们正处于机器人学的“Big Bang 时刻”。

4.3 本章小结

Physical AI 的核心思路是：语言模型需要语言常识，机器人需要物理常识。Cosmos 提供物理常识的 foundation model，Omniverse 提供虚拟训练环境，两者共同构成了机器人学的“ChatGPT 时刻”的基础设施。

5 AI Safety：工程问题而非哲学问题

与 Dario Amodei 偏哲学化的 AI safety 讨论不同，Jensen 将 AI safety 定位为一个**工程问题**。

AI Safety 的三个层次

Jensen 将 AI 安全分解为三个层次：

1. **功能安全**：AI 想做正确的事，但执行不到位（如自动驾驶传感器故障）——需要深入的工程和测试
2. **系统安全**：AI 运行正常但系统故障（如硬件在关键时刻坏掉）——需要冗余设计（如飞机的三重备份计算机）
3. **恶意使用**：deepfake、虚假信息、身份冒充——需要法规和技术对策

AI 的“有意为善”与“执行不力”

Jensen 特别强调了一个容易被忽视的安全问题：AI 系统的**意图是好的**，但由于工程缺陷而造成伤害。这与传统安全工程（航空、医疗）面临的问题本质相同，需要的是严格的工程实践、冗余设计和持续测试，而不是全新的哲学框架。

5.1 本章小结

Jensen 的 AI safety 观带有鲜明的工程师色彩：将问题分解为可操作的子问题，用成熟的安全工程方法论（冗余、测试、监控）来逐一解决。

6 能效革命与计算的物理极限

当被问到当前计算的技术限制时，Jensen 给出了一个简洁的答案：**能源**。

Jensen 带了一台 DGX 原型机来展示。2016 年交付给 OpenAI 的第一台 DGX-1 售价 \$250,000，消耗的能源是当前版本的 10,000 倍，而当前版本的性能还要高 6 倍。也就是说，8 年间 AI 计算的**能效提升了 10,000 倍**。

Jensen 用了一个生动的类比：如果电灯泡的能效也提升 10,000 倍，一个 100 瓦的灯泡在产生同样照明的情况下只需要 0.01 瓦。

Jensen 强调，并行计算与串行计算在物理层面上有不同的改进空间。CPU 的提升受到时钟频率和制程的限制（摩尔定律的放缓），而 GPU 的并行架构可以通过增加计算单元、优化内存带宽和改进互联来持续改进。

6.1 本章小结

能效是 AI 计算的终极约束，但 NVIDIA 在过去 8 年中实现了 10,000 倍的能效提升，证明并行计算架构仍有巨大的改进空间。

7 Transformer 不是终点

Cleo Abram 提出了一个尖锐的问题：NVIDIA 是否应该为 Transformer 这一特定架构设计专用芯片？Jensen 的回答揭示了 NVIDIA 的核心哲学。

通用性 vs. 专用性

Jensen 将问题归结为一个核心信念的选择：

- 选项 A：Transformer 是 AI 研究者将发现的**最后一个架构**
- 选项 B：Transformer 是通向未来架构的**跳板**，未来的架构可能“几乎无法被识别为 Transformer”

NVIDIA 选择了 B。理由很简单：回顾计算机科学和工程的历史，**没有任何一个想法能永远保持不变**。因此 NVIDIA 要创建一个让发明家、创新者和研究者能够“在汤里游泳并想出惊人想法”的通用平台。

专用化的风险

如果 10 年前你为某种特定任务将 GPU 变成了“微波炉”（只能做一件事），那么当新的应用出现时，你的硬件就毫无用处了。通用计算的本质美妙之处在于，它今天能做 10 年前没人能想象到的事情。

7.1 本章小结

NVIDIA 的竞争优势不仅仅是硬件性能，更是其“通用平台”的哲学。通过保持架构的灵活性和可编程性，NVIDIA 确保了无论 AI 算法如何演进，其硬件都能受益。

8 AI 时代的个人建议

在访谈的尾声，Jensen 分享了他对个人如何应对 AI 时代的建议。

Jensen 的建议：用 AI 让自己更强

Jensen 用自己的经历类比：他被数千名在各自领域都是世界顶尖的超级人才包围，但这从未让他觉得自己不再被需要——相反，它赋予了他信心去挑战更大的目标。

他的核心建议：

1. **立刻获取一个 AI tutor**——用它学习任何你想学的东西
2. **持续问自己**：“我如何用 AI 把我的工作做得更好？”
3. 这个问题应该**贯穿所有职业**：律师、医生、化学家、生物学家...
4. 就像上一代人必须学会“如何用计算机做好自己的工作”，这一代人必须学会“如何用 AI 做好自己的工作”

“超级人类”的比喻

“我们将变成超级人类——不是因为我们拥有超能力，而是因为我们拥有**超级 AI**。”

Jensen 还指出了有趣的对比：如果把一台电脑放在从未用过电脑的人面前，他绝对不可能在一天内学会使用。但如果把 ChatGPT 放在一个人面前，他只需要输入“我不知道如何使用 ChatGPT，告诉我”，AI 就会教他。智能本身降低了使用智能的门槛。

8.1 本章小结

Jensen 的未来观是乐观的：AI 不会取代人类，而是赋能人类。关键是主动拥抱这一工具，而不是被动等待。

9 总结与延伸

这场一小时的深度对话展现了 Jensen Huang 作为技术领袖的远见：从 GPU 游戏市场的规模化优势，到 CUDA 的开放平台战略，到 AlexNet 催化的全栈重构，再到 Physical AI 和 World Foundation Model 的前沿布局。

核心观点总结

1. **平台思维**: NVIDIA 的核心竞争力是通用并行计算平台, 而非特定应用
2. **Scaling 信念**: 深度学习的可扩展性没有已知上限, 这支撑了持续投入
3. **Physical AI**: World Foundation Model (Cosmos) + 虚拟训练 (Omniverse) = 机器人学的 ChatGPT 时刻
4. **能效优先**: 10,000 倍能效提升证明并行计算仍有巨大空间
5. **通用性哲学**: 不为特定架构优化, 保持对未来创新的开放性
6. **AI 赋能**: 每个人都应该问 “如何用 AI 把我的工作做得更好”

9.1 拓展阅读

- NVIDIA, *CUDA Programming Guide* ——CUDA 平台的技术文档
- Krizhevsky et al., *ImageNet Classification with Deep Convolutional Neural Networks* (2012) ——AlexNet 论文
- NVIDIA, *Cosmos: World Foundation Model* ——Cosmos 世界模型的技术说明
- NVIDIA Omniverse ——<https://www.nvidia.com/en-us/omniverse/>
- Cleo Abram YouTube Channel ——本次访谈的完整视频