

课程笔记

青稞 AI 嘉年华：Infra 专题

青稞社区 & AI

2026 年 3 月 29 日

青稞社区

2025“青稞”AI嘉年华

青稞Talk VOL.100 特辑

线上直播

Infra专题

12月28日 周日

10:00-12:00

主持人 万佑逸

Sea AI Lab 联合创始人兼总工程师

新加坡国立大学博士

曹明星

清华大学计算机系副教授

庄博涵

浙江大学研究员

游凯超

LLM Core Maintainer

清华大学博士

朱子霖

智源 AI 院 Infra 工程师

LLM 开源项目作者

朱力耕

NVIDIA 研究员, MIT 博士

张皓

RLHF 作者

Founder of Vibe AI

共创伙伴: CSD 减论平台 | DINOQ.me | Mooncake | 趋猎科技

合作伙伴: WebAgentLab | ModelScope 魔搭社区 | AgentAlpha

视频作者/频道：青稞社区

发布日期：2025

视频时长：约 112 分钟

视频链接：未填写

目录

1	引言	2
2	嘉宾与研究方向	2
2.1	张明星（清华大学副教授）	2
2.2	其他嘉宾	2
3	2025 年 Infra 领域关键进展	2
3.1	PD 分离（Prefill-Decode Disaggregation）	2
3.2	大 EP（Expert Parallelism）	2
3.3	RL Infra	2
3.4	Agent Infra	2
3.5	本章小结	2
4	云端 vs. 边缘端推理	3
4.1	云端推理	3
4.2	边缘端推理	3
4.3	本章小结	3
5	总结与延伸	3

1 引言

本场是青稞 AI 嘉年华的 Infra 专题，聚焦大模型推理和训练基础设施的最新进展。

2 嘉宾与研究方向

2.1 张明星（清华大学副教授）

MoonCake & KTransformers

张明星团队发起了两个重要的开源项目：

- **MoonCake**：云端分布式集群推理优化
- **KTransformers**：边缘端 CPU-GPU 异构推理优化

主要聚焦推理场景，2025 下半年也开始做 RL Infra 和 Agent Infra。

2.2 其他嘉宾

来自学术界和工业界的 Infra 专家分享各自方向的最新进展。

3 2025 年 Infra 领域关键进展

3.1 PD 分离 (Prefill-Decode Disaggregation)

PD 分离

将 Prefill 和 Decode 两个阶段分离到不同的硬件/集群上执行。Prefill 阶段计算密集，适合高算力节点；Decode 阶段内存带宽密集，适合高带宽节点。PD 分离在 2025 年已成为 well-known 的技术。

3.2 大 EP (Expert Parallelism)

MoE 模型的 Expert 并行：将不同 Expert 分配到不同 GPU 上，实现高效的 MoE 推理。

3.3 RL Infra

RL Infra 的核心瓶颈

现在 RL 训练的核心卡点在 rollout (推理) 上，而不是训练本身。高效的推理引擎（如 vLLM、SGLang）是做好 RL Training 的前提。

3.4 Agent Infra

Agent 场景对 Infra 提出新要求：多轮对话、工具调用、异步执行、状态管理等。

3.5 本章小结

PD 分离、大 EP、RL Infra 是 2025 年 Infra 领域的三大关键技术方向。

4 云端 vs. 边缘端推理

4.1 云端推理

大规模集群部署，追求高吞吐量。PD 分离、大 EP 是核心优化手段。

4.2 边缘端推理

本地设备部署，追求低延迟和隐私保护。CPU-GPU 异构计算是关键技术。

4.3 本章小结

云端和边缘端有不同的优化目标和技术路线，但推理优化是共同的核心主题。

5 总结与延伸

1. PD 分离和大 EP 已成为推理优化的标准技术
2. RL Infra 的核心瓶颈在推理 (rollout)
3. Agent 场景对 Infra 提出了新的需求
4. 云端追求吞吐，边缘追求延迟，各有优化路线