

课程笔记

青稞 AI 嘉年华：LLM/MLLM 专题圆桌

主持：陈嘉乐 嘉宾：曹玉、薛福昭、刘子伟、谢天宝

2025



2025“青稞”AI嘉年华
青稞Talk VOL.100 特辑 线上直播

LLM/MLLM专题
12月28日 周日
18:00-19:30

主持人：陈嘉乐
清华大学博士
腾讯AI实验室研究员

刘子伟
南洋理工大学助理教授

薛福昭
Senior Research Scientist
@ Google DeepMind

谢天宝
香港大学博士
创始人兼CEO (OpenAI)

曹玉
大语言模型算法专家

共创伙伴：CD 减论平台 | DINQ.me | Mooncake | 趋近科技
合作伙伴：WebAgentLab | StodelScape | agentAlpha

视频作者/频道：青稞社区

发布日期：2025

视频时长：约 99 分钟

项目主页：<https://github.com/hqh1025/ai-course-notes>

目录

1 引言与嘉宾介绍	2
1.1 本章小结	2
2 模型架构: MoE vs Dense	2
2.1 MoE 的短期优势与长期隐忧	2
2.2 本章小结	3
3 原生多模态 vs 桥接式多模态	3
3.1 两种路线的对比	3
3.2 LLM 与 VLM 为何分开? 何时统一?	4
3.3 本章小结	4
4 合成数据与 Mid-training	5
4.1 Mid-training 的定位	5
4.2 合成数据的两大挑战	5
4.3 Mid-training 是否引入新知识?	5
4.4 多模态数据瓶颈与 Vision-Centric 路线	6
4.5 本章小结	6
5 后训练与强化学习	6
5.1 RL 的核心要素	6
5.2 RL 的 Scaling Law 缺失	7
5.3 RL 的泛化性问题	7
5.4 本章小结	8
6 Agentic & Tool Use	8
6.1 当前 Agent 的核心瓶颈	8
6.2 本章小结	8
7 持续学习与 Memory	9
7.1 Continual Learning 的工程挑战	9
7.2 Parameter-based vs Context-based 两条路	9
7.3 本章小结	9
8 2026 年展望	9
9 总结与延伸	10
9.1 拓展阅读	10

1 引言与嘉宾介绍

本场是青稞 AI 嘉年华 LLM/MLLM 专题圆桌讨论，由陈嘉乐主持，围绕三大主题展开：预训练（模型架构、数据、多模态统一）、后训练（RL、Reasoning）、以及 Agentic & Tool Use。

四位嘉宾

- 曹玉——某厂多模态大模型后训练 & RL 方向。长期深耕强化学习与后训练，2025 年是其方向“开花结果”的一年。
- 薛福昭——Google DeepMind Research Scientist，主做 Pretraining Scaling Law、Data-Efficient Scaling、Distillation 与 Model Architecture。来自 Google 内部视角，认为 Pretraining 仍在稳步前进，并未放缓。
- 刘子伟——新加坡南洋理工大学。关注 Reasoning、Model Architecture（含 Diffusion LM）、原生多模态等三个方向，认为学术和工业都有很多有趣的工作涌现。
- 谢天宝——香港大学 PhD，主攻 Computer Use 与 Multimodal Agent 工程。偏 Engineering Science，强调工程能力在当下大模型迭代中的核心地位。

2025 年整体印象：AI 一年，人间三年

从 DeepSeek R1 的突破开始，整个行业被按下加速键。开源模型在 Reasoning 领域迅速追上 O1/O3 等闭源模型。文生图、文生视频等应用蓬勃发展。头部模型的能力边界仍在快速扩展，发展速率远未放缓。

1.1 本章小结

四位嘉宾分别来自 Google DeepMind（预训练）、学界（NTU/HKU）、工业界（后训练/RL），视角互补。2025 年是 AI 加速发展的一年，无论预训练、后训练还是应用层，均取得了显著进展。

2 模型架构：MoE vs Dense

2.1 MoE 的短期优势与长期隐忧

主持人提出：MoE 和稀疏注意力已成为主流做法，大家对效率的关注是否已超过对效果的关注？

薛福昭：MoE 长期可能被干掉

MoE 本质是用 memory（参数量）换 FLOPs——同时意味着 data efficiency 较差。但**长期来看 FLOPs 永远是最便宜的**：尽管摩尔定律不再完美，芯片提升速度仍比数据增长快得多。因此：

- 一切用其他东西换 FLOPs 的方案都是**短期 solution**
- 一切用 FLOPs 换其他东西的方案都是**长期 solution**

模型可能会逐渐回到 Dense，甚至像 Diffusion Model 那样变成 Super-Dense。

曹玉 (后训练视角): 完全同意 FLOPs 是唯一确定性变量。但补充一个观点——传统不含合成数据的预训练“可能已经 dead 了”。像 Gemini 这样的模型从预训练阶段就引入大量合成数据，相当于用 FLOPs 换 Data，再用 Data 做 Scaling。如果预训练本身已在做“FLOPs for Data”，那 MoE 作为带宽受限硬件体系下的工程解仍有其价值。

刘子伟: 短期和长期存在 Trade-off，个人稍偏 Dense Model。但考虑具体部署场景，MoE 仍有其使用特点。此外，有人在探索下一代计算架构（存储与计算更紧密耦合），这可能在 3-5 年后影响架构选择。

谢天宝: Model Architecture 研究已进入百花齐放状态。MoE 只是工业界的成熟方案，学术界还有更多探索。关键是架构设计应跟随 Learning Paradigm 走——如果未来 Continual Learning 变得重要，架构选择也会随之改变。

OpenAI 的共识：从 Compute-Bound 到 Data-Bound

薛福昭指出，OpenAI 在 GPT-4.5 发布时公开表示，整体已从 Compute-Bound 转向 Data-Bound——这是整个 Community 的共识。

2.2 本章小结

MoE 是当前硬件约束下的工程最优解，但长期可能回归 Dense。预训练范式已发生变化：合成数据的大量引入使得“传统预训练”的边界模糊化。架构选择最终取决于硬件演进和学习范式。

3 原生多模态 vs 桥接式多模态

3.1 两种路线的对比

主持人引入讨论：原生多模态（直接将 pixel 变成 token，从早期就图文混合训练）vs 桥接式（先训 LLM，再接 ViT + adapter）。

薛福昭: Native 更 Clean, 但 Encoder 有工程优势

桥接式 (Encoder-based) 的优点:

- Encoder 和 Decoder 可分开训练，更容易优化
- 可以灵活压缩 Token 数量，全局计算效率更好

桥接式的缺点:

- Encoder 的训练目标 (CLIP? Detection? Reconstruction?) 无法保证对下游完全无损
- Infra 复杂度高: Image 位置不规则导致 Sequence Parallelism 时 workload 不均衡，需要复杂的 reshuffle/recompute，对 MFU 伤害很大

Native 的优点: pixel token 与 text token 无区别，Infra 层面几乎不需要修改纯 LM 的基础设施。

刘子伟 (偏好 Native): Native 的三大优势:

1. **Data 全局考虑**——不用先训 ViT 再接 LM，数据配比更统一

2. **Emerging Ability**——早期就有 Interleaved Data, Early Fusion 可能带来涌现能力 (Gemini 3 据报道重训了原生版本)

3. **Infra Clean**——可直接复用 LM 的 Infra, 部署更简单

但目前缺乏一个所有人都能用的开源 Native Multimodal Codebase/Checkpoint。

谢天宝: Native Multimodal 从 2023 年 Gemini 1 就开始讨论。本质上是工程成熟度的问题——工业界手里有想法但工程能力还没完全跟上, 还在吃当前方案的红利。**最终哪种方案留下来, 取决于可维护性和可控性** (类比软件工程)。

曹玉 (数据视角): 多模态模型的发展**跟着数据的可获得性走**。原生多模态有更好的数据亲和力——对于后训练来说, base model 基础能力越强越好, native 架构在这方面有天然优势。同时提出一个未解问题: 原生多模态的**输出端**应该包含哪些模态? 输入端 (text/vision/audio) 没争议, 但输出端各执一词——人本身并没有 vision native 输出能力。

3.2 LLM 与 VLM 为何分开? 何时统一?

主持人指出: 国内很多厂商仍将 LLM 和 VLM 分开发布, 而国外 (GPT、Gemini) 倾向统一模型。

薛福昭: 闭源模型是黑盒, 可能内部就是两个模型路由。如果用 Encoder + Decoder 结构部署, 最佳做法是分两个芯片——text-only query 不需要 vision encoder 的 memory。合在一起会让问题更复杂, 但在 Serving 层面是可解的。

谢天宝: LLM/VLM 分开与 Coding/Math/Tool Use 分开研发的原因一样——分支开发、然后合并是工程上的常见做法。目前处于一个“中间版本”的状态。

曹玉: VLM 和 LLM 分开是暂时的。对于真正有智能的操作体, 理解世界的能力**一定不是单一模态的**。当前分离是因为 Transformer 在 discrete signal 上远比 continuous signal 建模成熟。长期一定会克服工程/组织/技术问题, 迈向原生输入多模态。

刘子伟: 短期分开有历史因素 (Benchmark 偏文字智能、Vision 对排名影响不大)。但从 Physical AI 的角度看——需要长程决策 (long-horizon action/decision) 和多模态融合, 这些场景**必须统一**。人类是“先有运动能力后有语言”, AI 是反过来, 最终也要解那些需要 sensory input 的底层任务。

3.3 本章小结

Native vs Encoder-based 各有优劣, 短期共存, 长期趋向 Native。LLM/VLM 分开是工程/组织的暂时状态, Physical AI 时代必然统一。

4 合成数据与 Mid-training

4.1 Mid-training 的定位

曹玉：Mid-training 是 World Model 建模的训练中间态

Mid-training 的定义一直不严谨。早期它是“达不到 SFT Golden Label 质量的指令数据”。现在的认知更高：

- RL Post-training 是对已有知识技能的**组合与泛化**
- 这些技能需要在 Mid-training 阶段被模型**理解和体会**
- Mid-training 数据不仅教模型“怎么做事” (Policy Model)，也在**建模世界的状态转移** (World Model)
- 观察数学等 Mid-training 数据：Loss Mask 与 SFT 不同，模型可以看到中间状态转移

在 Policy Model 和 World Model 功能压缩到同一模型的时代，Mid-training 质量很大程度上决定了 Post-training 质量。

4.2 合成数据的两大挑战

薛福昭：合成数据的核心风险

挑战一：跨代迁移——当前模型生成的合成数据，其 gain 能否 transfer 到下一代更大的模型？直觉上就是 challenge，实践中也是。相当于用当前模型的 ceiling 去训练下一代。

挑战二：前置质量 vs Post-training Gain——将 Post-training 模型生成的数据“回灌”到更早的训练阶段，可能会蚕食 Post-training 本身的 gain。因为 Pre → Post 本质是 data quality 不断提升的过程，提前引入高质量数据后，Post-training 的边际收益可能下降。

附加风险：大模型记忆力强，合成数据不可避免包含与训练数据相似的分布，导致隐式 repeat → overfitting → Model Collapse。

4.3 Mid-training 是否引入新知识？

谢天宝：业界共识是 Post-training 将 Pre/Mid-training 中已存在的 trajectory 的 pass rate 从 pass@64 拉到 pass@1。如果 Pre/Mid-training 没有见过足够好的数据，Post-training 很难强行学到。同时 Post-training 的 token 窗口有限，不能放太多数据，必须在 Mid-training 补回来。

刘子伟：学界有 NeurIPS Best Paper Runner-up 级别的工作研究这个问题——Pre-training 奠定知识的大分布，Mid-training 把 boundary 往外推。但如果考虑原生多模态模型，Mid-training 可能需要不一样的 signal（不只是 language），以及 learning to learn 的能力。

数据分析的科学化

谢天宝指出：很多厂商和学校对数据的分析能力有限——“数据要不要、放在哪个阶段”主要靠人判断。Active Learning、Self-Improvement 等概念虽然存在，但与工程师手动管理主流模型训练之间仍有很大脱节。数据管理的科学化是一个值得深入研究的方向。

4.4 多模态数据瓶颈与 Vision-Centric 路线

曹玉：语言模型得益于互联网海量文本，但不可能有第二个互联网提供同等规模的 text-vision pair。低等动物没有 text 概念但生存了很久——VLM 可能不需要那么多数据就能打底，更多应该通过环境交互（RL 或 reward-free 的 learning from experience）来学习。

刘子伟：可以回看前深度学习时代的视觉自监督工作（何恺明、Alusha 等）获得启发。团队尝试过 Visual Jigsaw（打乱图像/视频让模型恢复顺序），能激发 low-level 和 high-level 特性，包括空间智能——这是当前最强模型（GPT-5、Gemini）也做不好的方向。

薛福昭：Vision-Centric 是长期方向

反对纯仿生路线（人/动物的 vision perception 很大程度来自 physical touching，机器很难获得这种 signal）。但摆脱对文本的依赖是 make sense 的：pixel reconstruction、next frame prediction 等方式可以提供海量 vision token。当 compute 再翻 10–100 倍时，text-image pairs 一定跟不上，直接用 vision 硬搞是可行的。

4.5 本章小结

Mid-training 不只是“质量略低的 SFT”，而是 World Model 建模的训练中间态。合成数据面临跨代迁移和 Model Collapse 风险。多模态数据瓶颈可能通过 Vision-Centric 自监督路线突破。

5 后训练与强化学习

5.1 RL 的核心要素

谢天宝（工程视角）列举了 RL 的四大要素：

1. **Environment**——题面（问题集）+ Sandbox（执行环境）。不同场景要求差异巨大，有些甚至需要 replicate 整个 Internet。
2. **Foundation Model**——Mid-training 质量、Cold Start SFT、模型本身的 RL 调性都很重要。
3. **Training Infra**——RL 任务的 context 显著长于 SFT；inference engine、context management、agent memory 设计都需要来回迭代。
4. **RL 算法**——算法设计又反过来要求 environment 和 training infra 的配合（如 traceback 支持、efficiency 优化）。

这四者高度耦合，涉及的工程细节极多，很难在学术界完整研究，也很难一次性掌握 know-how。

曹玉：RL 是闭环控制，问题定义比算法更关键

RL 本质上是带反馈信号的闭环控制，信号链路中每个环节都重要。DeepSeek R1 之所以成功，关键在于**问题选取与定义的清晰度**——这远比具体算法更决定成败。

当前 RL 面临的现实挑战：

- 环境出 bug 概率极高
- 问题选取难度大
- Reward 获取 sparse
- 不同任务间的矛盾冲突仍依赖 human-centric 方式解决

RL 正在朝**专业化方向**发展：做 coding 的人必须成为好的 reward model，做垂类（金融、法律、医疗）也必须懂领域。

5.2 RL 的 Scaling Law 缺失

薛福昭：RL 最大的问题之一是**缺乏开源级别的 Scaling Law**。开源模型发布的是 train 好的 7B/14B/70B，不是 Scaling Curve 上完整可预测下一个 tier 的模型。导致：

- 训完小模型不知道大模型会发生什么
- 迭代依赖最终的大 Run（又慢又贵）
- RL 本身 loss 上蹿下跳，environment 不稳定（package 更新、异步问题），结论非常 noisy

一旦建立稳定的 Scaling Law + Leaderboard，RL 的迭代效率会大幅提升。

5.3 RL 的泛化性问题

曹玉：RL “训什么有什么，但不代表其他方面会提升”。当前 RL 参数更新量仍处于“小扰动”范围（极低 LoRA rank 就能打平 full-parameter），导致单任务能力难以自然泛化到其他领域。但 RL 相比 SFT (offline imitation learning)，在理论上应有更好的泛化性——关键是 **RL 的 Scaling 还远未达到 promise 的量级**。

刘子伟：不追求强泛化到完全 unseen task，能在已知 task 矩阵内有一定**内插能力**就已经足够 impressive。类比 2018 年 Meta Learning 那一波也没找到 general 的泛化方案。Task 和 Environment 的 Scaling 可能是泛化性的关键。

薛福昭：Generalization 的定义不 clear。如果按 FLOPs 计（每个 task sample 1024 条 trace），RL 对指定 task 的泛化性**应该更强**（比 SFT 每条 sequence 一个 task）。关键瓶颈是无法获得 trillion 级别的 environments。

刘子伟：去伪存真

过去半年 RL 因 reasoning 大火涌现了大量变种 trick。但最近的工作（如 Just RL）发现，很多 trick 并不有效——**最朴素、最干净**的方案把超参调好就能达到最优。经历 bubble 后，社区开始区分哪些进展是真的。

5.4 本章小结

RL 已从“锦上添花”变为提升模型能力的核心工具，但面临 environment 复杂度、scaling law 缺失、泛化性不足三大挑战。DeepSeek R1 的成功源于问题定义的清晰而非算法创新。RL 正在走向专业化。

6 Agentic & Tool Use

6.1 当前 Agent 的核心瓶颈

谢天宝：过去一年最大突破是从短时任务到多步长时任务。但**决策质量仍然很低**——观察 trajectory 会发现关键 decision 经常出错（Deep Research 的 report 不反映事实，Coding Agent 引入 bug 后反复 debug）。第二大问题是 **Context/Memory 管理**：当 multimodal agent 的 token 足够多时，很难在无损信息的前提下存储、管理和利用 memory，这导致 agent 有能力上限。Memory 的表示、管理和利用——本质上还是 2020–2023 年的研究方式（如 symbolic memory management），并未根本性改变。

刘子伟：三个关键点：

1. **Long Sequence**——Tool Use 越实用，状态越长；end-to-end 解需要突破 long sequence 的 action space
2. **Self Reflection**——每步出错概率随步数累积，强纠错/恢复能力是 real-world 落地的关键
3. **技能迁移**——Computer Use 中学到的 skills 有没有可能 transfer 到 Physical World（大部分 robots 不会用工具）。人之所以快速上手电脑图标，是因为图标抽象了现实工具的元素——反过来也可能成立。

曹玉：2025 年最 Impressive 的 Agentic 产品

软件：Claude Code——强长程 agentic 能力，在 digital world 中做到了理想中 agentic AI 应做的事。由此可见 Anthropic 对 Agentic & Tool Use 的理解达到了很高水位。整个产业因此发生变化，大部分 coding 服务商都把 Claude Code 作为核心服务之一。

硬件：豆包手机——可以自动刷抖音极速版赚钱并用微信转账，非常 impressive。但几天后很多功能被限制（不能打开微信、不能跨平台比价），暴露了 **agentic AI 技术水平与国内厂商开放政策之间的矛盾**。

核心观察：在 Digital World 中 scaling 到 trillions of environments 很难。一种可能的 paradigm 是**直接把 agent 推向真实世界**（如 Claude Code 做软件、豆包手机做硬件），让世界给出 reward signal，而不是在模拟环境中无休止地训练。

薛福昭：对 agentic 不是专家，但相信从 Tool Use → Web Agent → **Gaming**（Minecraft → 魔兽 → GTA 级 3A 游戏）→ Physical AI 的路径。Gaming 是重要的中间步骤——3A 游戏提供了非常真实的 simulator 环境。

6.2 本章小结

Agent 已能处理长时任务但决策质量低、Memory 管理是硬瓶颈。Claude Code 是 2025 年 agentic 的标杆产品。真实世界的 reward signal 可能比模拟环境更有效。Gaming 是通向 Physical AI 的关

键中间步骤。

7 持续学习与 Memory

7.1 Continual Learning 的工程挑战

谢天宝：以 Cursor 为例，它做了简单的 Continual Learning (Type 补全)，但周期不实时（几小时更新一次），且面临 messy signal、小 batch size 下有效梯度、灾难性遗忘、恶意攻击等问题。核心问题是：**过去我们训完模型就 freeze 做 inference，从不在 inference 时更新参数**——这是一个巨大的范式差异，也是非常大的研究方向。

曹玉：从逻辑上说 “FLOPs for Continual Learning” 是自然且和谐的——用 FLOPs 换持续的智能提升。但工程挑战巨大：用什么方法去 Learn (LoRA? Sparse Update?)、能否做到 Per User Per Model 的 Serving? 希望 2026 年有机会了解哪些模型架构或方式能真正把 Test-Time Training 做出来，而非仅停留在理论推导和小 toy example 上。

7.2 Parameter-based vs Context-based 两条路

薛福昭：不搞花里胡哨，直接用 Context

Lifelong Learning 有两条路：

1. **Parameter-based**——LoRA / MoE 加 Expert / Embedding Bank。风险：模型越大越不稳定，小 batch size 的 backpropagation 很 risky，长期使用体验可能退化。
2. **Context-based**——搞一个 Prompt Database (类似 Memory Retrieval)，把历史写进去。唯一缺点是 context 很长——**但长 context 本质上还是 FLOPs**，回到开头的原则。

建议：不要花里胡哨，直接搞成 context + retrieval。模型的 knowledge 更新就交给周期性的新版本发布（反正现在几个月就出一个新 model）。

刘子伟：大模型可能像一个 OS——包含不同区域，某些参数应慢更新 (Low-frequency knowledge)，某些应快更新 (High-frequency knowledge)。早在 20-30 年前就有 Slow Weight / Fast Weight 的概念 (Hinton 等人)。此外，不同领域对 Long-tail Knowledge 的需求不同，某些 key application 一定需要在模型/数据层面考虑这个因素。数据天生是长尾分布的，低频部分不动、高频部分持续更新——这种 dynamics 值得深入研究。

7.3 本章小结

Continual Learning 是下一代 AI 的关键能力，但面临稳定性、工程复杂度、Serving 成本三重挑战。Context-based 方案更安全但需要长 context 支持；Parameter-based 方案更灵活但风险更大。

8 2026 年展望

- **薛福昭**：期待 Pretraining 出现较大的 Paradigm Shift；个人希望学习更多 RL 等跨领域知识。
- **刘子伟**：(1) 多模态迈向更 Unified/Native 的模型，NLP/Vision/Infra 各方向人才都能贡献；(2) 相信会出现一个大的范式——从 Language-Centric 走向 Vision/Multimodal-Centric。

- **曹玉**：继续推进 RL 后训练。2025 年很多做后训练的同学被迫在算法和 Infra 之间反复跳跃，是快速成长的过程。希望 DeepSeek 春节不要再卷（笑）。期望做更多接地气的 research，通过产品实践来回答 Continual Learning 等问题。
- **谢天宝**：把手头 Multimodal Agent 相关工作做扎实；小范围实验 Self-Improvement 和 Continual Learning。

9 总结与延伸

本场核心观点速览

1. **架构**：MoE 是短期工程解，Dense 是长期方向；FLOPs 永远最便宜。
2. **多模态**：Native Multimodal 长期看好，LLM/VLM 分离是暂时状态。输入端统一无争议，输出端仍有分歧。
3. **数据**：合成数据面临跨代迁移和 Model Collapse 风险；Mid-training 是 World Model 建模的训练中间态。Vision-Centric 自监督可能破解多模态数据瓶颈。
4. **RL**：闭环控制特性使得问题定义比算法更重要；缺乏 Scaling Law、泛化性不足、environment 复杂度是三大挑战。RL 正走向专业化。
5. **Agent**：决策质量低、Memory 管理是核心瓶颈；Claude Code 是 2025 标杆；直接推向真实世界获取 reward signal 可能是突破口。
6. **持续学习**：Context-based (Prompt Database + Retrieval) 比 Parameter-based 更安全实用；长 context 本质还是 FLOPs。

9.1 拓展阅读

- DeepSeek-R1 技术报告——RL 后训练的新范式
- OpenAI “From Compute-Bound to Data-Bound” Blog Post
- Visual Jigsaw / Spatial Intelligence Benchmark 相关工作
- Claude Code 产品设计与 Agentic 架构
- Slow Weight / Fast Weight 经典文献 (Hinton et al.)