

课程笔记

RL 专题 | 2025 ”青稞” AI 嘉年华

五道口纳什 & Codex

2026 年 3 月 29 日



青稞社区

2025“青稞”AI嘉年华

青稞Talk VOL.100 特辑 线上直播

RL 专题
12月28日 周日
13:30-15:00



吕兴豪
清华大學博士生
导师为周志文教授



崔途祺
上海人工智能实验室青年科学家




胡 健
OpenRLHF作者



郑楚杰
腾讯千帆研究员, Qwen3,
Qwen2.5 系列开源模型训练核心贡献者



李英儒
CUHK博士
英广研院科学家

共创伙伴:  减论平台 |  DINQ.me |  Mooncake |  趋近科技
合作伙伴:  WebAgentLab |  ModelScope 魔搭社区 |  AgentAlpha

视频作者/频道: 青稞社区

发布日期: 2025

视频时长: 约 87 分钟

视频链接: 未填写

目录

1 引言：大模型时代的强化学习浪潮	2
1.1 嘉宾介绍与 2025 年关键进展	2
1.2 本章小结	3
2 强化学习算法设计	3
2.1 PRIME：从 Value Model 视角出发	3
2.2 Reinforce++：回归经典的智慧	4
2.3 GSPO：Sequence Level 优化的回归	4
2.4 从第一性原理出发的算法设计	4
2.5 ”好的 RL 算法”应具备什么特点？	5
2.6 本章小结	5
3 模型架构与强化学习的适配	5
3.1 算法适配架构 vs. 架构适配算法	5
3.2 RL 友好即推理友好	6
3.3 两种看待 RL 与大模型关系的视角	6
3.4 MoE 架构的 RL 训练困境	6
3.5 本章小结	7
4 强化学习训练框架	7
4.1 框架演进：从 TRL 到现代框架	7
4.2 OpenRLHF 的设计哲学	7
4.3 理想训练框架的特征	8
4.4 框架的未来方向	8
4.5 本章小结	9
5 训练稳定性：Entropy 与 Mismatch	9
5.1 Entropy：从 Collapse 到 Explode	9
5.2 Entropy 是”结果”而非”原因”	9
5.3 MoE 模型的 Entropy 控制	10
5.4 训推不一致 (Train-Inference Mismatch)	10
5.5 关键监控指标总结	11
5.6 本章小结	11
6 2026 年展望：强化学习的未来方向	11
6.1 更难的任务、更开放的环境	11
6.2 Scaling：Infra 与数据的双重瓶颈	12
6.3 全异步 RL：工业界的下一个战场	12
6.4 Agentic RL 与长程 Credit Assignment	12
6.5 本章小结	13

7 总结与延伸	13
7.1 核心洞察	13
7.2 开放问题	13
7.3 拓展阅读	14

1 引言：大模型时代的强化学习浪潮

2025 年，强化学习（RL）在大语言模型（LLM）领域掀起了一场技术革命。从年初 DeepSeek R1 的发布开始，各家旗舰模型的训练都离不开强化学习。在 2025 年“青稞”AI 嘉年华的 RL 专题讨论中，四位在强化学习领域经验丰富的嘉宾——崔干曲（上海人工智能实验室）、胡建（OpenRLHF 项目发起人，Emilia Research）、郑楚杰（通义千问团队）和李英儒（NovaStar Research）——围绕强化学习算法设计、模型架构适配、训练框架演进、训练稳定性以及未来发展等核心话题，进行了深入的分享与讨论。

本次讨论的核心议题

1. 强化学习算法设计的出发点与心路历程
2. 模型架构如何适配强化学习训练
3. RL 训练框架的现状与未来
4. Entropy、Mismatch 等关键指标与训练稳定性
5. 2026 年强化学习的发展方向展望

1.1 嘉宾介绍与 2025 年关键进展

崔干曲（上海人工智能实验室，青年科学家）：毕业于清华大学，主要研究强化学习在大模型推理能力提升上的算法与机理。代表工作包括 PRIME（复刻 O1 的开创性工作）、Implicit PRM（隐式过程奖励模型）以及首个达到 IPHO 金牌水平的开源物理推理模型 P1。

胡建（网名“初期”，OpenRLHF 项目发起人）：现任职于 Emilia Research，长期处于 RL 的 infra 与算法联合优化的交叉领域。提出了 Reinforce++ 等影响力的算法，并主导了 OpenRLHF 框架的设计与开发。

郑楚杰（通义千问团队）：专注于大模型 RL 训练的稳定性研究，核心关注如何让 RL 训练长期稳定地持续下去。提出了 GSPO 算法，并应用于千问 2507 等模型的发版训练。

李英儒（NovaStar Research）：强化学习理论算法出身，关注训退不一致（Train-Inference Mismatch）问题以及 RL 优化理论在大模型下的适配。致力于从第一性原理出发，为现有的 RL recipe 提供理论解释与指导。

2025 年 RL 领域的共识与趋势

四位嘉宾不约而同地指出：2025 年最有影响力的进展大多不在算法层面，而在 **Infra**（基础设施）和**数据**层面。RL 算法本身仍然以 PPO（2017 年）甚至 Policy Gradient（提出数十年）为基础，但如何在现代 GPU 上实现高效稳定的大规模训练，这方面的创新和突破是巨大的。代表性进展包括：

- **训退不一致 (Train-Inference Mismatch)**：被广泛认识为影响训练稳定性的关键问题
- **MoE 模型的 RL 稳定性**：Mixture-of-Experts 架构给 RL 训练带来了特有的挑战
- **Hybrid 架构**：超长上下文与 Agent 场景下的 RL 稳定性
- **Importance Sampling**：Truncated IS 等技术从 infra 观察中产生算法改进

1.2 本章小结

2025 年是大模型 RL 的“文艺复兴”年——理论基础早已存在，但在大模型的特殊场景下进行适配和工程化落地才是真正的创新前沿。Infra 与算法的联合优化成为主流范式，纯粹的理论推导已不足以驱动进展，必须结合底层系统的观察来指导算法改进。

2 强化学习算法设计

2.1 PRIME：从 Value Model 视角出发

崔干曲团队在 2024 年初（DeepSeek R1 之前）试图复刻 O1 时，面临的核心问题是：**如何突破 Sparse Reward 导致的 Credit Assignment 困难？**

传统方法（如 GRPO）仅使用最终的 Verifiable Reward 作为训练信号，这意味着模型只能从最终结果获得反馈，无法精确知道推理过程中的哪些步骤是正确的。PRIME 的核心思路是引入 **Implicit PRM**（隐式过程奖励模型），通过 Log Probability 的方式自动进行 Credit Assignment。

PRIME 的核心设计思想

- **问题**：PPO 的 Value Model 在大语言模型上训练初期预测极差，导致 reward 先下降再回升（“dip-then-recover”现象），引入额外的训练不稳定性
- **方案**：用 Log Probability 建模 Value，而非传统的 Linear Head 方式。训练前后，Reward Model 仍然是语言模型形式，避免了丢弃 embedding 层接 linear head 的粗暴做法
- **优势**：这是一种更自然、更健壮的 Value 建模方式，尤其在训练初期不会出现严重的 Value prediction 偏差

从今天的视角回看，PRIME 其实是一种 **Value Model 的替代建模方式**。虽然当前 GRPO 等无 Value Model 的方法已经能训得很好，但崔干曲认为，在未来更复杂的场景（如 Agentic RL 中存在内部 feedback 的情况），如何将多源 feedback 转化为 Process Reward 或 Value Estimation，仍然是一个值得深入研究的问题。

此外，PRIME 与 Uncertainty Distillation 方法有深层的联系——两者都在最小化 Policy Model

与 Teacher/Reward Model 之间的 KL 散度，本质上是一种将 Reward Model 知识蒸馏到 Policy Model 的过程。

Value-based Actor-Critic 方法的未来

当前 GRPO 等方法因简单高效而大行其道，但 Value-based 方法并非过时。崔干曲预测，随着任务复杂度提升（更多的 feedback 来源、更长的交互链路），社区将重新关注 Value-based Actor-Critic 方法。这一方向仍有大量可深挖的空间。

2.2 Reinforce++：回归经典的智慧

胡建设计 Reinforce++ 的出发点带有“回归经典”的色彩。在传统 Multi-Agent RL 时代，PPO 在大规模游戏场景中表现非常稳定。来到大模型时代后，胡建的直觉是：经典方法中的许多细节设计（如 Global Batch Norm）是经过前人深思熟虑的，应该被继承而非丢弃。

Reinforce++ 的设计哲学

1. 从 PPO 出发，**去掉 Critic**（避免大模型上 Value Model 的训练困难）
2. **保留 PPO 中经过验证的工程技巧**：Global Batch Norm 等
3. 验证了经典技巧在新场景下仍然有效，“长期存在的东西一定有它存在的道理”

胡建进一步提出了一个重要观点：未来的 RL 算法不再是一个单独的算法，而是一组**优良 Recipe 的组合**。例如：Truncated Importance Sampling + On-Policy Learning + Batch Norm + 合适的 Infra 实现，共同构成一套稳定的训练方案。

2.3 GSPO：Sequence Level 优化的回归

郑楚杰团队在训练千问 2507 版本时发现，GRPO 在后期总会出现稳定性问题。他们怀疑根本原因在于**优化目标本身**：GRPO 的优化目标本应是 Sequence Level 的，但与 Token Level 的优化目标之间缺乏直接的理论关联。

GSPO 的核心创新

- **回归第一性原理**：直接推导 Sequence Level 的优化目标
- **去掉 KL Penalty**：在 235B 及更大模型上，去掉 KL Penalty 后训练速度显著提升，且 GSPO 能保持稳定训练
- **实际应用**：GSPO 被应用于千问 2507 发版以及后续模型（如 Consonant X）的训练

GSPO 的局限性

初版 GSPO 没有考虑训推不一致（Train-Inference Mismatch）问题。后续在内部迭代中增加了对 Mismatch 的修复，产生了 GSPO-VR 等改进算法，进一步提升了稳定性。

2.4 从第一性原理出发的算法设计

李英儒从强化学习理论研究者的视角出发，强调了两个核心观点：

第一，回归第一性原理。许多当前的训练崩溃问题源于对基本概念的忽视。例如，很多框架在 Recompute 阶段将重新计算的概率当作 Rollout 概率使用，这不符合直觉——真正产生采样的概率应来自推理引擎（如 vLLM），而非训练引擎的 Recompute。

第二，理论应为实践服务。李英儒认为，做理论不是为了复杂而复杂，而是为了：(1) 提供简单的解释；(2) 为设计更简单有效的 Scalable 算法提供方法论指导。

Off-Policy Issue 的历史渊源

Train-Inference Mismatch 问题本质上是经典的 Off-Policy Issue 在大模型时代的新表现。这一问题在传统 RL 中已经研究了数十年。李英儒自 2019 年起就在游戏 RL 中研究类似问题 (Divergence of Entity)，当时做的工作与现在的 KL Penalty 方法非常相似。从 TRPO (2015 年) 到现在的各种 IS 修正方法，核心都是关于**单调性能提升的保证**。

2.5 “好的 RL 算法”应具备什么特点？

四位嘉宾达成了高度一致的共识：

好的 RL 算法 (Recipe) 的标准

1. **简单**：每个 Trick 应易于实现，新手看一眼就能理解其作用
2. **符合直觉**：设计应有清晰的 motivation，不是黑箱式的“加了就有效”
3. **有效**：能在各种模型规模和任务上稳定训练，并产生真实的性能收益
4. **组合性**：好的“算法”实际上是一套 Recipe——基本优化目标（如 Reinforce + IS Correction）加上一系列经过验证的 Trick (PPO Clip、Batch Norm、Language Consistency Penalty 等)

郑楚杰进一步指出：与其说“好的 RL 算法”，不如说“好的 RL 配方 (Recipe)”。现实中，大家摸索出一套稳定的配方后就开始使用，并不会给这套 Trick 的组合专门起个名字。

2.6 本章小结

RL 算法设计正在从追求单一突破性算法转向追求一套稳定、简洁、可组合的 Recipe。PRIME 代表了 Value Model 建模的新思路，Reinforce++ 体现了回归经典的智慧，GSPO 展示了第一性原理推导的力量。四位嘉宾一致认为，未来的 RL 算法创新将更多来自 Infra 与算法的联合优化，而非纯粹的理论推导。

3 模型架构与强化学习的适配

3.1 算法适配架构 vs. 架构适配算法

崔干曲提出了一个有趣的视角转换：通常我们考虑的是“让算法适应模型架构”，但很少有人反过来想“让架构适应算法”。他认为架构设计更多受到 Infra 和硬件效率的驱动（训练效率、推理效率、多模态支持、长文本处理），RL 算法处于相对“靠后”的位置——在架构确定之后再进行适配。

Hybrid 架构带来的新挑战

在 Hybrid 架构（如 Mamba + Attention 混合模型）上做 RL 训练，复杂度远高于 Full Attention 架构。Hybrid 架构涉及 State 的更改和回滚操作，高效计算这些操作并非 trivial。这也意味着 RL 训练与架构设计之间存在 Trade-off——RL 研究者需要与架构团队协调，确保新架构对后续 RL 训练友好。

3.2 RL 友好即推理友好

胡建从 infra 角度给出了一个精辟的判断：

对 RL 友好的模型架构

在当前 Long Context、Long Thought 输出的场景下，RL 训练的大部分算力瓶颈集中在生成（Generation/Rollout）部分。因此，提升 RL 训练效率本质上就是提升推理效率。推理友好的架构创新包括：

- **Linear Attention / Mamba**：降低长序列的计算复杂度
- **千问 3 Next**：在推理友好性方面的架构创新
- **MTP (Multi-Token Prediction)**：DeepSeek 提出，对推理效率有显著提升

胡建同时提出了一个前瞻性观点：如果未来 **Diffusion LLM** 取代了 Autoregressive 范式，整个 RL 训练的瓶颈可能从推理优化转向训练优化——这将是一个“天翻地覆”的变化。

3.3 两种看待 RL 与大模型关系的视角

郑楚杰提出了两种对立的视角：

视角一：RL 是大模型的辅助。先确定模型架构（MoE、MTP 等推理加速技巧），再在此基础上适配 RL 算法。这是当前工业界的主流做法。

视角二：大模型是 RL 的辅助。如果我们的终极目标是通过 RL 实现 AGI，那么大模型只是提供先验知识的手段。在这种视角下，应该使用最有利于 RL 训练的模型架构（如 Dense Model，不加 MTP 等加速技巧）。但这种做法在实践中因成本太高而少有人采用。

模型架构变化影响 RL 特性

郑楚杰的一个重要观察：模型架构（以及基模预训练）的变化会连带改变后续 RL 训练的特性。因此，RL 问题和架构问题不能分开来看——每一代模型都需要针对其特有的问题做 RL 方面的改进。

3.4 MoE 架构的 RL 训练困境

李英儒从优化理论的角度解释了为什么 MoE 模型难以进行 RL 训练：

MoE 难训的理论根源

- MoE 架构的离散选择性（Router 的 Expert 选择）从根本上就给优化带来了困难
- 从 Off-Policy 算法的角度看，MoE 实际上**缩小了 Trust Region**——Expert 的选择变化会导致模型行为的剧烈变化
- 现有的 Routing Replay 等技巧都是在解决这一 Trust Region 缩小的问题
- 这个问题不是 RL 独有的——MoE 在 Pretraining 中就已经遇到类似的路由平衡问题

李英儒对未来持乐观态度：可能会出现一些新的 Sparse 架构，既能保持 Sparse 激活的效率优势，又能在优化上具有更好的特性（例如，在 Router 上更好地近似梯度）。

3.5 本章小结

模型架构与 RL 训练之间存在深层的耦合关系。当前工业界以”架构优先，RL 适配”为主流范式。RL 友好性本质上等价于推理友好性——架构层面的创新（Linear Attention、MTP 等）直接惠及 RL 训练效率。MoE 架构给 RL 带来了独特的 Trust Region 缩小问题，需要算法与架构协同设计来解决。

4 强化学习训练框架

4.1 框架演进：从 TRL 到现代框架

崔干曲作为 RL 训练框架的”资深用户”，见证了从 TRL 到 OpenRLHF 再到 veRL、SLIME 的演进历程。他的核心观察是：

训练框架的关键进化

OpenRLHF 的历史性贡献：率先引入了”高效推理引擎（vLLM）+ 训练引擎（DeepSpeed）解耦并拼接”的设计范式。体验过 TRL 初期训练效率的人会深刻感受到，这是一个代际跃迁。此后，几乎所有主流框架都采用了这种推理-训练解耦的架构。

4.2 OpenRLHF 的设计哲学

胡建分享了 OpenRLHF 的设计初衷：当时作为用户，没有一个框架能让 RL 工程师用得”爽和顺手”。设计的核心思路是：

1. **从 RL 工程师的视角出发：**不是 System Engineer 的视角，而是”以前做 PPO 跑游戏环境的人”的视角
2. **技术选型：**Ray（分布式调度）+ vLLM（推理引擎）+ DeepSpeed（训练引擎）的组合
3. **易用性优先：**在保证性能够用的前提下，持续优化易用性

DeepSpeed 到 Megatron-Core 的演进

胡建解释了为何 OpenRLHF 最初选择 DeepSpeed 而非 Megatron-Core：当时的 Megatron-Core 对 RL 工程师极不友好。后来 NVIDIA 工程师借鉴了 DeepSpeed 的优势进行改进，使得 Megatron-Core 在后来的 veRL 等框架中变得可用。技术选型需要因时制宜——选择当前最适合目标用户群体的方案。

4.3 理想训练框架的特征

综合四位嘉宾的观点，理想的 RL 训练框架应具备以下特征：

好的 RL 训练框架

1. **简洁性**：框架不应过于臃肿，Data Flow 清晰，方便 Debug
2. **可 Debug 性**：Rollout、Training、Recompute、Reward/Advantage 计算等每一步都能打出中间结果并存储——这是正确性的保障
3. **易用性**：新手能快速上手，算法研究者能方便地修改调度流程和算法逻辑
4. **借助开源力量**：使用开源的推理引擎（vLLM/SGLang）和训练引擎（Megatron），而非自己从零搭建——开源社区的测试覆盖和迭代速度远超内部团队
5. **社区生态**：活跃的 Contributor、良好的讨论氛围、持续的维护——这决定了框架的长期生命力和影响力

当前框架的痛点

- veRL 等框架逐渐变得臃肿，当需要对调度流程进行修改时“非常难受”
- 正确性问题——有团队使用正确性不满足的框架训练，导致模型训不上去且找不到原因
- 大规模训练（600B+ 模型）需要商业公司内部 Infra 团队做 Megatron-Core 的定制优化，开源框架难以覆盖

4.4 框架的未来方向

李英儒从强化学习特性出发，指出了框架需要支持的新需求：

1. **异步训练**：Rollout 与 Training 的分离式架构，支持异步数据流
2. **Replay Buffer**：支持数据复用以提升 Sample Efficiency
3. **可扩展的 Rollout**：通过增加 Rollout 节点来线性扩展采样能力
4. **长程 Agentic 支持**：Agent 与 Sandbox 的长时间交互（coding 环境数十小时交互），对框架的调度和资源管理提出新挑战

从游戏 RL 到大模型 RL 的框架演进

李英儒指出，Agentic RL 的框架需求越来越像传统游戏 RL——Agent 跟环境交互、异步采样、分离式架构。但新的挑战在于：除了 GPU 上的 Generation Bottleneck，还增加了**环境交互 Bottleneck**（如等待代码编译、Sandbox 反馈等），这使得 Sample Efficiency 问题更加突出。

4.5 本章小结

RL 训练框架经历了从 TRL 到 OpenRLHF 再到 veRL/SLIME 的快速演进。推理-训练解耦是里程碑式的架构创新。好的框架需要在简洁性、可 Debug 性、易用性之间取得平衡，同时借助开源社区的力量保持迭代速度。未来的框架需要支持异步训练、长程 Agentic 交互等新场景。

5 训练稳定性：Entropy 与 Mismatch

5.1 Entropy：从 Collapse 到 Explode

Entropy（熵）是 RL 训练中一个被广泛关注的指标。崔干曲介绍了对 Entropy 认知的演变：

早期关注 Entropy Collapse（2024 年中）：RL 训练初期 Entropy 会快速下降（collapse），导致模型丧失探索能力。当时的应对措施包括 Clip Higher（DAPO 中的做法）以及推导 Entropy 变化公式来指导干预。

现在更关注 Entropy Explode（2025 年下半年）：在大规模 MoE 模型上进行 RL 训练时，Entropy 的急剧升高往往伴随着训练失败。

Entropy 的双面性

- Entropy 是 Exploration 的**必要条件**（但非充分条件）：没有 Entropy 就不可能探索新轨迹
- 但 Entropy 急剧升高同样危险：这往往意味着模型状态变得不稳定（如 Language Mixing——英文 Query 下冒出大量中文回复）
- **理想状态**：给定固定的 Prompt 集合和生成长度，Entropy 应呈现平稳或缓慢下降的趋势（因为模型逐渐收敛）

5.2 Entropy 是”结果”而非”原因”

郑楚杰和李英儒都强调了一个重要观点：Entropy 是模型学习的**结果**，而不是原因。

基于 Entropy 做调整可能并不本质

郑楚杰认为：与其直接干预 Entropy，不如去解决导致 Entropy 异常的根本原因。例如：

- Entropy 急剧上升 → 可能是 Language Mixing 等模型状态不稳定的结果
- Entropy 下降过快 → 可以通过扩大 Exploration Space（增大 Batch Size、增加 Prompt 多样性、增加生成长度）来自然缓解

从优化理论的角度（李英儒）：Policy 在词表维度的 Simplex 上做优化，Entropy 反映了优化 Iterate 距离 Simplex 内部的远近。收敛时 Entropy 自然下降。但使用 Interior Point Method 等手段可以让优化过程在 Simplex 内部移动，从而保持较高的 Entropy。

5.3 MoE 模型的 Entropy 控制

崔干曲分享了在大规模 MoE 模型上控制 Entropy 的实战经验：

1. **冻结 Router**：不训练 Router 是一种比较轻量但有效的方式
2. **控制 Entropy 在稳定值附近**：借鉴之前的 Entropy 控制方法，将 Entropy 稳定在合理范围
3. 尝试过 Routing Replay、R3 等方法，发现它们只能**延缓**而非**根治**稳定性问题

胡建补充了他的实践方案：

MoE RL 训练的轻量方案

1. **纯 Online Learning**：每次做一个更新，IS 始终为 1，从根本上避免 Expert 选择变化的问题
2. **TIS + Mask**：对偏离程度较高的 Token 进行 Mask
3. **Sequence Level Filter**：通过 IS 的几何均值，将偏离过大的整条轨迹直接 Filter 掉（与 GSPO 思路一致）
4. 在 Online Learning 下，不用 Clip Higher，Entropy 也能保持稳定

5.4 训推不一致 (Train-Inference Mismatch)

训推不一致是 2025 年下半年被广泛认识到的关键问题。其核心是：**训练引擎和推理引擎由于精度实现不同，对同一个 Token 的概率计算存在差异，这个差异会在训练过程中累积放大。**

Mismatch 的动态特性

李英儒指出一个关键观察：Mismatch 不是从一开始就很高的——如果它纯粹是 Infra 层面的精度问题，应该从一开始就存在且保持恒定。但实际上，Mismatch 会在训练后期突然急剧增大。这说明 Mismatch 是一个**动态现象**，与优化过程密切相关：

- 精度差异在不同引擎上产生微小的 Gradient Noise
- 这个 Noise 在训练过程中累积，将模型推向精度容易放大的参数区域
- 到达该区域后，Mismatch 从微小变为显著，训练随之崩溃

郑楚杰补充了对 Mismatch 的实践观点：完全消除 Mismatch 在当前 Infra 条件下几乎不可能（且会严重降低推理速度），因此**实际应做的是将 Mismatch 控制在合理范围内**，防止其突然急剧增大。他还观察到，Mismatch 的突然增大可能与 Overfitting 相关。

5.5 关键监控指标总结

RL 训练中需要密切监控的指标

1. **Entropy**：监控模型的探索/收敛状态，关注异常的急升或急降
2. **PPO KL**：Policy 更新的步幅控制
3. **vLLM KL**：推理引擎与训练引擎之间的 Mismatch 程度
4. **Reference Model KL**：训练模型与参考模型之间的距离
5. **Grad Norm**：梯度的范数，反映优化稳定性
6. **TIS (Truncated Importance Sampling)**：Off-Policy 程度
7. **Response Length**：生成长度变化

当任何一个指标出现异常抖动，”基本上这个模型就被砍了一刀，可能要炸了。”（胡建）

5.6 本章小结

训练稳定性是大模型 RL 的核心工程挑战。Entropy 作为结果指标，反映了模型的探索-收敛状态，但直接干预 Entropy 可能不是本质解法。MoE 模型的 RL 训练尤其困难，冻结 Router 和 Online Learning 是目前较为有效的轻量方案。训推不一致是一个动态累积的现象，需要从 Infra 精度对齐和优化稳定性两个维度联合解决。

6 2026 年展望：强化学习的未来方向

6.1 更难的任务、更开放的环境

崔干曲的展望以”Goal-Oriented”为关键词：强化学习的本质特征在于它是目标导向的，不同于 Pretraining 和 SFT 的行为克隆范式。在模型需要完成收集数据极其困难的任务时，必须切换到 RL 这种目标导向的方法。

2026 年 RL 的主线方向（崔干曲）

1. **更难的任务**：模型需要在 Sandbox 中进行长时程交互，仅关注最终产出
2. **更开放的场景**：更复杂的外部环境、更丰富的 Feedback 来源
3. **更长程的交互**：Memory 系统、Self-Evolve（自我进化）
4. **Infra 与架构的挑战**：这些自由度的增加会在 Infra 和模型架构层面带来巨大挑战

6.2 Scaling: Infra 与数据的双重瓶颈

胡建认为 2026 年 RL 的核心仍然是 **Scaling** 问题：

1. **Infra Scaling**：如何实现稳定的大规模长期训练
2. **数据 Scaling**：Agentic RL 需要大量高质量的环境（真实或合成），如何扩大环境规模是关键瓶颈——“总是拿小数据学习，上限就在那里”
3. **算法趋于收敛**：RL 算法层面的大改动可能不多了，更多是小的方面创新（如 Process-based Value Model）

6.3 全异步 RL：工业界的下一个战场

郑楚杰做出了一个具体的技术预判：

2026 年的工业界 RL 方向（郑楚杰）

全异步 RL (Fully Asynchronous RL) 将成为主流。核心矛盾是**计算利用率与算法性能**之间的权衡：

- 全异步框架下，一段模型回复可能由多个模型版本生成——天然引入 Off-Policy 问题
- 需要研究在异步场景下的算法适配：给定一套算法配方，Off-Policy 的容忍程度如何？
- 当前开源框架对全异步 RL 的支持尚不完善，这将是未来数月的重点工作
- 优先打上计算效率，才能讨论 Scale 的问题

6.4 Agentic RL 与长程 Credit Assignment

李英儒的展望聚焦于 **Agentic RL** 和**长程问题**：

1. **环境交互成为新的 Bottleneck**：从 Reasoning RL 到 Agentic RL，瓶颈从 GPU Generation 转向环境交互（等待编译、Sandbox 反馈等），Sample Efficiency 问题更加突出
2. **Effective Horizon 急剧增长**：Agent 可能需要“写三天的代码”才能完成任务，真正的分叉决策点（20% 的关键节点）形成了极长的 Effective Horizon
3. **Credit Assignment 成为关键挑战**：在长程 Agentic 场景下，仅有 Outcome Reward 的 Token-Level Advantage 估计可能不再足够，需要更细粒度的 Credit Assignment 和 Variance Reduction 方法

从传统 RL 汲取智慧

李英儒反复强调，大模型 RL 面临的很多问题在传统 RL 中已有深入研究。Agentic RL 的框架需求越来越像游戏 RL (Agent 与环境交互、异步采样、分离式架构)，而 Sample Efficiency、Credit Assignment、Variance Reduction 这些经典话题在新场景下获得了新的生命力。

6.5 本章小结

2026 年的 RL 发展将沿三条主线展开：(1) 任务复杂度持续提升，从 Reasoning 走向 Agentic；(2) Infra 和数据的 Scaling 成为核心瓶颈，全异步 RL 将成为工业界主流；(3) 长程 Credit Assignment 等经典 RL 问题在新场景下重获关注。算法层面的大变革可能趋缓，但 Recipe 的持续优化和理论解释仍有广阔空间。

7 总结与延伸

7.1 核心洞察

本次青稞 RL 专题讨论呈现了大模型 RL 领域当前最前沿的思考和实践经验。以下是贯穿全场讨论的核心洞察：

大模型 RL 的五大核心认知

1. **Infra 决定上限**：2025 年最具影响力的进展来自 Infra 而非算法。训推不一致、MoE 稳定性等问题的解决方案都源于对底层系统的深刻理解
2. **算法是 Recipe**：单一算法的时代已过，取而代之的是一套经过验证的 Trick 组合。好的 Recipe 应该简单、符合直觉且有效
3. **第一性原理不过时**：从 GSPO 的 Sequence Level 优化目标推导，到训推不一致的理论分析，回归基本原理始终是解决新问题的有力武器
4. **经典 RL 理论的“文艺复兴”**：PPO 中的 Batch Norm、Policy Gradient 的 Variance Reduction、Off-Policy Correction 等数十年前的技术在大模型场景下焕发新生
5. **Co-design 是趋势**：算法与 Infra 的联合优化、模型架构与 RL 训练的协同设计将成为常态

7.2 开放问题

讨论中暴露出若干尚未解决的开放问题：

1. **Token-Level Value Model 的根本困难**：从统计学习理论角度，训好 Token-Level Value 需要的采样量与序列长度呈多项式关系，在当前计算预算下存在 Fundamental Limit
2. **Exploration 的缺失**：当前大模型 RL 几乎没有真正的 Exploration，主要依赖模型自身的先验——未来如何引入结构化的探索机制？
3. **Diffusion LLM 对 RL 范式的影响**：如果 Autoregressive 范式被取代，RL 的整个训练 Pipeline 可能需要重构

4. **全异步训练下的 Off-Policy 容忍度**: 给定一套算法配方, Off-Policy 程度可以容忍到什么地步?
5. **长程 Agentic 场景的 Credit Assignment**: Agent 执行数天任务时, 如何有效地将最终 Reward 回传到关键决策点?

7.3 拓展阅读

- **PRIME**: 崔干曲等人的工作, 通过 Implicit PRM 实现自动 Credit Assignment
- **Reinforce++**: 胡建提出, 回归 PPO 经典技巧的精简 RL 算法
- **GSPO**: 郑楚杰等人提出的 Sequence-Level 优化算法, 去掉 KL Penalty 提升训练效率
- **OpenRLHF**: 开源 RL 训练框架, 首创推理-训练引擎解耦架构(<https://github.com/OpenRLHF/OpenRLHF>)
- **TRPO** (Schulman et al., 2015): Trust Region Policy Optimization, 现代 RL 算法的理论基石
- **DAPO**: 提出 Clip Higher 等 Entropy 控制方法的工作
- **Train-Inference Mismatch Blog**: 李英儒团队 2025 年 9 月发布的关于训推不一致问题的深度分析