


课程笔记

State of AI in 2026: LLM、编程、Scaling Laws、中国、Agents、GPU

五道口纳什 & Codex

2026 年 3 月 29 日



视频作者/频道: Lex Fridman

发布日期: 2026

视频时长: 4h 25m

视频链接: <https://www.youtube.com/watch?v=State-of-AI-2026>

目录

1 引言	2
1.1 本章小结	2
2 Transformer 架构与替代方案	2
2.1 GPT-2 与标准 Transformer	2
2.2 State Space Models 与替代架构	2
2.3 Diffusion Models 用于文本生成	3
2.4 本章小结	3
3 Scaling Laws 与训练	3
3.1 预训练 Scaling Laws	3
3.2 推理时 Scaling (Test-time Compute)	4
3.3 本章小结	4
4 强化学习与 RLHF/RLVR	4
4.1 从 RLHF 到 RLVR	4
4.2 RL 的分布式训练架构	4
4.3 可验证领域的边界	5
4.4 本章小结	5
5 数据：合成数据与质量	5
5.1 合成数据的兴起	5
5.2 本章小结	5
6 AI 编程与开发者工具	6
6.1 编程范式的变革	6
6.2 从零构建 LLM 的教学价值	6
6.3 本章小结	6
7 LLM 的定制化与个人化	6
7.1 Memory 功能与隐私边界	6
7.2 本章小结	7
8 AGI 的定义与展望	7
8.1 什么是 AGI?	7
8.2 本章小结	7
9 硬件与 NVIDIA 的未来	7
9.1 NVIDIA 的持续主导地位	7
9.2 本章小结	8
10 开源与 AI 民主化	8
10.1 开源模型的意义	8
10.2 本章小结	8

11 知识获取与学习方式的变革	8
11.1 AI 时代的学习方法	8
11.2 本章小结	9
12 总结与延伸	9
12.1 拓展阅读	9

1 引言

本期 Lex Fridman 播客邀请了两位 AI 领域广受尊敬的研究者和教育者——Sebastian Raschka 和 Nathan Lambert，共同回顾过去一年 AI 领域的重大技术突破，并展望未来发展趋势。Sebastian 是机器学习教育者和研究者，著有多本深度学习书籍；Nathan 是 Allen Institute for AI (AI2) 的研究员，同时也是知名 AI 博客 Interconnects 的作者。

嘉宾背景

- **Sebastian Raschka**: 机器学习研究者、教育者，著有《Build a Large Language Model (From Scratch)》等书籍，擅长从零构建 LLM 的教学
- **Nathan Lambert**: AI2 研究员，Interconnects 博客作者，专注于 RLHF、开源模型和 AI alignment 研究

1.1 本章小结

这是一次综合性的 AI 年度回顾对话，涵盖从底层架构到上层应用的完整技术栈。

2 Transformer 架构与替代方案

2.1 GPT-2 与标准 Transformer

对话首先回顾了 Transformer 架构的基础。原始的“Attention is All You Need”论文提出了 encoder-decoder 结构，GPT 系列则只使用了 decoder 部分。

Transformer 核心组件回顾

标准 GPT 风格的 Transformer decoder 包含：

- **Self-Attention**: 每个 token 关注序列中所有之前的 token，计算注意力权重
- **前馈网络 (FFN)**: 对每个 token 独立进行非线性变换
- **层归一化 (Layer Norm)**: 稳定训练过程
- **因果掩码 (Causal Mask)**: 确保生成时只看到之前的 token

Attention 的计算复杂度为 $O(n^2)$ ，其中 n 是序列长度，这是长上下文处理的主要瓶颈。

2.2 State Space Models 与替代架构

对话提到了受 State Space Models (SSM) 启发的新架构，例如 Mamba。这些模型用固定大小的状态 (state) 替代了 full attention，使得推理时的内存和计算成本与序列长度线性相关而非二次方。

SSM 的核心思想

State Space Models 维护一个固定大小的隐状态 (hidden state)，通过递推更新来处理序列信息。与 attention 不同，SSM 不需要存储整个序列的 KV cache，因此在推理时更加高效。但在实践中，纯 SSM 模型在某些任务上仍不如 Transformer，当前趋势是 hybrid 架构（混合 attention 和 SSM 层）。

2.3 Diffusion Models 用于文本生成

一个前沿话题是将 diffusion process 应用于文本生成。传统上 diffusion 在连续域（如图像像素）效果出色，但文本是离散的。研究者正在探索如何将去噪过程应用于离散 token，这与 BERT 风格的 masked language model 有某种类似之处。

Diffusion 文本模型的挑战

将 diffusion 应用于文本面临根本性挑战：像素是连续可微的，可以直接在其上定义噪声和去噪过程；但 token 是离散的，不能直接加高斯噪声。当前的方法包括在 embedding 空间做 diffusion、使用离散噪声过程等，但这些方法是否能在规模上超越 autoregressive 模型仍不确定。

2.4 本章小结

Transformer 架构仍然是 LLM 的主流选择，但 SSM/hybrid 架构和 diffusion 文本模型等替代方案正在快速发展。长上下文处理效率是推动架构创新的主要动力。

3 Scaling Laws 与训练

3.1 预训练 Scaling Laws

Scaling laws 描述了模型性能与模型大小、数据量和计算量之间的幂律关系。Chinchilla 论文确立了“compute-optimal”训练的基本原则：给定固定计算预算，模型参数量和训练数据量应该按特定比例缩放。

Scaling Laws 的核心公式

$$L = \frac{A}{N^\alpha} + \frac{B}{D^\beta} + C$$

其中：

- L —— 模型的 loss
- N —— 模型参数量
- D —— 训练数据量 (token 数)
- A, B, C, α, β —— 拟合常数

这个关系意味着在任何给定的计算预算下，存在最优的参数量和数据量分配比例。

3.2 推理时 Scaling (Test-time Compute)

一个重要的新趋势是”推理时 scaling”——不再只关注训练时投入多少计算，而是在推理时也投入更多计算来提升性能。这与 Chain-of-Thought (CoT) 推理和 reasoning models 密切相关。

训练 vs 推理的 Scaling 权衡

传统 Scaling Laws 关注训练阶段：更大的模型 + 更多数据 = 更好的性能。而推理时 Scaling 的思路是：在推理时让模型”思考更久”（生成更多中间推理步骤），以换取更高的准确率。这两种 scaling 维度可以互补——一个较小但善于推理的模型可能在某些任务上超越更大但直接回答的模型。

3.3 本章小结

Scaling Laws 仍然有效，但 scaling 的维度正在扩展——从单纯的训练计算量扩展到推理时计算、数据质量和训练方法等多个方向。

4 强化学习与 RLHF/RLVR

4.1 从 RLHF 到 RLVR

强化学习已经成为 LLM 训练的关键阶段。早期的 RLHF (Reinforcement Learning from Human Feedback) 使用学习到的 reward model 来优化模型行为。而更新的 RLVR (RL with Verifiable Rewards) 则直接使用可验证的正确性信号作为 reward。

RLHF vs RLVR

- **RLHF**: 训练一个 reward model 来模拟人类偏好，然后用 RL 优化 LLM 使其输出获得更高的 reward score。缺点是 reward model 可能被”游戏化” (reward hacking)
- **RLVR**: 在有客观正确答案的领域（如数学、代码），直接用正确性验证作为 reward。优点是 reward 信号准确无偏，缺点是只适用于可验证的领域

4.2 RL 的分布式训练架构

Nathan 解释了大规模 RL 训练的基础设施需求：在世界各地部署 actor (执行推理生成回答)，然后将结果发送回紧密互连的计算集群进行梯度更新。这种架构需要在不同类型的并行化 (data parallelism、model parallelism、pipeline parallelism) 之间做权衡。

RL 训练的基础设施挑战

RL 训练与纯预训练的基础设施需求不同：

- **Actor**: 分布式的推理节点，可以地理分散
- **Learner**: 需要紧密互连的 GPU 集群，用于梯度计算和模型更新
- **通信**: actor 和 learner 之间需要高效的数据传输

这种架构意味着 RL 阶段的计算不仅仅需要大量 GPU，还需要复杂的调度和通信系统。

4.3 可验证领域的边界

数学和代码是 RLVR 的经典领域，因为它们有客观的正确性判据。但对话提到了一个开放问题：当你在足够多的可验证领域上训练时，模型是否会自然泛化到不可验证的领域？

泛化的不确定性

目前尚不清楚 RLVR 在可验证领域（数学、代码）上训练的推理能力能在多大程度上迁移到不可验证的领域（创意写作、战略规划等）。在 instruction tuning 的文献中，存在一个“泛化拐点”——当你训练的任务数量足够多时，模型突然可以泛化到从未见过的任务。我们不确定 RLVR 是否也存在这样的拐点。

4.4 本章小结

RL 已从 RLHF 发展到 RLVR，在可验证领域取得了显著成功。但 RL 训练的基础设施复杂性和泛化边界仍是活跃的研究方向。

5 数据：合成数据与质量

5.1 合成数据的兴起

数据质量比数据数量更重要已成为共识。合成数据——由 LLM 生成的训练数据——在多个阶段被大量使用：预训练数据增强、instruction tuning 的指令生成、以及 RL 中的 rollout 数据。

合成数据的分层

合成数据并非简单地让 LLM 生成文本：

- **Raw LLM 输出**：质量参差不齐，可能包含幻觉
- **Human-in-the-loop 验证**：人类对 LLM 输出进行筛选和修正，即使只验证一小部分代码行，质量也会显著提升
- **多阶段过滤**：先生成大量候选，再通过多重质量过滤筛选出高质量子集

纯 LLM 生成数据的风险

Sebastian 提醒：不能简单地用 LLM 来学习某个领域知识。LLM 生成的内容在数学中可能包含错误，而你在阅读时未必能发现（因为你不会逐步验证每个推导）。代码领域相对安全，因为你可以直接运行来验证。这种可验证性的差异使得合成数据在不同领域的可靠性差异巨大。

5.2 本章小结

合成数据是当前 LLM 训练的重要组成部分，但其质量控制至关重要。Human-in-the-loop 验证和可验证领域的自动检测是确保合成数据质量的两大支柱。

6 AI 编程与开发者工具

6.1 编程范式的变革

对话深入讨论了 AI 如何改变编程体验。Sebastian 认为，使用 AI 编程”不那么孤独”——就像有一个结对编程伙伴。Nathan 则关注 AI 编程对整个软件工程行业的影响。

AI 编程的当前状态

AI 编程工具已经从简单的代码补全发展到：

- **对话式编程**：通过自然语言描述需求，AI 生成完整代码
- **代码审查**：AI 识别 bug、安全漏洞和性能问题
- **代码库理解**：AI 理解整个项目上下文，提供精准建议
- **测试生成**：自动为现有代码生成测试用例

6.2 从零构建 LLM 的教学价值

Sebastian 强调了从零实现 LLM 的教学价值。他的书《Build a Large Language Model (From Scratch)》的目标是让读者在单个 GPU 上就能完成所有实验。这与直接使用 Hugging Face Transformers 库不同——后者的代码过于复杂（因为需要支持大量不同模型），不适合用于学习。

学习 LLM 的方法论

Sebastian 推荐的学习路径：

1. 从零实现核心组件（attention、FFN、位置编码等）
2. 在单 GPU 上训练小规模模型，自我验证理解
3. 对比自己的实现与 Hugging Face 等产品级实现的差异
4. 这种方式类似 RLVR——通过代码运行来验证自己的理解

6.3 本章小结

AI 正在深刻改变编程方式，但理解底层原理仍然重要。从零构建模型是学习 LLM 最扎实的方法之一。

7 LLM 的定制化与个人化

7.1 Memory 功能与隐私边界

对话讨论了 LLM 的个性化趋势。ChatGPT 等产品已经推出了 memory 功能，允许 AI 记住用户的偏好和历史。但这引发了一个重要的隐私问题：工作和个人生活的边界。

个性化与隐私的张力

你可能不希望你的工作 AI 知道你的个人爱好项目，反之亦然。公司可能不允许员工使用带有个人信息的 AI 工具。这意味着用户可能需要维护多个 AI 订阅/配置——一个用于工作（干净的、无个人信息的），一个用于个人用途。这种碎片化本身就是一个值得关注的用户体验问题。

7.2 本章小结

LLM 的个性化是提升用户体验的重要方向，但需要在个性化与隐私之间找到合适的平衡点。

8 AGI 的定义与展望

8.1 什么是 AGI？

对话涉及了 AGI (Artificial General Intelligence) 的定义问题。OpenAI 的定义偏向于“能完成大量经济上有价值的任务”，但 Nathan 对此并不完全认同。

AGI 定义的光谱

- **弱定义**：AI 能作为“远程工作者的替代品”，完成大量经济任务——这已经是一个相当高的门槛
- **中定义**：AI 能在任何人类能做的认知任务上达到或超过人类水平
- **强定义**：AI 能做出人类无法预料的科学发现——这远超当前能力

当前的 LLM 虽然能力强大，但距离“远程工作者替代品”仍有显著差距，更不用说更强的定义了。

8.2 本章小结

AGI 的定义仍在争论中，不同的定义暗示着不同的时间表。务实的做法是关注具体能力的进步，而非纠结于是否已达到“AGI”。

9 硬件与 NVIDIA 的未来

9.1 NVIDIA 的持续主导地位

对话讨论了 NVIDIA 在 AI 硬件领域是否会继续主导。Nathan 认为 NVIDIA 具有巨大的优势——持续迭代和大规模制造能力——但也面临被颠覆的风险，特别是如果有人在架构层面做出根本性创新。

NVIDIA 面临的潜在挑战

- **ASIC 竞争**：Google TPU、Amazon Trainium 等定制芯片针对特定工作负载优化
- **架构创新**：如果计算范式根本性变化（如从矩阵乘法转向其他操作），NVIDIA 的优化方向可能需要调整
- **开源硬件**：RISC-V 等开放架构可能在长期带来新的竞争格局

但目前 NVIDIA 的生态系统优势和迭代速度使其短期内难以被取代。

9.2 本章小结

NVIDIA 在 AI 硬件领域的主导地位短期内稳固，但技术演进的不确定性意味着没有永恒的赢家。

10 开源与 AI 民主化

10.1 开源模型的意义

对话涉及了开源 AI 模型的战略意义。Nathan（来自 AI2，一个致力于开源 AI 的机构）讨论了开源的价值和局限。

开源 AI 的曼哈顿项目类比

Nathan 指出，曼哈顿项目的动力来自文明级别的风险（civilizational risk）。但对于开源 AI 模型，很难论证存在类似的文明级风险。这使得以“安全”为理由限制开源 AI 的论点缺乏说服力。开源的真正价值在于：(1) 推动研究透明度，(2) 降低 AI 使用的门槛，(3) 防止少数公司垄断 AI 能力。

10.2 本章小结

开源 AI 在推动技术民主化和研究透明度方面具有不可替代的价值，但其治理和安全框架仍需发展。

11 知识获取与学习方式的变革

11.1 AI 时代的学习方法

Sebastian 和 Nathan 都讨论了 AI 如何改变人们获取知识的方式。Sebastian 认为传统教科书——由专家线性组织的知识——仍然具有不可替代的价值，特别是对于数学等需要系统学习的领域。

AI 辅助学习的边界

- **AI 擅长**：回答具体问题、解释概念、提供代码示例、降低入门摩擦
- **AI 不擅长**：提供系统化的学习路径、确保数学推导的正确性、替代深度阅读的思维训练
- **最佳实践**：将 AI 作为学习的辅助工具，与传统教材和课程结合使用

11.2 本章小结

AI 使知识更容易获取，但不能替代系统化的深度学习。最有效的学习方式是将 AI 辅助与传统方法结合。

12 总结与延伸

本次 4 小时 25 分的深度对话覆盖了 AI 领域几乎所有关键议题：

1. **架构**：Transformer 仍是主流，但 SSM 和 diffusion 正在挑战其地位
2. **训练**：从预训练 scaling 扩展到推理时 scaling，RL 成为关键训练阶段
3. **数据**：合成数据兴起，但质量控制和人类验证不可或缺
4. **编程**：AI 正在根本性地改变编程体验和软件工程行业
5. **硬件**：NVIDIA 主导地位稳固但非永恒，专用芯片带来新竞争
6. **开源**：对研究透明度和 AI 民主化至关重要
7. **AGI**：定义模糊，但具体能力持续快速进步

核心洞察

2025–2026 年 AI 领域最重要的趋势不是单一突破，而是多个维度同时 scaling 的融合：更大的模型、更好的数据、更长的推理链、更高效的架构、更强的 RL 训练。这种多维度的同步进步使得预测 AI 能力的上限变得异常困难。

12.1 拓展阅读

- Sebastian Raschka, *Build a Large Language Model (From Scratch)*
- Nathan Lambert, Interconnects 博客: <https://www.interconnects.ai/>
- "Attention is All You Need", Vaswani et al., 2017
- "Scaling Laws for Neural Language Models", Kaplan et al., 2020
- "Training Compute-Optimal Large Language Models" (Chinchilla), Hoffmann et al., 2022