

演讲笔记

How We Scaled Kimi K2.5

杨植麟 (Moonshot AI / Kimi) — GTC 2026 Keynote

五道口纳什 & Codex

2026 年 3 月 29 日



演讲者：杨植麟 (Moonshot AI / Kimi)

场合：NVIDIA GTC 2026

视频时长：39 min

视频链接：未填写

目录

1 引言：开放模型的愿景	2
2 Token Efficiency: Muon 优化器与训练稳定性	2
2.1 为什么 Token Efficiency 如此重要	2
2.2 Muon 优化器	2
2.3 QK-Clip: 解决训练不稳定性	3
2.4 本章小结	3
3 Long Context: Kimi Linear 与 Delta Attention	3
3.1 为什么长上下文对 Agent 时代至关重要	3
3.2 Kimi Delta Attention: 细粒度衰减	3
3.3 高效实现: Chunk-wise 公式与矩阵求逆	4
3.4 性能对比	4
3.5 本章小结	4
4 Agent Swarms: 多 Agent 并行协作	4
4.1 Agent Swarm 范式	4
4.2 Agent Swarm 的 RL 训练	5
4.3 本章小结	5
5 Kimi K2.5: 三个维度的融合	5
5.1 训练与架构	5
5.2 跨模态增强效应	6
6 Attention Residue: 下一代架构的预告	6
6.1 从 ResNet 到 Attention Residue	6
6.2 Block Attention Residue	6
6.3 实验结果	7
6.4 本章小结	7
7 总结与延伸	7
7.1 研究范式的转变	7
7.2 三个维度的乘法效应	7
7.3 开源社区的未來	7
7.4 拓展阅读	7

1 引言：开放模型的愿景

杨植麟在 GTC 2026 的演讲中阐述了 Moonshot AI (Kimi) 在开放模型领域的最新进展。他引用了 Jensen Huang 在 CES 上的一张 slide，指出开放模型正在快速缩小与闭源模型之间的差距，并正在达到前沿水平。

核心理念

开放模型不仅要“开放”，更要“出色” (Open models cannot be just open — they have to be great)。Kimi 团队的目标是让智能通过开源模型触达世界每个角落，同时在性能上与闭源模型竞争。

演讲围绕三个 scaling 维度展开：

1. **Token Efficiency**: 通过更好的架构和优化器，提升每个 token 的学习效率
2. **Long Context**: 扩展上下文长度以支持更复杂的 agent 任务
3. **Agent Swarms**: 多 agent 并行协作完成复杂任务

从 Scaling 到 Agent 的统一视角

杨植麟将这三个维度用 agent 的语言统一表述：token efficiency 对应更强的先验 (agent RL 搜索更高效)；long context 对应更长的 agent 运行时间 (可运行数天甚至数周)；agent swarms 则是并行化的新维度。最终目标是拥有一群具有超长上下文、超强先验的 agent 组成的集群。

2 Token Efficiency：Muon 优化器与训练稳定性

2.1 为什么 Token Efficiency 如此重要

杨植麟从经典的 Kaplan scaling law 出发，强调 token efficiency 不仅关乎效率，更关乎智能的上界。

Token Efficiency

假设你拥有 50 万亿高质量 token，如果新优化器能带来 2 倍的 token efficiency 提升，那就相当于“凭空”获得了 100 万亿 token 的效果。在高质量数据量趋近上限 (data wall) 的时代，提升 token efficiency 直接意味着推高智能的天花板。

2.2 Muon 优化器

Muon 是一种二阶优化器，其核心思想是对每次梯度更新进行变换，使得各参数分量相互正交。与传统的 AdamW 相比，Muon 在相同参数数量和训练 token 数下能显著提升性能。

Kimi 团队是首个证明 Muon 优化器可扩展到大规模 LLM 训练的工作，核心技术包括：

- **Decay 策略**：对 scaling 到更大模型至关重要
- **RMS 一致性**：引入可调系数，确保 Muon 的 RMS update 与 Adam 可比
- **分布式实现**：将优化器状态分片到 data parallel group，实现高效的分布式 Muon

2.3 QK-Clip: 解决训练不稳定性

当 Muon 扩展到 1 万亿参数模型时，团队遇到了训练不稳定性问题：max logits 迅速飙升超过 1000（正常值约为 50–100），导致训练发散。

QK-Clip 技术

对每个 attention head，在 forward pass 中计算 max logit，然后计算一个除数因子，应用于 query 和 key 的投影，将最大值约束在给定范围内。实验表明：

- 应用 QK-Clip 前后的训练曲线严格重合——不影响训练收敛
- Max logit 在达到阈值（如 100）后被有效约束，随后自然下降

这使得 Kimi 团队成功完成了历史上首次大规模 Muon 训练（1 万亿参数）。

训练稳定性不可忽视

传统 Adam 训练中较少出现的 logit explosion 问题，在使用二阶优化器时可能被放大。仅仅更换优化器而不考虑稳定性机制，可能导致训练完全失败。

2.4 本章小结

Token efficiency 不仅是工程优化，更是推高智能上界的关键路径。Muon 优化器通过正交化梯度更新实现 2 倍 token efficiency 提升；QK-Clip 技术解决了大规模训练中的稳定性问题，使 Muon 成功扩展到万亿参数。

3 Long Context: Kimi Linear 与 Delta Attention

3.1 为什么长上下文对 Agent 时代至关重要

杨植麟引用了一个“隐藏的宝石”级别的经典图表：Transformer 与 LSTM 的对比。Transformer 不仅在相同参数和 token 数下获得更低的 loss，更关键的是它能**持续通过上下文改善预测**——随着 token index 增加，Transformer 的 loss 持续下降，而 LSTM 在一定范围后趋于饱和。

Transformer 的真正优势

Transformer 胜出不只是因为“更强”，更因为它能利用更长的上下文持续获得信息增益。这一特性在 agent 时代尤为关键：agent 需要运行数天甚至数周来完成复杂任务（如从零编写 Linux 内核），这要求模型能高效处理超长的 trajectory。

3.2 Kimi Delta Attention: 细粒度衰减

Kimi Linear 架构的核心创新是 **Kimi Delta Attention**，它改进了 GDR（Generalized Delta Rule）的循环记忆机制。

传统 linear attention 使用全局标量衰减因子（global scalar decay），导致只能在“遗忘一切”和“记住一切”之间二选一。Kimi Delta Attention 引入了**细粒度衰减因子**（fine-grained decay）：

$$\alpha \in \mathbb{R}^{d \times d} \quad (\text{对角矩阵，而非标量})$$

这样不同 channel 可以有不同的衰减速率：

- 部分 channel 缓慢衰减——保留长距离信息
- 部分 channel 快速衰减——及时遗忘并吸收新信息

3.3 高效实现：Chunk-wise 公式与矩阵求逆

为了在现代 GPU 上并行化，需要将递推公式转换为 chunk-wise 形式。但对角矩阵 α 无法像标量那样轻易提取公因子，带来了巨大的工程挑战。

精确等价的并行公式

通过引入**矩阵求逆运算**和**累积衰减因子**，团队将递推公式重写为三个可并行计算的等式。这不是近似——是数学上严格等价的公式，在不牺牲任何精度的前提下实现高效并行。

3.4 性能对比

Kimi Linear 在公平对比中取得了全面领先：

- **短上下文任务** (MMAU)：优于 MLA 和 GDN
- **长上下文任务** (Ruler)：同样优于其他变体，且效率更高
- 扩展到 100 万 token 及以上时，效率优势更加显著
- 这是**首个在所有维度上超越 full attention 的架构**（短上下文、长输入、长输出）

架构采用 linear attention 与 full attention 以 3:1 的比例混合，在长上下文能力和效率之间取得平衡。

3.5 本章小结

Kimi Linear 通过细粒度衰减因子和精确等价的并行公式，实现了比 full attention 更好的性能和更高的效率，尤其在超长上下文场景下优势显著。

4 Agent Swarms：多 Agent 并行协作

4.1 Agent Swarm 范式

单 agent 模式面临任务复杂度的瓶颈。Kimi 提出了 **Agent Swarm** 范式：

- 一个**主 agent (orchestrator)** 负责任务编排
- 主 agent 可以生成一组**子 agent**，分配子任务
- 子 agent 并行执行，主 agent 收集结果
- 整个过程可迭代进行

类比人类组织

Agent Swarm 类似于一家公司的组织结构：CEO 负责分解和分配任务 (orchestrator)，AI 研究员、Web 开发者、物理研究员等各司其职 (sub-agents)，最终由 fact checker 等角色汇总结果。

实验表明，Agent Swarm 能显著降低任务执行时间，尤其在高复杂度任务上效果突出。当扩展到 100 甚至 1000 个子 agent 时，可以在可接受的时间内完成复杂任务。

4.2 Agent Swarm 的 RL 训练

三项奖励函数

除了标准的结果奖励 (outcome reward) 外，Agent Swarm 的 RL 训练引入了两个额外的奖励信号：

1. **Instantiation Reward**：激励子 agent 的并行实例化，防止“串行坍塌”——即模型退化为单 agent 执行
2. **Finish Reward**：确保子任务有较高的完成率，防止模型“刷”第一个奖励——只生成大量子 agent 但不完成任务
3. **Outcome Reward**：标准的任务完成度奖励

前两个奖励在训练过程中逐渐衰减权重 (decay strategy)，早期鼓励探索，后期侧重结果。

Agent Swarm 的训练陷阱

如果只有 outcome reward，模型容易退化为单 agent 模式 (串行坍塌)。如果只加 instantiation reward，模型可能 hack 这一信号——生成大量伪子任务但从未完成。必须同时使用三种奖励信号才能实现稳定训练。

4.3 本章小结

Agent Swarm 通过多 agent 并行协作开辟了新的 scaling 维度。三项精心设计的奖励函数配合衰减策略，使模型能有效学习并行编排和任务分解能力。

5 Kimi K2.5：三个维度的融合

5.1 训练与架构

K2.5 将上述三个维度的进展融合为一个模型：

- **Muon + QK-Clip 优化器**：提升 token efficiency
- **Kimi Delta Attention + Linear 架构**：增强 long context 能力
- **Agent Swarms**：开辟并行 scaling 新维度

模型在 NVIDIA H800 GPU 上训练，每个节点包含 2 TB RAM，GPU 间通过 NVLink 互联。K2.5 基础模型经过超过 30 万亿 token 的训练（base model 15T + K2.5 额外 15T），训练过程极其平稳——没有任何 loss spike。

Early Fusion：原生视觉-文本联合训练

K2.5 是首个具有**原生联合视觉-文本能力**的开放模型。不同于在文本模型之上添加视觉能力的 late fusion 方案，K2.5 从训练第 0 天起就融合视觉和文本 token（early fusion），初步实验表明这一方案优于 late fusion。

5.2 跨模态增强效应

K2.5 训练中发现了一个令人兴奋的现象：两种模态可以相互增强。

Vision 改善 Text，Text 改善 Vision

- **Vision → Text**：仅使用视觉任务进行 RL（不含任何数学/编程任务），却能提升文本推理性能
- **Text → Vision**：拥有强大的文本基础后，完全不需要视觉 SFT 数据（Zero Vision SFT），仅用文本 SFT + 联合 RL 就能达到接近 SOTA 的视觉性能

这一发现表明，early fusion 使两种模态真正共享了表示空间，实现了能力的双向迁移。

6 Attention Residue：下一代架构的预告

6.1 从 ResNet 到 Attention Residue

杨植麟回顾了何恺明在 ICML 2016 的经典 tutorial：ResNet 解决了深度网络训练中的梯度消失问题，使任意深度的网络变得可训练。他引用 Ilya Sutskever 两年前的观点：**Residual connection 本质上是旋转了 90 度的 LSTM**。

深度维度上的”注意力”

如果在时序维度上，从 LSTM 到 Attention 是一次成功的升级，那么在深度维度上，能否做同样的事？Residual connection（类似 LSTM 的加法门控）可以被替换为 Attention——不仅取上一层的输出，而是对**所有前序层的输出**进行注意力聚合。这就是 Attention Residue。

6.2 Block Attention Residue

为了减少通信和显存开销，团队进一步设计了 **Block Attention Residue**：

- 将所有层分为多个 block（如每 16 层一个 block）
- Block 内部使用标准 residual connection
- Block 之间使用 attention residue

6.3 实验结果

- Scaling law 上实现 **24% token efficiency 提升** (50T token → 等效 62T token)
- Validation loss 持续低于原始曲线
- 在 GPQA、Math、HumanEval 等推理密集型 benchmark 上改进最为显著

6.4 本章小结

Attention Residue 将时序维度上从 LSTM 到 Attention 的成功迁移到深度维度，以 24% 的 token efficiency 提升和推理任务上的显著改进，展示了架构创新仍有巨大空间。

7 总结与延伸

7.1 研究范式的转变

杨植麟指出，当前 AI 研究范式与 10 年前截然不同。过去侧重“发表新 idea”，但缺乏严格实验的支撑难以得出可靠结论。如今，有了 scaling ladder 和丰富的 benchmark 体系，可以在不同规模上验证想法，从而对“古老”的技术（如优化器、注意力机制、残差连接）做出自信且扎实的改进。

7.2 三个维度的乘法效应

从加法到乘法

三个 scaling 维度不是简单叠加，而是相互增强的乘法关系：

- Adam (2014) → Muon-Clip: 更好的 token efficiency
- Full Attention (2017) → Kimi Linear: 更好的长上下文
- Residual Connection → Attention Residue: 更高效的深度 scaling

将这些改进相乘，可以获得远超单项改进之和的整体提升。

7.3 开源社区的未来

杨植麟对开源社区的未来持乐观态度，认为在架构和优化方面将持续涌现突破性改进。Agent Swarms 不是终点——scaling 的新维度会不断出现，推动开源模型与闭源模型的持续竞争。

7.4 拓展阅读

- Kaplan et al., "Scaling Laws for Neural Language Models" (2020) — 经典 scaling law
- Muon Optimizer 论文 — Kimi 团队的二阶优化器工作
- Kimi Linear 技术报告 — Delta Attention 的详细公式推导
- Attention Residue 技术报告 — 深度维度注意力的完整实验
- He et al., "Deep Residual Learning for Image Recognition" (2015) — ResNet 原始论文