

访谈型技术笔记

姚顺宇访谈：在 Anthropic 与 Gemini 训练模型，个人英雄主义之后

基于 Zhang Xiaojun Podcast 公开视频、字幕与原视频画面整理

2026-05-12



视频作者/频道: Zhang Xiaojun Podcast

发布日期: 2026-05-11

视频时长: 03:48:00

视频链接: <https://www.youtube.com/watch?v=ttkd0t5qTD4>

本地素材: youtube/ttkd0t5qTD4/original.mkv, 4K AV1 + Opus; 字幕来自 YouTube SRT。

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 导读：这不是一场模型发布会，而是一张 2026 年 AI 研究的横截面	3
1.1 章节地图	4
1.2 本章小结	4
2 从 benchmark 竞争到问题定义竞争	4
2.1 术语消化：公开指标为何会失真	6
2.2 为什么意愿曾经决定能力差异	6
2.3 本章小结	6
3 “Pre-train 没有到头”：scaling law 与数据墙	6
3.1 scaling law 的三种“到头”含义	7
3.2 本章小结	8
4 Coding 的爆发：从写代码到长程代理	8
4.1 Manus、OpenClaw 与 wrapper 的壁垒问题	9
4.2 产品经理为什么暂时难被替代	10
4.3 本章小结	10
5 蒸馏、资源劣势与中国模型公司的机会	10
5.1 硬蒸与软蒸	11
5.2 机器人为什么仍有机会	11
5.3 本章小结	11
6 物理训练如何塑造 AI 研究品味	12
6.1 非厄米系统的直觉版解释	12
6.2 “挑战不擅长的事”	12
6.3 本章小结	13
7 Anthropic：top-down 机制、Claude 训练与产品化	13
7.1 Claude 3.7/4.5 与工具使用能力	13
7.2 top-down 为什么难复制	14
7.3 产品经理的新角色	14
7.4 本章小结	14

8 Gemini: ML coding 与 long horizon	14
8.1 long horizon 的技术问题	15
8.2 ML coding: 让 AI 训练 AI	16
8.3 本章小结	16
9 组织、产品与中美差异	16
9.1 neo lab 的机会与死亡率	17
9.2 TPU 与 GPU 的组织含义	17
9.3 本章小结	17
10 “AI 本质是简单的”: 靠谱、细致与负责	17
10.1 24 小时强化学习面试题	18
10.2 个人英雄主义之后	18
10.3 本章小结	19
11 总结与延伸	19
11.1 speaker closing: 从英雄到系统	19
11.2 本笔记的核心提炼	19
11.3 拓展阅读	20

1 导读：这不是一场模型发布会，而是一张 2026 年 AI 研究的横截面

这期访谈的主角是姚顺宇：清华物理本科、斯坦福理论物理博士，短暂进入 Berkeley 做博士后后转向 AI，先后在 Anthropic 与 Google DeepMind 做前沿模型训练工作。访谈题目虽然带着人物故事色彩，但真正有价值的部分，是它把 2026 年初模型实验室内部的一组问题串了起来：模型能力是否同质化、预训练是否到头、coding 与 long-horizon agent 为什么突然爆发、蒸馏的边界在哪里、Anthropic 与 Gemini 的组织差异，以及为什么姚顺宇认为 AI 时代已经不再是个人英雄主义的时代。

本笔记的阅读方式

本笔记不是逐字转写，而是把 3 小时 48 分钟访谈压缩成一份结构化技术笔记。每一章都保留访谈中的核心判断，并补充必要背景：benchmark、scaling law、agentic coding、distillation、long horizon、TPU/GPU 拓扑、组织设计等。人物经历部分服务于理解研究品味和选择，不会展开成传记。



图 1: 开场介绍：两位同名的姚顺宇/姚顺雨，以及本期嘉宾从理论物理转入 AI 的履历。¹

读图：封面与人物帧的作用

本期不是幻灯片课程，视频画面主要提供语境证据：谁在说、在哪一段说、讨论对象是否已经切换。读者不应从人物画面本身推断技术结论，而应把它当作章节锚点，技术判断来自字幕、章节和上下文整理。

¹ 视频画面时间区间：00:04:12-00:04:40。画面本身是访谈场景，教学价值在于定位人物与问题背景。

访谈主线

访谈从“两个姚顺宇”的身份辨析开始，迅速进入 AI 行业判断：三大模型实验室在纸面 benchmark 上接近之后，差异转向问题定义、数据构造、产品形态和组织执行。随后，姚顺宇用自己的物理训练经历解释为什么他偏好困难问题、为什么重视实验验证，最后落到组织与集体主义：现代大模型已经太复杂，单个英雄很难独立推动系统级跃迁。

1.1 章节地图

时间段	原视频章节	本笔记处理重点
00:00–00:07	两个 Shunyu Yao	嘉宾履历、物理转 AI、两位同名研究者的差异
00:07–00:25	竞争与逃逸	benchmark 同质化、模型差异从能力转向行为定义
00:25–00:35	Pre-train 没有到头	scaling law、数据墙、预训练学习能力
00:35–00:54	Coding 的爆发	agentic coding、长程任务、产品 wrapper 与模型壁垒
00:54–01:08	蒸馏与机器人	硬蒸/软蒸、资源劣势下的中国模型策略、机器人机会
01:08–01:52	物理经历	非厄米系统、高能物理、物理训练对 AI 实验观的影响
01:52–02:41	Anthropic	Claude 训练、top-down 机制、产品化与 Claude Code
02:41–03:01	Gemini	ML coding、long horizon、有限训练与近似无限使用
03:01–03:48	预测、组织、集体主义	neo lab、C 端产品、TPU/GPU、AI 研究员素质、个人英雄主义之后

1.2 本章小结

本期访谈最重要的信号不是“某家公司更强”，而是前沿模型训练已经进入一个更难外部观察的阶段：公开指标差距缩小，真实差异藏在数据、评估、行为定义、工具使用、长期任务和组织执行里。理解这期访谈，关键是把它当作“AI 工程组织如何在高不确定性下做 bet”的案例。

2 从 benchmark 竞争到问题定义竞争

姚顺宇认为，2026 年初的前沿模型格局已经不再是简单的“谁追不上谁”。Gemini、OpenAI、Anthropic 这几家在公开 benchmark 上的差距明显收窄，SWE-bench、AIME、IMO 等指标仍有参考价值，但很多时候一两个百分点已经接近噪音，而不是稳定信号。模型的真实差异更多体现在用户

体验：Claude 在通用工具使用和 agent 上仍然强，Codex 在纯 coding 方向缩小差距，Gemini 在纯 reasoning 和日常使用上有优势，但这些差异不一定能被单一公开分数捕获。



图 2: 谈到模型实验室竞争时，访谈把“纸面 benchmark”与“真实用户体验”区分开来。²

读图：benchmark 讨论应看什么

这张图没有曲线或表格，重点是把读者带回访谈现场：这一段正在从公司竞争切到评估方法。真正要比较的是三层信息：公开榜单、内部评估、真实用户体验；画面只证明该论述来自原视频对应区间。

核心判断：差异从“能不能做”转向“要它怎么做”

早期模型差异表现为能力差异：谁更会推理、谁更会写代码、谁更会调用工具。当前前沿模型接近后，难点转向定义目标行为：什么才算好 agent，什么才算好 coding assistant，什么样的 long-horizon 行为值得优化。也就是说，竞争对象从单纯模型能力转向任务定义、数据构造、评估体系和产品反馈闭环。

²视频画面时间区间：00:16:20–00:16:55。本图用于标记讨论 benchmark 同质化的上下文。

2.1 术语消化：公开指标为何会失真

术语	解决的问题	访谈中的含义
SWE-bench	衡量模型修复真实软件 issue 的能力	当前强模型已接近高分区，一两个百分点差异未必代表真实产品体验差异。
AIME / IMO	数学推理 benchmark	能显示 reasoning 能力，但不能直接说明模型在工具使用、产品协作、长期任务中的表现。
Noise vs Signal	区分随机波动与稳定趋势	姚顺宇强调，公开榜单接近时，小差距更可能是噪音；要看内部评估和真实使用。
Behavior Definition	明确模型应当表现出的行为	当前核心难点：不是“模型会不会”，而是“应该怎样做才算对”。

不要把榜单分数当成完整能力画像

榜单通常压缩了任务、数据分布、评分规则和失败模式。当前模型实验室的竞争越来越像“高维行为优化”：同样 80% 的 SWE-bench 分数，可能对应完全不同的交互体验、工具调用策略、失败恢复能力和用户信任感。

2.2 为什么意愿曾经决定能力差异

访谈中反复出现一个词：意愿。姚顺宇说，过去模型能力差异很大程度来自公司愿不愿意把资源投向某类能力。Claude 长期重视 tool use 和 coding，OpenAI 一段时间重视 reasoning，这些选择都会影响 infra、数据、评估和训练管线。前沿模型训练不是只靠一个算法想法，而是靠持续投入把行为目标变成可训练的数据和可追踪的指标。

数据不是中性资源

姚顺宇举了一个很有意思的例子：早期模型写代码好，部分原因可能不是大家预先设计了多么高级的 coding pipeline，而是互联网中的 GitHub 数据天然比普通网页质量更高。也就是说，模型行为有时来自数据分布中的隐性偏置；研究者事后才理解“为什么它学会了这个”。

2.3 本章小结

模型竞争进入新阶段后，公开 benchmark 仍重要，但不再足以解释全部差异。前沿实验室真正竞争的是：谁能更好地定义任务、构造数据、搭建评估，并把这些转化成稳定的模型行为。

3 “Pre-train 没有到头”：scaling law 与数据墙

当主持人问模型进步速度是否放缓时，姚顺宇明确回答“完全没有”。他的理由不是某个 benchmark 还在涨，而是作为研究员的体感：模型学习东西的能力变强了。以前让模型学会某件事需要很多技巧，现在更重要的是把问题定义清楚、构建合适数据和环境，剩下很多事情会“顺其自然”。



图 3: “Pre-train 没有到头” 章节: 访谈把模型进步放缓与 benchmark 饱和分开讨论。³

读图：预训练章节的视觉证据

画面仍是双人访谈，说明这里没有官方幻灯片或公式板书。阅读时应把 “Pre-train 没有到头” 理解为口头判断，需要结合后文的 scaling law、数据墙和用户体验讨论，而不是把单帧画面当作实验证据。

核心判断：benchmark 饱和不等于能力增长停止

如果指标上限是 100%，越接近上限，月度增长自然变慢。但用户体验的增长不一定线性对应 benchmark 分数。从 70% 到 75% 可能比从 50% 到 60% 更有体感，也可能在某些任务上没有体感。真正的问题是：模型是否仍能通过更好的预训练、数据和环境获得新的泛化能力。

3.1 scaling law 的三种 “到头” 含义

姚顺宇把 “预训练到头” 的可能原因拆成几类。第一，规律本身可能有适用范围，无法无限延展。第二，规律需要的某个条件无法满足，例如高质量数据不够。第三，外部观察者可能只看到某类指标饱和，却误以为底层学习能力饱和。

³视频画面时间区间：00:30:10–00:30:38。该帧来自预训练章节中段，用于定位讨论场景。

“到头” 说法	真实含义	应如何验证
规律适用范围到头	scaling law 不再外推	需要跨规模实验，而不是单点 benchmark 观察。
数据墙	高质量数据无法继续扩展	要看数据治理、合成数据、环境数据、交互数据能否补足。
指标饱和	某个公开测试接近上限	要换更难、更真实、更贴近产品的评估。
体验边际下降	用户不再感到显著提升	要分析任务分布，而不是只看平均分。

预训练在这里不只是“继续喂文本”

访谈中的 pre-training 指向更宽泛的底座学习能力。它包括模型从大规模数据中学到世界知识、代码结构、语言模式、任务先验和抽象能力。后训练、工具使用、强化学习和环境数据会改变模型行为，但底座的学习能力仍决定了很多上限。

“数据墙”不是一句口号

说数据撞墙，至少要回答三件事：哪类数据撞墙，质量定义是什么，替代数据或环境反馈是否真的不可用。姚顺宇的态度是：未来几个月看不到预训练到头的迹象，但这不等于 scaling law 可以无限外推。

3.2 本章小结

预训练是否到头，不能只看公开榜单。姚顺宇的判断强调“模型学习能力”仍在增强，而下一阶段更依赖问题定义、数据构造和环境设计。scaling law 的争论本质上是对可扩展资源、数据质量和评估边界的争论。

4 Coding 的爆发：从写代码到长程代理

访谈中最密集的技术讨论之一，是 coding 与 agentic workflow 的爆发。姚顺宇认为，OpenClaw 一类产品在技术上并不令人惊讶，因为相关能力在更早的 Claude/Opus 阶段已经可以展示；它真正的价值是让更多人意识到：可以让模型控制多个工具、调用多个模型、聚合结果，并完成很长的 long-horizon 任务。



图 4: Coding 爆发章节：讨论 OpenClaw、Manus、agentic coding 与模型能力自然外溢。⁴

读图：coding 爆发的证据类型

本节图像用于时间定位，不展示 OpenClaw 或 Manus 的界面。有效证据来自访谈中的因果链：模型工具使用能力已经具备、产品把可能性展示出来、长程任务共识被触发。不要把人物帧误读为产品截图。

从代码补全到 long-horizon agent

早期 coding 模型主要生成一段代码；agentic coding 则要求模型理解代码库、规划多步修改、运行测试、解释错误、回滚或修复，并在长时间上下文中保持目标一致。能力差异不只在“不会写函数”，而在工具调用、状态管理、错误恢复和任务收敛。

4.1 Manus、OpenClaw 与 wrapper 的壁垒问题

姚顺宇没有把 Manus 与 OpenClaw 的差异解释成清晰的技术代际。他更关注一个商业问题：如果 wrapper 没有自己的模型壁垒，长期生存会很难。当前很多壁垒仍在模型侧；产品侧是否能形成数据飞轮，还没有被证明。除了 agentic coding，他认为真正 AI-native 且已成功的场景并不多。

什么是 AI-native 场景

AI-native 场景不是“把 AI 加到旧产品里”，而是任务形态本身因为模型能力而改变。Chatbot 可看作搜索的交互式扩展；agentic coding 则更接近新形态，因为它把写代码、运行环境、调试、测试和项目管理连成一条工作流。

⁴视频画面时间区间：00:42:57-00:43:25。该帧对应 coding 产品形态讨论的中段。

4.2 产品经理为什么暂时难被替代

访谈中对 Claude Code、Cowork 等产品的讨论，指向一个重要判断：AI 产品经理的价值不再只是按钮摆放和 feature 排序，而是理解“人如何与 AI 协作”。好的产品形态会改变交互方式，就像短视频改变内容消费，Claude Code 改变软件工程入口。

不要把 wrapper 一概看低

“wrapper 没有壁垒”是市场常见说法，但并不意味着所有 wrapper 都无价值。真正的问题是：它能否形成 workflow 锁定、数据反馈、用户习惯、团队执行和模型侧深度集成。没有这些，wrapper 容易被模型公司吸收；有这些，就可能变成新入口。

4.3 本章小结

Coding 的爆发不是单点模型能力提升，而是模型能力、工具链、评估、环境和产品形态共同成熟的结果。OpenClaw/Manus 的讨论说明：产品展示可能比技术突破更早触发大众共识，但长期壁垒仍取决于模型、数据和工作流闭环。

5 蒸馏、资源劣势与中国模型公司的机会

谈到中美模型差距时，姚顺宇认为过去一年到一年半 gap 在缩小，但能否完全弥合甚至反超仍不确定。他特别提到，中国模型公司在算力资源上处于劣势，这种劣势可能逼出一些有趣策略，其中之一就是 distillation。



图 5: 蒸馏章节：讨论“硬蒸”和更聪明的蒸馏方式。⁵

⁵ 视频画面时间区间：00:59:30–01:00:00。该帧对应硬蒸/软蒸的讨论场景。

读图：蒸馏段落如何使用画面

画面只能说明时间来源，不能说明蒸馏方法细节。蒸馏的技术信息需要读相邻表格：硬蒸、软蒸、环境蒸馏和自我蒸馏的区别在训练信号，而不是在视觉元素。

5.1 硬蒸与软蒸

姚顺宇把蒸馏分成粗糙的“硬蒸”和更有科学含量的蒸馏。硬蒸就是直接拿大模型生成 token 强行训练，既有商业伦理问题，也显得智力上贫乏，因为它说明团队不知道自己真正想优化什么。更聪明的蒸馏则可能围绕能力迁移、偏好学习、数据生成、任务定义展开：不是抄答案，而是用强模型帮助构造更好的训练信号。

类型	做法	风险/价值
硬蒸	直接收集强模型输出 token 做训练	法务和伦理风险高；容易学表面答案，缺少行为目标。
软蒸	利用强模型辅助生成任务、反馈、解释或偏好信号	更接近科学问题：如何把能力、过程和评估迁移到弱模型。
环境蒸馏	让模型在任务环境中产生轨迹，再筛选/评分	对 agent/coding 更有价值，但基础设施复杂。
自我蒸馏	用模型自身或同族模型迭代提升数据	可能形成闭环，也可能放大错误和模式崩塌。

蒸馏的本质不是复制答案，而是设计训练信号

如果不知道自己要什么，蒸馏会退化成抄输出；如果清楚目标行为，蒸馏可以变成数据工程和能力迁移工具。两者差异在于：是否有明确任务定义、评估标准和失败分析。

5.2 机器人为什么仍有机会

访谈中，姚顺宇对机器人实验室表达了比语言模型更强的兴趣，因为机器人仍有许多没有被做好的问题。语言模型已经不是蓝海；真正年轻的人如果想找机会，未必应该追逐最热方向，而应该找“没人做到好”的方向。机器人、多模态生成、量子调控等都可能是更蓝海的空间。

资源劣势可能改变研究品味

当算力不能无限堆，团队会被迫重视效率、蒸馏、数据选择、训练信号和产品落地。资源劣势不是优势本身，但可能促使不同路径出现。中国模型公司的机会，可能正来自这种路径差异。

5.3 本章小结

蒸馏不是一个简单的“偷不偷”问题，而是训练信号设计问题。硬蒸风险高且暴露目标缺失；软蒸和环境蒸馏则可能成为资源受限团队提升能力的重要路线。

6 物理训练如何塑造 AI 研究品味

姚顺宇的物理经历不是访谈的花絮，而是理解他研究判断的重要背景。他本科做凝聚态理论，后来做理论高能、量子信息与黑洞相关方向。谈到非厄米系统时，他强调本科时期的研究和现在做 AI 有相似性：先有一个理解或想法，再设计数值实验验证，最后把想法落实成 pipeline。



图 6: 物理经历章节：从凝聚态、非厄米系统到 AI 实验方法。⁶

6.1 非厄米系统的直觉版解释

在普通量子力学里，哈密顿量通常是厄米的，这保证能量本征值是实数，系统演化保持概率守恒。非厄米系统则常用来描述开放系统、耗散、增益、测量或有效动力学。对 AI 笔记读者来说，不必深入物理细节，但要理解它训练出的研究习惯：面对复杂系统时，先构造可检验模型，再用数值实验逼近理解。

从物理到 AI 的迁移

物理训练强调：定义问题、建立简化模型、设计实验、观察异常、修正理论。大模型训练也类似：提出行为假设，设计数据和训练 pipeline，用实验观察 loss、benchmark、用户行为和失败案例，再回到假设。差异在于，AI 系统更工程化、更依赖组织协作。

6.2 “挑战不擅长的事”

访谈中，姚顺宇多次说自己喜欢挑战不擅长的事。离开物理并不是因为物理无趣，而是他觉得自己在那个方向已经看到很多比自己聪明的人，也想去挑战一个新领域。这个选择解释了他后来去 Anthropic、再去 Gemini 的动机：不是追求头衔，而是寻找能迫使自己学习新东西的环境。

⁶视频画面时间区间：01:28:25–01:28:55。该帧用于标记物理背景讨论。

不要把跨界神话化

从物理转 AI 并不自动意味着“降维打击”。姚顺宇反而多次说 AI 不一定需要最抽象的聪明，而需要靠谱、细致、负责。跨界带来的价值主要是研究品味和实验习惯，而不是天然优越感。

6.3 本章小结

物理背景给姚顺宇提供的是一种处理复杂系统的方式：从想法到实验，从实验到理解，再到 pipeline。这个方法迁移到 AI 后，表现为对问题定义、数据构造和实验验证的重视。

7 Anthropic: top-down 机制、Claude 训练与产品化

在 Anthropic 的经历是访谈中最重要的职业段落。姚顺宇谈到 Anthropic 的独特性：它能实行相对 top-down 的机制，这对其他模型公司很难。原因不只是组织文化，也和技术领导、项目聚焦、产品方向与模型训练之间的耦合有关。



图 7: Anthropic 章节：讨论 Claude 训练、组织机制与产品化。⁷

7.1 Claude 3.7/4.5 与工具使用能力

访谈涉及 Claude 3.7、4.5 等模型训练，但很多细节因公司保密无法展开。可提炼出的关键点是：Anthropic 对 tool use、coding 和工作流产品化有长期投入，后续 Claude Code、Cowork 等产品把模型能力转成了工作效率入口。

⁷ 视频画面时间区间：02:14:38-02:15:05。该帧来自 Anthropic 训练经历讨论的中段。

模型能力需要产品出口

如果模型能力不能被产品形态释放，外部用户感知不到；如果产品形态没有模型能力支撑，也难以形成长期壁垒。Anthropic 的案例说明，前沿模型公司需要同时理解训练、评估、工具链和用户 workflows。

7.2 top-down 为什么难复制

姚顺宇认为，Anthropic 的 top-down 机制很独特，OpenAI 和 Gemini 都不容易照搬。大公司和 startup 的打法不同：startup 需要 make bet，敢押注；大公司资源更多但流程复杂。top-down 的优势是能把方向、资源和执行统一起来，风险是如果判断错，整个组织会一起走偏。

组织类型	优势	风险
Startup	决策快，敢押注，方向统一	资源少，容错率低，壁垒不足时容易被收购或复制。
大公司	资源、算力、人才和基础设施强	流程长，方向多，难以形成一致 bet。
Anthropic 式 top-down	能把模型训练、产品和安全方向集中推进	依赖技术领导判断，错误方向代价高。

7.3 产品经理的新角色

访谈对 Claude Code 的讨论很有意思：好的 AI 产品经理不只是传统意义上的 feature 经理，而是懂得如何设计人与 AI 协作的界面。Claude Code 的价值在于，它让模型嵌入真实开发循环：读代码、改代码、跑测试、解释错误、继续迭代。

AI 产品不是“把模型接进去”

AI 产品化的核心是重写交互方式。聊天框是搜索的交互升级；Claude Code 是软件工程循环的交互升级；未来的 Cowork 类产品可能是协作办公的交互升级。产品经理需要理解模型边界、失败模式、上下文管理和用户信任。

7.4 本章小结

Anthropic 的案例说明，前沿模型竞争不能只看模型本身。组织能否快速押注、产品能否释放能力、技术领导能否处理训练与 workflow 之间的耦合，都会影响模型公司的外部表现。

8 Gemini: ML coding 与 long horizon

加入 Google DeepMind 后，姚顺宇的工作重心转向 ML coding 和 long horizon。ML coding 指向一个更激进的目标：让 AI 参与甚至部分完成“训练 AI”的流程，包括选择数据、设计反馈信号、构建训练/评估 pipeline。long horizon 则指模型在很长任务中保持目标、状态和上下文一致。



图 8: Gemini 章节：讨论 ML coding、long horizon 与训练有限但使用近似无限。⁸

读图：long horizon 章节的关键不是画面，而是任务结构

这张帧对应 ML coding 与 long horizon 的讨论。读者应把注意力放在后面的表格：状态压缩、任务分解、环境反馈、记忆/检索。图像提供可追溯时间点，表格才提供概念拆解。

train with finite, use as infinite

访谈中的一句关键口号是：用有限 context 训练，但在使用时接近无限。它不一定意味着单次训练样本无限变长，而是让模型在有限上下文中学会压缩、选择、遗忘、检索和延续，从而完成远超训练窗口长度的任务。

8.1 long horizon 的技术问题

长程任务的难点不只是上下文长度。真正的问题包括：哪些信息该保留，哪些信息该丢弃，如何从过去状态恢复目标，如何避免早期错误滚雪球，如何把长期任务拆成可验证子任务，以及如何评估“坚持目标”而不是只评估单步答案。

问题	机制	失败模式
状态压缩	把历史交互摘要成可用记忆	丢掉关键约束，导致后续偏航。
任务分解	把长期目标拆成短期可验证步骤	子任务正确但总体目标错误。
环境反馈	用运行结果、测试、用户反馈修正行为	反馈稀疏或噪声大，模型学错。
记忆/检索	从外部存储取回相关信息	检索到相似但错误的信息。

⁸ 视频画面时间区间：02:51:43-02:52:15。该帧来自 Gemini 工作重心讨论中段。

8.2 ML coding: 让 AI 训练 AI

姚顺宇提到的 ML coding，不只是让模型写普通业务代码，而是让模型参与训练系统本身。它要处理数据选择、反馈信号、训练基础设施、实验记录、评估和 failure analysis。这个方向如果做成，会改变研究员的工作方式：研究员从手写所有实验逻辑，转向设计目标、约束、检查和评估。

AI 自训练不是自动驾驶研究所

让 AI 参与训练 AI，并不等于完全放手。姚顺宇后面提到的面试题也说明：如果候选人全盘交给 AI，却不能解释 AI 做了什么，讨论环节会露馅。未来研究员的价值在于与 AI 协作、理解产物、校验结果，而不是盲目信任输出。

8.3 本章小结

Gemini 章节的核心是两个方向：ML coding 和 long horizon。前者让 AI 参与模型训练流程，后者让模型在长任务中保持目标和状态。二者共同指向更自主的 AI 工作流，但都依赖精细的数据、反馈和评估设计。

9 组织、产品与中美差异

访谈后半段从技术转向组织和产品。姚顺宇对 neo lab 潮流并不乐观，认为大多数都会死，除非有真正好的人和清晰方向。谈到中国与美国的产品差异时，他认为美国过去十年更擅长 ToB、enterprise 和效率软件，因为这些市场直接且利润高；中国更擅长复杂 C 端产品，把广告、直播、电商、内容和分发转成隐性的利润飞轮。



图 9: 组织与产品章节：讨论 neo lab、C 端产品、美国 enterprise 市场和中国复杂产品能力。⁹

⁹ 视频画面时间区间：03:12:57-03:13:28。该帧来自组织与产品讨论中段。

9.1 neo lab 的机会与死亡率

很多从模型大厂出来的团队会成立新实验室，但姚顺宇认为多数 neo lab 会死。原因是语言模型主线已经不是蓝海，基础设施、算力、人才、数据、评估、产品入口都越来越集中。除非团队在新方向上有真正差异化，否则很难与大模型公司竞争。

为什么“语言模型末班车已发车”

这句话不是说 AI 没机会，而是说最核心的语言模型主战场已经高度资本化、组织化和基础设施化。年轻研究者更适合寻找尚未被做好的方向，例如多模态生成、机器人、科学 AI、量子调控、长程 agent 等。

9.2 TPU 与 GPU 的组织含义

访谈里有一段硬件讨论：GPU 的优势在生态和小规模通用性，典型节点内 NVLink 互连很强；TPU 则更像为大规模集群设计，采用 3D Torus 等拓扑。如果 compiler 和 sharding 策略足够好，可以利用更大规模的结构。这里的 sharding 指把参数、激活、优化器状态或数据切分到多张加速卡上，使它们不必在每张卡完整复制；它既是内存策略，也是通信策略。这里的关键不是哪个硬件绝对更好，而是硬件形态会影响软件栈、组织能力和训练策略。

硬件路线	优势	代价
GPU	生态成熟，通用性强，小规模易用；节点内高速互联	大规模成本高，供应链和集群调度压力大。
TPU	为大规模训练优化，拓扑可扩展，Google 内部软件栈深度配合	通用生态弱，更依赖 compiler、sharding 和内部基础设施。

硬件不是孤立变量

TPU/GPU 选择背后是组织能力选择：谁能写 compiler，谁能设计 sharding，谁能调度大集群，谁能把模型、数据和硬件一起优化。硬件优势必须通过软件栈和组织执行释放。

9.3 本章小结

组织与产品讨论把技术竞争放回现实：模型公司不是论文团队，而是基础设施、产品、组织、市场和人才系统。neo lab 的生存、C 端产品的复杂度、硬件路线的选择，都取决于这种系统能力。

10 “AI 本质是简单的”：靠谱、细致与负责

姚顺宇在访谈中有一个很有争议但值得认真理解的判断：AI 这件事“不太需要脑子”，最重要的素质是靠谱、做事细、对自己做的事负责。这不是说 AI 没有难题，而是说当前大模型训练中的许多工作不是靠孤立灵感，而是靠把大量细节做对。



图 10: 结尾章节：讨论 AI 研究员素质、个人英雄主义结束与集体主义胜利。¹⁰

读图：结尾帧与论证边界

结尾帧对应“个人英雄主义之后”的口头判断。它支持的是来源定位，不支持统计意义上的行业结论；行业判断仍需结合组织、硬件、产品和训练系统的多段论述。

10.1 24 小时强化学习面试题

他举了一个面试题：让候选人在 24 小时内从 0 到 1 完成一个强化学习项目，可以使用 AI。这个题不再考“你能不能手写所有代码”，而是考三件事：能不能有效利用 AI，能不能理解 AI 生成的系统，能不能在讨论中解释设计选择和失败原因。

未来研究员的核心能力

未来研究员不一定是写最多代码的人，而是能定义问题、调度 AI、理解产物、检查细节、承担结果的人。AI 降低了实现门槛，但提高了验证和责任门槛。

10.2 个人英雄主义之后

姚顺宇说，自己进入 AI 行业时，个人英雄主义时代已经结束了。这并不是否认历史上的英雄人物：Hinton、Transformer 论文团队等都曾起到关键作用。但今天的大模型系统太大，数据、算力、训练、后训练、产品、安全、基础设施全部耦合，单个英雄很难独立完成系统性突破。真正的英雄更可能是“英雄集体”。

¹⁰ 视频画面时间区间：03:36:16-03:36:48。该帧来自结尾关于行业素质和集体主义的讨论。

集体主义不是平均主义

这里的集体主义不是说个人不重要，而是说重要个人必须嵌入组织系统。技术领导者仍然关键，但他的价值在于能下场救火、理解别人工作、容纳不同专业，并把组织运行成一个能持续解决问题的系统。

“不需要脑子” 容易被误读

这句话不是反智，而是反对把 AI 神秘化。许多工作确实是本科生也能做的工程与实验，但难在长期可靠、细致、负责地做对，并在复杂系统里理解因果关系。聪明不是不重要，而是不再足够。

10.3 本章小结

结尾的核心判断是：AI 行业进入系统工程时代。个人灵感仍有价值，但不能替代组织执行、工程细节和责任感。最稀缺的人，未必是最会讲宏大概念的人，而是能把模糊目标变成可验证系统的人。

11 总结与延伸

11.1 speaker closing: 从英雄到系统

访谈的最后，姚顺宇谈到自己没有太多 AI 行业内的偶像，因为他进入这个行业时，个人英雄主义时代已经过去。他承认早期 AI 和物理中都有英雄人物，例如 Hinton 或 Transformer 团队，但今天的前沿 AI 更像集体主义工程。一个人可以发起方向、推动产品、修正路线，但真正的模型进步需要数据、算力、训练系统、评估、产品和组织共同配合。

11.2 本笔记的核心提炼

1. 模型能力没有简单停滞，预训练是否到头不能只看公开 benchmark。
2. 前沿模型差异正在从“能力高低”转向“行为定义、数据构造和产品体验”。
3. Coding 爆发的关键不是代码补全，而是长程 agent 工作流。
4. 蒸馏的价值取决于训练信号设计；硬蒸只是低级复制。
5. Anthropic 的启示是 top-down 技术组织与产品化协同；Gemini 的启示是大规模横向资源和 long-horizon 方向。
6. 未来研究员需要会用 AI，但更要理解 AI 产物、检查细节并承担责任。
7. AI 的下一个蓝海未必是语言模型主线，而可能在机器人、多模态、科学 AI、长程任务和新产品交互中。

11.3 拓展阅读

- OpenAI scaling laws 与 Chinchilla scaling laws: 理解“预训练是否到头”的两类历史背景。
- SWE-bench 与 agentic coding 评估: 理解 coding benchmark 为什么会接近饱和但产品体验仍有差异。
- Transformer、seq2seq、scaling law、tool use agent 相关论文: 理解访谈中提到的影响 AI 进程的关键技术脉络。

最后的判断

这期访谈最值得带走的一句话，不是“AI 不需要脑子”，而是“AI 需要靠谱、细致和负责”。当模型能力越来越强，实现变得更容易，真正的稀缺能力会转向定义问题、验证系统、组织协作和承担结果。