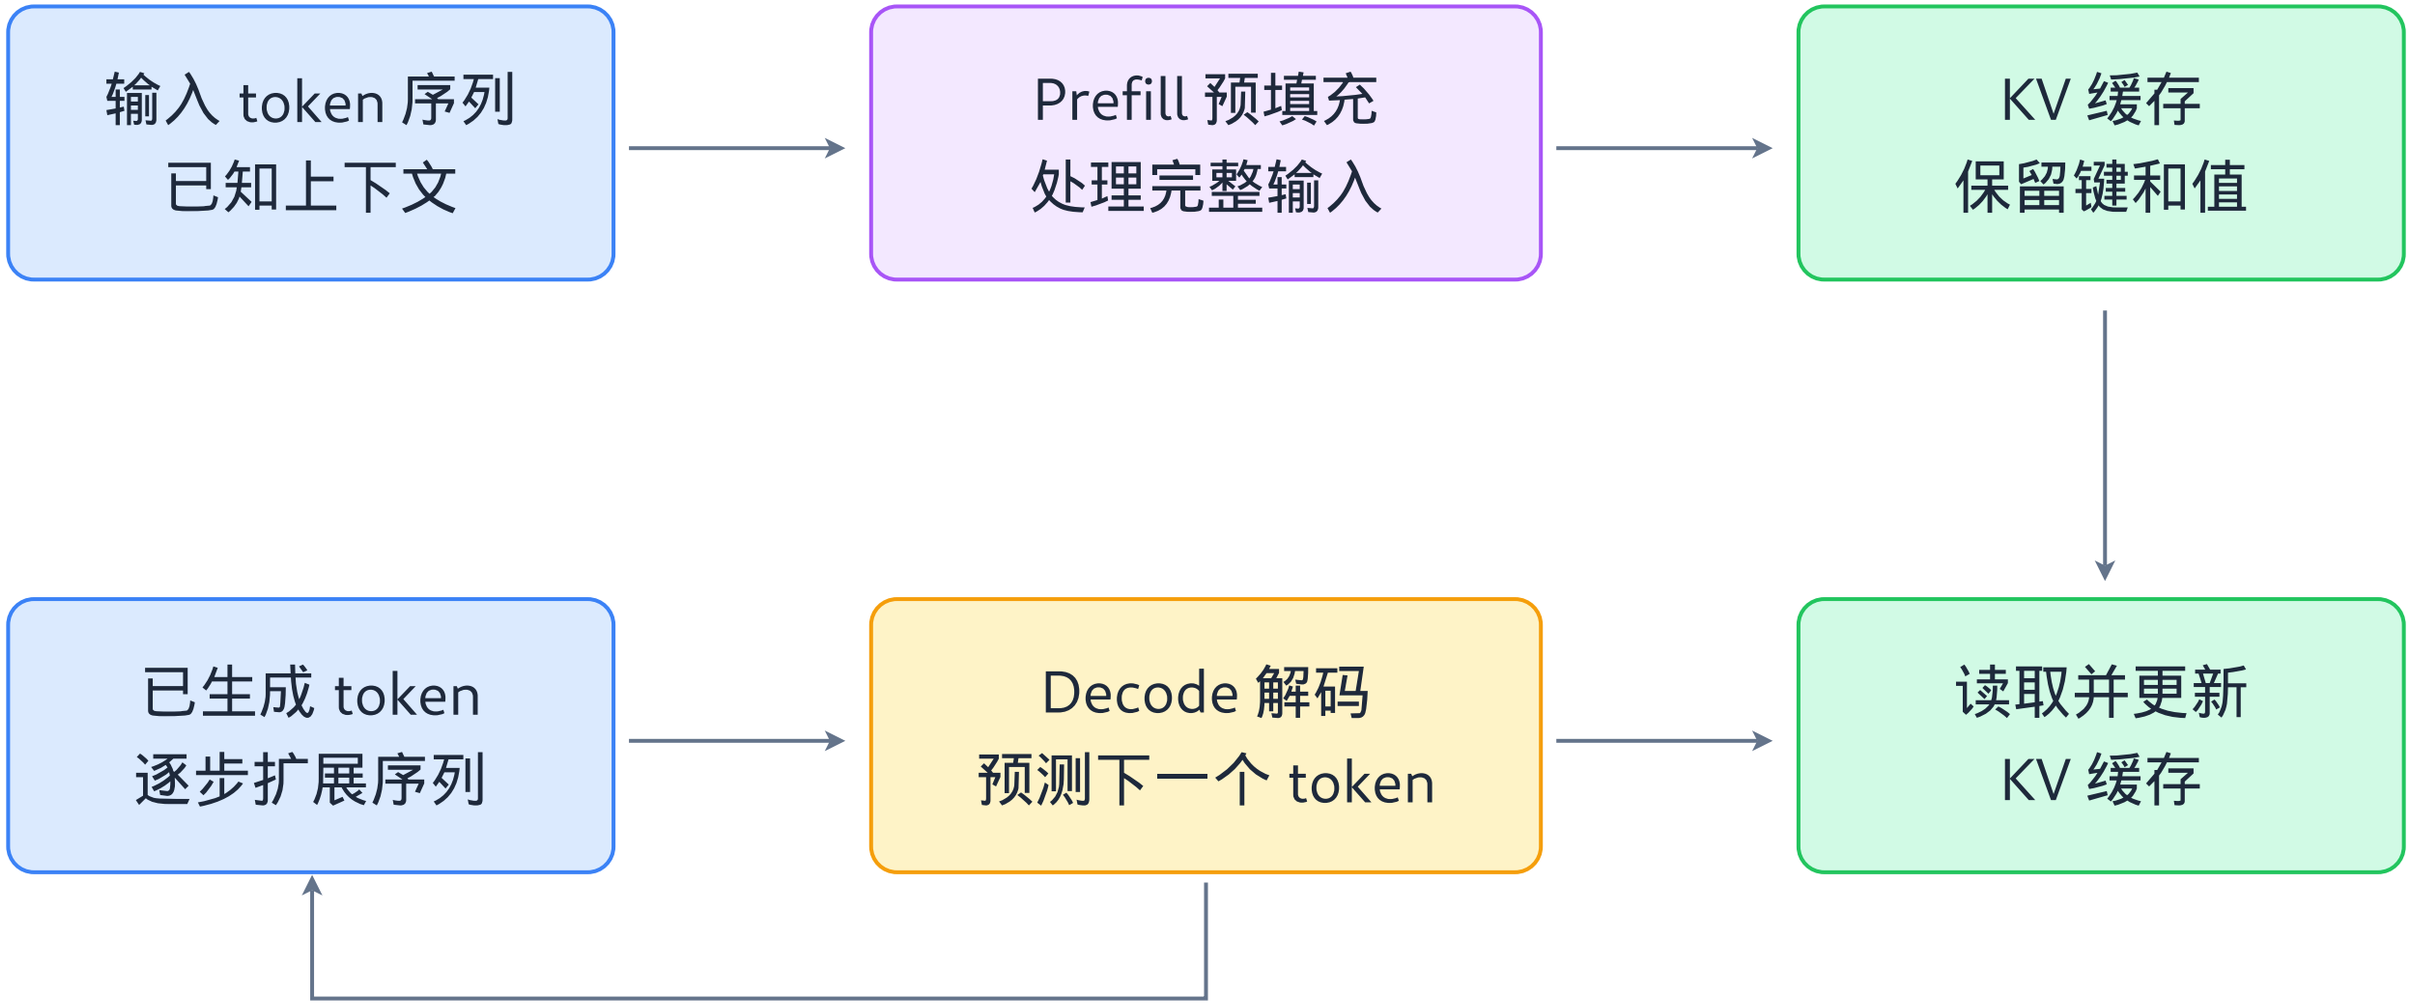预填充与解码使用同一模型的不同方式