

深度访谈教学笔记

# 多模态研究十年史、o1 启发与下一个 GPT-4 时刻

Zhang Xiaojun Podcast: 李广密 co-host 对话张祥雨

基于公开视频、章节结构、转写稿、视频描述与自制概念图整理

2025-06-03



视频标题: 102. 和张祥雨聊, 多模态研究的挣扎史和未来两年的 2 个 “GPT-4 时刻”

视频频道: Zhang Xiaojun Podcast

视频时长: 02:28:44

视频链接: <https://www.youtube.com/watch?v=vWrYHvSRz0s>

素材说明: YouTube 未暴露可下载字幕; 正文基于 faster-whisper large-v3 CPU int8 分块转写、视频描述、章节结构和自制教学图整理。固定访谈画面不在正文重复使用。

项目主页: <https://github.com/hqh1025/ai-course-notes>

# 目录

- 1 导读：这期为什么是多模态技术路线课 2
  - 1.1 阅读路线 3
  - 1.2 本章小结 3
- 2 CV 的十年学习史：从模型 scaling 到 NLP 范式迁移 3
  - 2.1 静态图像为什么不是自然语言 4
  - 2.2 本章小结 5
- 3 生成与理解为什么没有真正融合 5
  - 3.1 生成可控性的根本问题 6
  - 3.2 本章小结 7
- 4 Next Token Prediction 的缺陷：压缩不等于计算精度 7
  - 4.1 特征坍塌：高概率特征与精确约束的冲突 8
  - 4.2 本章小结 9
- 5 o1 的启发：RL、CoT 与反思 pattern 9
  - 5.1 Critical Decision：一个 token 解决不了的地方 10
  - 5.2 本章小结 11
- 6 视觉 Long CoT：把慢思考搬进视觉空间 11
  - 6.1 为什么生成也需要 CoT 12
  - 6.2 两条腿：预训练语料与动作空间 13
  - 6.3 研究路线时间线 13
  - 6.4 本章小结 14
- 7 Long Context、多模型协作与在线学习 14
  - 7.1 为什么架构不是本质 15
  - 7.2 在线学习与自主学习 16
  - 7.3 世界模型与机器人抢跑 17
  - 7.4 本章小结 18
- 8 总结与延伸 18
  - 8.1 术语总表 18
  - 8.2 后续观察问题 19
  - 8.3 拓展阅读 19

## 1 导读：这期为什么是多模态技术路线课

本节先建立阅读框架。这期是张小珺商业访谈录里少见的高技术密度访谈，李广密作为 co-host，把问题集中在多模态十年史、视觉与语言的差异、o1 范式对多模态的启发，以及未来两年可能出现的 GPT-4 时刻。张祥雨的叙述不是一组论文八卦，而是一条技术路线：CV 曾经持续向 NLP 学习，但静态图像本身和自然语言不同；多模态真正的突破，可能要从 next token prediction、RL、CoT、动作空间和在线学习重新理解。

### 本期核心命题

多模态的难点不只是“把图像、视频和文本放进一个模型”。静态图像里生成、理解和人类对齐天然分离；视觉生成与视觉理解长期没有真正融合；o1 之后，研究者开始意识到：多模态也可能需要思维链、反思、动作空间扩展和环境反馈，才能出现真正的 GPT-4 时刻。

### 视觉策略说明

本视频是固定访谈画面，没有 slides 或屏幕演示。正文只使用封面作为来源识别；正文图像全部为自制概念图，用来解释 CV/NLP 迁移史、静态图像三重割裂、生成理解 gap、next token 缺陷、RL/CoT、视觉 Long CoT、long context 多模型协作和在线学习。



图 1: CV 向 NLP 学习的历史：从 ImageNet/ResNet 到 ViT、iGPT、MIM 与多模态大模型。自制概念图，依据 00:02:00–00:17:14 对谈内容整理。

### 读图：CV 的 GPT 时刻没有简单复制 NLP

图中从 ImageNet、ResNet 到 ViT/iGPT/MIM，再到 VLM，展示的是 CV 不断借鉴 NLP 范式的过程。关键问题是：迁移架构容易，迁移数据属性和目标函数很难。语言数据天然来自人

类表达，静态图像却不天然包含人类理解。

## 1.1 阅读路线

为了避免被术语淹没，本节给出读这期的四个问题。第一，为什么 CV 向 NLP 学了十年，却没有在静态图像上复刻 GPT？第二，为什么图像生成和图像理解放进一个系统后仍然像两个模型？第三，为什么大模型越大，文科和对话能力更强，但数学推理可能会跳步、退化？第四，为什么 o1 的反思和 CoT pattern 会让多模态研究重新看到路？

| 阅读问题          | 访谈中的材料                  | 要形成的判断              |
|---------------|-------------------------|---------------------|
| CV 为什么难复制 GPT | 静态图像、生成/理解/对齐割裂         | 数据形态决定学习目标，不能只迁移架构。 |
| 多模态为何未融合      | 理解模型和生成模型各自变强但互不增益      | 缺少共同的思考过程和可控动作空间。   |
| 推理为何会退化       | 大模型数学跳步、next token 压缩缺陷 | 分布压缩不等于计算精度。        |
| 未来突破在哪里       | RL、CoT、视觉 Long CoT、在线学习 | 关键在动作空间、反馈和持续学习。    |

## 1.2 本章小结

EP102 的主线是：多模态不是“多加一种输入”这么简单。要理解未来两年的 GPT-4 时刻，必须同时理解静态图像数据的特殊性、语言模型目标函数的缺陷、o1 引入的反思模式，以及在线学习对下一代 Agent 的意义。

# 2 CV 的十年学习史：从模型 scaling 到 NLP 范式迁移

上一章建立问题，本章回到历史。张祥雨把自己的早期学术主线放在 2012 年后的深度学习 scaling 上：ImageNet 提供大数据，CUDA/GPU 提供算力，AlexNet 证明模型扩大可以显著提升效果，随后 ResNet 等工作进一步打开深层视觉网络。这个阶段的核心是 model scaling：让视觉模型更深、更大、更可训练。

后来 NLP 的 Transformer、BERT、GPT 成为新范式，CV 社区开始把这些方法迁移过来。ViT 把 Transformer 放进视觉；iGPT 尝试像语言一样自回归建模图像；MIM 和对比学习试图通过遮蔽、增强和不变性学习视觉表征。但张祥雨的判断是，许多方法只是把 NLP 的外形搬到了 CV，未必解决静态图像的根本差异。

## 术语消化: CV 向 NLP 学了什么

| 术语                   | 机制                            | 本期中的意义                    |
|----------------------|-------------------------------|---------------------------|
| ImageNet             | 大规模标注图像数据集                    | 让视觉模型第一次有稳定 scaling 数据基础。 |
| ResNet               | 残差连接支持深层网络训练                  | 证明视觉 model scaling 可行。    |
| ViT                  | 把图像切成 patch, 用 Transformer 建模 | 架构迁移成功, 但不等于目标函数迁移成功。     |
| iGPT/MIM             | 自回归或遮蔽式图像建模                   | 试图复刻语言建模, 但受图像数据属性限制。     |
| Contrastive Learning | 通过增强视图学习不变性                   | 很依赖人为设计的 augmentation。    |

### 课堂提示: 不要把“用了 Transformer”当作 GPT 时刻

张祥雨的提醒是, 架构只是大方向。ViT、MIM、iGPT 让 CV 学到 NLP 的工具, 但静态图像是不是能用同一套目标函数学出生成、理解和对齐, 才是真问题。

## 2.1 静态图像为什么不是自然语言

本节进入第一条关键论证。自然语言语料本身是人类生成的, 它已经把人类概念、意图、语义和对齐关系写进 token 序列。GPT 在语言上做生成建模时, 生成能力、理解能力和人类对齐能在同一目标里相互增强。静态图像则不同: 图像是自然世界和成像系统产生的, 它不因为人类如何理解而改变。

这就导致三个能力在图像上天然割裂。生成图像可以学像素分布; 理解图像需要引入人类语义; 人类对齐需要标签、caption、问答、偏好或任务定义。即使模型能生成逼真图像, 也不代表它理解场景; 即使模型能理解图像, 也不代表它能控制生成过程。

## 静态图像的三重割裂

生成、理解和人类对齐在静态图像中天然分离




图 2：静态图像的三重割裂：生成、理解和人类对齐在静态图像中天然分离。自制概念图，依据 00:18:22–00:24:23 对谈内容整理。

### 读图：图像在那里，理解是人加进去的

图中心是 Image，周围是生成、理解、对齐、自然和任务。读这张图时要抓住一句话：图像不天然等于人类语义。杯子、桌子、动作和空间关系需要人类任务框架注入，不能只从像素分布里自动得到 GPT 式语义统一。

## 2.2 本章小结

CV 的十年进展说明，数据、算力、架构和 scaling 都很重要；但它也说明，视觉不是语言的简单替身。静态图像把生成、理解和对齐拆开，多模态必须先处理这个数据形态差异。

## 3 生成与理解为什么没有真正融合

上一章解释静态图像的根本差异，本章看张祥雨在多模态系统里的实际挫折。他曾试图把图像生成、图像理解、文字生成和文字理解放进同一个系统：把图像 token 化，用语言式 Transformer 处理多模态，再接入 diffusion 等生成模块。结果是，理解模型越来越强，生成模型也越来越强，但放在一起没有出现  $1+1 > 2$  的叠加效果。

最尖锐的证据是：把生成部分拿掉，理解能力并不受影响；把理解模型接到生成模型上，生成可控性仍然差。模型能识别某个视频违反物理常识，却无法阻止自己生成违反物理常识的视频。这说明两条分支还没有共享同一种内部思考过程。




图 3: 生成与理解未融合: 两个分支都变强, 但放在一起没有  $1+1$  大于  $2$ 。自制概念图, 依据 00:29:10–00:38:45 对谈内容整理。

**读图：系统连接不等于能力融合**

左边理解模型擅长看图、视频和语言对齐；右边生成模型擅长产生图像和视频。中间的 gap 不是工程接口，而是能力无法互相校正。真正的一体化，应当让理解约束生成，让生成过程反过来训练理解。

3.1 生成可控性的根本问题

本节把“可控性差”拆开。图像和视频生成模型可以学习高概率视觉模式, 但复杂场景需要遵守几何、物理、身份一致性、时间连续性和语义约束。语言提示并不总能把这些约束精确传入生成过程; 理解模型也不一定能把“这不合理”转成生成模型内部的可执行修正。

术语消化：生成、理解、对齐、可控性

| 概念  | 含义            | 本期中的问题            |
|-----|---------------|-------------------|
| 生成  | 产生图像、视频或文本    | 可能逼真，但不一定可控。      |
| 理解  | 识别对象、关系、动作和语义 | 可指出错误，但未必能指导生成。   |
| 对齐  | 与人类意图和评价一致    | 图像对齐依赖语言、偏好和任务定义。 |
| 可控性 | 按约束稳定生成目标结果   | 多物体、物理和时序约束最容易失败。 |

### 生成模型会“知道错”但仍然做错

这不是表面矛盾。判断一个结果是否错，和在生成过程中一步步避免错误，是两种不同能力。前者像批改，后者像规划和执行。多模态系统缺的，正是连接批改和执行的思考链路。

## 3.2 本章小结

多模态一体化的困难在于，理解和生成并不是接上线就能互相增强。它们需要共享可解释、可搜索、可纠错的中间过程；这正是后面 o1、CoT 和视觉 Long CoT 进入讨论的原因。

## 4 Next Token Prediction 的缺陷：压缩不等于计算精度

前面的问题发生在视觉，本章转向语言模型，因为张祥雨认为语言模型里也出现了类似的瓶颈。训练大模型时，他观察到一个怪现象：模型越大，通用对话、情商、知识量更强；但数学等局部推理能力可能先上升、后平缓，再继续扩大反而下降。一个线索是，大模型更倾向于“跳步”，不像小模型那样老老实实算。

他的解释指向 next token prediction。这个目标本质上是在建模数据分布，也可理解为压缩：模型越能预测下一个 token，就越能压缩语料。但压缩人类语料的分布，不等于在数学、逻辑、几何和物理任务上保持计算精度。人类语料中有大量跳步、直觉和省略，大模型压缩得越好，可能越学到这些捷径。

$$L_{\text{NTP}} = - \sum_t \log p_{\theta}(x_t | x_{<t})$$

其中， $x_t$  是第  $t$  个 token； $x_{<t}$  是此前上下文； $p_{\theta}$  是模型给出的下一个 token 概率； $L_{\text{NTP}}$  越低，说明模型越能拟合训练分布。但数学题要求的是步骤正确和结果正确，而不是输出分布看起来像互联网解答。



## Next Token Prediction 的缺陷

压缩分布不等于计算精度，越大会越倾向跳步



读图：从左到右看依赖关系；正文负责展开细节，图只保留骨架。

图 4: Next Token Prediction 的缺陷：压缩分布不等于计算精度，越大会越倾向跳步。自制概念图，依据 00:41:11–00:50:48 对话内容整理。

### 读图：shortcut 是分布学习的副作用

图中从 Data Distribution 到 Compression，再到 Shortcut、Math 和 RL。关键是 shortcut：如果训练分布里有大量省略步骤，模型会学到“像人类答案”的压缩，而不是“每一步都计算正确”的程序。

## 4.1 特征坍缩：高概率特征与精确约束的冲突

本节解释访谈里的“特征坍缩”。生成模型会偏向保留数据分布里最容易压缩、最常见、最稳定的特征；但复杂推理关心的往往是少数关键步骤。数学里一步错全错，图像里一个手指、透视或物理接触错了，整体就失真。分布相似不能替代约束满足。

## 特征坍塌现象

生成模型会保留高概率特征, 却丢失计算和约束精度




图 5: 特征坍塌现象: 生成模型会保留高概率特征, 却丢失计算和约束精度。自制概念图, 依据 00:45:42–00:50:48 对谈内容整理。

### 读图: 像训练语料, 不等于算对

左侧“分布接近”解释为什么模型语言流畅、知识丰富; 右侧“精度不足”解释为什么数学、几何和物理仍会错。多模态推理需要的是精确约束, 而不是只让输出更像训练样本。

### 不要把压缩率当作智能上限

更好的 next token loss 往往提升通用能力, 但它不是所有智能任务的充分目标。需要精确搜索、长期规划、外部验证和动作反馈的任务, 必须引入额外目标和过程。

## 4.2 本章小结

next token prediction 是大模型起飞的基础, 但它也解释了为什么更大模型可能更会跳步。数学、视觉可控生成和多模态推理, 都需要超出分布压缩的目标函数。

## 5 o1 的启发: RL、CoT 与反思 pattern

上一章指出 next token prediction 的缺陷, 本章看张祥雨如何理解 o1。访谈中他的判断很明确: o1 的关键不只是用了 RL, 而是激发了一种思维链 pattern。传统 RL 的许多算法名字并不是重点; 重点是, 模型在预训练中已经见过许多思考、反思、检查和重做的模式, RL 可以把这些模式强化出来。

## RL 与 CoT Pattern

RL 不只是算法名，关键是激发可搜索的思考模式



读图：从左到右看依赖关系；正文负责展开细节，图只保留骨架。

图 6: RL 与 CoT Pattern: RL 不只是算法名，关键是激发可搜索的思考模式。自制概念图，依据 00:50:48–01:01:52 对话内容整理。

### 读图：RL 不是魔法，pattern 才是杠杆

图中 Pretrain 提供已有模式，RL 用目标反馈强化，CoT 把步骤展开，Reflection 修正路径，Critical Decision 处理关键分支。o1 的启发在于：模型不是凭空学会思考，而是把预训练里稀疏存在的思考 pattern 放大。

## 5.1 Critical Decision: 一个 token 解决不了的地方

本节解释为什么反思重要。推理过程中不是每个 token 都同样关键。很多 token 只是表达格式，真正决定成败的是少数 critical decision：走左边还是右边、用哪个公式、是否需要回头检查、某个中间结论是否可靠。当一个分支选择的复杂度超过单个 token 的表达能力时，模型需要展开更多步骤，把决策问题拆成可搜索空间。

## Meta-CoT 与 Critical Decision

当一个 token 解决不了分支选择，就需要反思和元思维链



读图：从左到右看依赖关系；正文负责展开细节，图只保留骨架。

图 7: Meta-CoT 与 Critical Decision: 当一个 token 解决不了分支选择，就需要反思和元思维链。自制概念图，依据 01:01:52-01:10:57 对谈内容整理。

### 读图：Meta-CoT 是 CoT 的 CoT

从 State 到 Branch，再到 One token?、Reflect 和 Meta-CoT，图中表达的是“对思考过程再思考”。模型不只是写步骤，而是在关键节点判断当前路径是否足够、是否要回退、是否要换分支。

### 课堂提示：动作空间比算法名字更关键

张祥雨反复强调，很多时候不是具体 RL 算法多神秘，而是动作空间是否包含正确动作。没有反思动作，模型很难在关键决策点搜索；有了反思动作，RL 才有东西可强化。

## 5.2 本章小结

o1 给多模态的启发是：智能不只是模型更大，还要有可搜索的中间过程。CoT、反思和 Meta-CoT 把不可解的单 token 决策，变成可以分解、试错和优化的动作空间。

## 6 视觉 Long CoT：把慢思考搬进视觉空间

上一章讲语言推理，本章回到多模态。张祥雨研究完 o1 后，重新理解视觉生成可控性差的问题：很多视觉生成任务本质上超过了单步推理复杂度。人类画图或理解空间关系时，并不是一次性从噪声生成完整图像；人会先理解场景，定位局部，检查关系，再逐步修正。多模态如果只做一次性生成，就很容易违反几何和物理约束。



图 8: 视觉空间 Long CoT: 在视觉空间慢思考，把反思模式迁移到多模态推理。自制概念图，依据 01:10:57–01:24:07 会谈内容整理。

读图：视觉 CoT 不是把中文推理写长

图中从 Image/Video 到 Visual Actions、Reason、Reflect 和 Answer。视觉 Long CoT 的重点是让模型在视觉空间做动作：局部观察、标注、回看、比较、生成辅助草稿、修正空间关系，而不只是输出更长的文字解释。

6.1 为什么生成也需要 CoT

本节连接视觉理解和视觉生成。张祥雨的路线是先做视觉理解中的 CoT，因为理解更容易获得可验证反馈；但更远的目标是让生成也带上思维链。高可控生成不是一次性画完，而是先理解语义约束，再通过局部生成、检查、修改来逼近目标。对于复杂视频，这一点更关键，因为时间连续性、物理因果和身份一致性都需要跨帧维护。

术语消化：视觉动作空间

| 动作    | 含义           | 为什么有用           |
|-------|--------------|-----------------|
| 局部观察  | 只看图像或视频的一部分  | 降低上下文干扰，提高细节判断。 |
| 标注/画框 | 在视觉空间生成中间结构  | 把隐含空间关系显式化。     |
| 回看/比较 | 对不同局部或时间点做对照 | 发现不一致和物理错误。     |
| 生成草稿  | 先生成可检查中间结果   | 让生成过程可反馈、可修正。   |
| 反思修正  | 发现错误后重走路径    | 把视觉任务变成可搜索过程。   |

## 6.2 两条腿：预训练语料与动作空间

前面说明视觉 Long CoT 需要动作，本节把路线收束为两条腿。多模态后续路线不是单线。第一条腿是扩充预训练语料：更多高质量图文、视频、生成过程、交互过程和视觉推理数据。第二条腿是扩展动作空间：让模型不仅能看和说，还能局部观察、画图、生成、检查、调用工具、调用子模型、接收反馈。只有数据和动作空间一起扩展，视觉思考才有机会接近语言推理的跃迁。




图 9: 多模态后续两条腿：扩充预训练语料，同时扩展动作空间。自制概念图，依据 01:31:31–01:45:42 对谈内容整理。

### 读图：数据解决“见过”，动作空间解决“会做”

左侧 Pretraining Data 让模型见到更多视觉和生成过程；右侧 Action Space 让模型在任务中有更多可执行动作。多模态 GPT-4 时刻很可能需要两者同时发生，而不是只继续堆图文对。

## 6.3 研究路线时间线

本节把前面的概念压成一张时间线，帮助读者从研究史而不是热词来理解这期。张祥雨的叙述大致经历四个阶段：第一阶段是 CV scaling，把 ResNet 等模型做深做大；第二阶段是 CV 学 NLP，尝试把 Transformer、BERT/GPT、MIM 和自回归思想迁移到图像；第三阶段是多模态一体化受挫，发现生成和理解没有真正互相增强；第四阶段是 o1 之后重新理解推理，把 RL、CoT、反思和动作空间带回视觉。

| 阶段        | 核心动作                                          | 得到的教训                    |
|-----------|-----------------------------------------------|--------------------------|
| 2012–2016 | ImageNet、AlexNet、ResNet<br>证明视觉 model scaling | 数据、算力和模型同时扩展能打开视觉识别。     |
| 2018–2022 | ViT、iGPT、MIM、对比学习<br>等向 NLP 学习                | 架构迁移有效，但目标函数和数据属性未被根本解决。 |
| 2023–2024 | 训练大多模态模型，尝试生成理解一体化                            | 理解和生成各自变强，却不能自动融合。       |
| o1 之后     | 从 RL、CoT、反思和动作空间<br>重新看多模态                    | 视觉也需要慢思考和可搜索中间过程。        |
| 未来两年      | long context、在线学习、自主<br>学习和世界模型               | GPT-4 时刻可能来自环境反馈和系统协作。   |

#### 老师强调：迷茫本身是路线证据

访谈中反复出现“做了大半年很迷茫”“后来 o1 出现后想清楚”这类表达。这里的迷茫不是噪音，而是技术路线的证据：如果一个方向通过加数据、加模型、接模块仍然没有  $1+1>2$ ，就说明缺的是新的训练目标或动作空间。

## 6.4 本章小结

视觉 Long CoT 是这期最重要的多模态新思路：把 o1 的反思和动作空间思想迁移到视觉，让模型在视觉空间慢思考。它不是简单拉长文字链，而是给多模态模型更多可验证、可搜索、可修正的视觉动作。

## 7 Long Context、多模型协作与在线学习

前面讨论多模态理解和生成，本章进入未来两年的两个 GPT-4 时刻。张祥雨认为，long context 很重要，但今天直接把超长上下文塞进一个 Transformer 里有问题：注意力会涣散，上下文越长，相似信息越多，模型越容易被干扰。真正的智能不是把所有东西无损记住，而是能压缩、遗忘、翻书、转移注意力。

## Long Context 与多模型协作

不用把整本书塞进一个上下文，而是全局规划+局部执行



读图：从左到右看依赖关系；正文负责展开细节，图只保留骨架。

图 10: Long Context 与多模型协作：不用把整本书塞进一个上下文，而是全局规划加局部执行。自制概念图，依据 01:46:56–02:07:09 会谈内容整理。

### 读图：全局规划和局部执行可以分开

图中 Global Planner 保留整体印象，Retrieve/Turn page 负责翻书，Local Worker 做局部推理，Feedback 回传结果，Context Shift 切换情景。这比把所有 token 都塞进同一个上下文更接近人的注意力机制。

## 7.1 为什么架构不是本质

本节解释“Linear Transformer 不本质”。张祥雨不是否认线性注意力或 RNN-like 架构的价值，而是说：如果目标只是通过架构硬扛超长上下文，可能没有触到问题核心。长上下文的核心是如何压缩、如何检索、如何切换情景、如何让多个模型或模块协作，而不只是把注意力复杂度从平方降下来。

### 不要把大海捞针当成智能本身

为了通过 retrieve 测试，模型可能学到“什么都不能忘”的 bias。但人类读书后写总结时，会记住结构，再按需要翻书找句子。真正有用的 long context 系统，应当允许遗忘、摘要、翻页、局部复查和上下文切换。



## 术语消化: long context 的两类问题

| 问题    | 含义                         | 本期中的判断          |
|-------|----------------------------|-----------------|
| 计算复杂度 | 注意力随长度增长带来成本问题             | 重要, 但不是唯一问题。    |
| 智能建模  | 如何压缩、遗忘、转移注意力和局部复查         | 更接近真正的长程智能。     |
| 多模型协作 | 用 planner 和 worker 分工处理上下文 | 可减少干扰, 并让系统可训练。 |
| 情景隔离  | 做第二题时不必背着第一题全部上下文          | 避免长上下文污染当前推理。   |

## 7.2 在线学习与自主学习

如果 long context 是一个潜在 GPT-4 时刻, 另一个就是在线学习或自主学习。张祥雨把它和 Agent 联系起来: 今天很多 Agent 是应用层工具编排, 但更根本的 Agent 应当能在环境中持续行动、接收反馈、改进策略。这里的 scaling 不再只是 model scaling 或 data scaling, 而是 environmental scaling: 能不能提供足够多、足够真实、足够可验证的环境反馈。

### 在线学习与自主学习

下一个 GPT-4 时刻可能来自环境反馈和持续自我改进



读图: 从左到右看依赖关系; 正文负责展开细节, 图只保留骨架。

图 11: 在线学习与自主学习: 下一个 GPT-4 时刻可能来自环境反馈和持续自我改进。自制概念图, 依据 02:08:30-02:25:00 对谈内容整理。

### 读图：环境反馈是新的 scaling 对象

图中 Environment、Agent、Feedback、RL/IRL 和 Online Learning 连成闭环。模型不再只从离线语料中学习，而是在任务、工具、世界和人类反馈中持续更新。难点是环境规模、反馈质量和安全边界。

### 课堂提示：Agent 应用和自主学习 Agent 不是一回事

今天许多 Agent 产品是工具编排和工作流自动化；张祥雨讨论的更根本 Agent，是能在环境反馈中持续改进的学习系统。前者是应用形态，后者是训练范式 and 智能机制。

## 7.3 世界模型与机器人抢跑

访谈最后把多模态和机器人连接起来。人没有视觉生成器官，但人有世界模型：我们可以在脑中预测空间、物理和行动后果。机器学习系统是否必须通过生成式训练获得世界模型，仍是开放问题；但如果机器人要在物理世界行动，它不能绕过视觉理解、动作反馈和世界模型。




图 12: 世界模型与机器人抢跑：人没有生成器官，但有世界模型；机器人不能跳过视觉理解。自制概念图，依据 02:25:00–02:28:44 对谈内容整理。

### 读图：机器人不能只押硬件身体

左边 World Model 负责空间推理、物理常识和未来预测；右边 Robotics 需要视觉、动作、反馈和本体共同过线。机器人行业若跳过视觉推理和世界模型，只靠本体和遥操作，很容易在智能上抢跑。

## 7.4 本章小结

未来两个关键突破方向是 long context 的真实智能建模, 以及在线/自主学习的环境反馈闭环。前者要求模型学会压缩、翻书和情景切换; 后者要求模型在行动中持续改进。

# 8 总结与延伸

本节把 EP102 压缩为七个结论。第一, CV 的 GPT 时刻不能简单复制 NLP, 因为静态图像不天然携带人类语义和对齐。第二, 多模态一体化的关键难点, 是生成和理解无法互相校正。第三, next token prediction 是大模型起飞基础, 也是推理跳步和精度不足的来源之一。第四, o1 的关键启发是用 RL 激发 CoT、反思和 critical decision 搜索。第五, 视觉 Long CoT 是把慢思考迁移到视觉空间。第六, long context 不只是架构复杂度问题, 更是压缩、检索、情景隔离和多模型协作问题。第七, 下一个更深的 Agent 时刻, 可能来自在线学习和 environmental scaling。

### 把 EP102 放进张小珺 AI/互联网队列

EP102 是这一批里技术含量最高的多模态路线访谈之一。它连接 EP110 的 Agent 技术报告、EP113 的 agentic LLM、EP115 的 Agent 研究哲学, 也为 EP106/EP109 的具身智能问题提供视觉推理和世界模型的上游解释。

## 8.1 术语总表

前面各章已经分散解释了 VLM、CoT、动作空间、在线学习和世界模型。本节把这些术语集中放在一起, 方便读者复盘整期论证链: 从静态图像的数据属性, 到 next token prediction 的目标函数, 再到 o1 式反思、视觉 Long CoT 和在线学习。

| 术语                    | 简明定义                          | 本期中的作用                      |
|-----------------------|-------------------------------|-----------------------------|
| VLM                   | Vision-Language Model, 视觉语言模型 | 连接图像、视频和文本的主要模型形态。          |
| MIM                   | Masked Image Modeling, 遮蔽图像建模 | CV 向 BERT 式预训练学习的代表路线。      |
| Next Token Prediction | 预测下一个 token 的训练目标             | 解释语言模型强大与跳步缺陷的共同来源。         |
| CoT                   | Chain of Thought, 思维链         | 把单步决策展开成可搜索过程。              |
| Meta-CoT              | 对 CoT 的再思考和反思                 | 处理 critical decision 和路径选择。 |
| Action Space          | 模型在任务中可选择的动作集合                | 决定 RL 是否能搜索到正确行为。           |
| Online Learning       | 在线学习, 系统在使用中持续更新              | 可能是下一代 Agent 的关键。           |
| World Model           | 预测世界状态变化的内部模型                 | 连接多模态、机器人和具身智能。             |

## 8.2 后续观察问题

本节不是泛泛列问题，而是把访谈里的路线判断转成可追踪的观察点。接下来两年，如果多模态真的出现新的 GPT-4 时刻，应该能在这些位置看到信号：模型不只是 benchmark 上升，而是视觉推理、生成可控性、long context 和在线学习出现新的系统能力。

1. 视觉 Long CoT 能否在真实 benchmark 上明显提升多模态推理，而不只是生成更长解释？
2. 生成模型的可控性是否会通过视觉 CoT、局部编辑和反馈训练出现质变？
3. long context 会继续靠单模型扩窗，还是转向 planner/worker、多模型协作和工具化翻书？
4. 在线学习如何解决安全、数据污染、反馈稀疏和持续更新成本？
5. 机器人领域能否在抢跑硬件和本体之前，补上视觉推理、世界模型和动作反馈的基础能力？

## 8.3 拓展阅读

- 对 Agent 训练和上下文工程感兴趣，可对照 EP110 Kimi K2 / ChatGPT Agent / Qwen3-Coder 技术报告笔记。
- 对 Agentic LLM 和测试时扩展感兴趣，可对照 EP113 杨植麟 Kimi K2 访谈笔记。
- 对具身智能的数据和世界模型问题感兴趣，可对照 EP106 王鹤、EP109 谢晨和 EP121 谭捷访谈。