

深度访谈教学笔记

Language 是毒药、拆掉 L 与小鹏 Physical AI 转型

Zhang Xiaojun 对话小鹏自动驾驶负责人刘先明

基于 Zhang Xiaojun Podcast 公开视频、GPU 转写稿、章节结构与自制概念图整理

2025-11-18



视频标题: 120. 小鹏新上任的刘先明首次访谈: Language 是毒药、拆掉 L、简单即美、换帅、小鹏的 AI 转型

视频频道: Zhang Xiaojun Podcast

视频时长: 01:48:46

视频链接: <https://www.youtube.com/watch?v=40qPt8R2uys>

素材说明: YouTube 无可用字幕; 正文基于 faster-whisper large-v3 CUDA 转写、视频章节、封面和自制教学图整理。固定访谈画面不在正文重复使用。

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 导读：一家车企为什么要从自动驾驶转向 Physical AI	3
1.1 本章小结	3
2 刘先明的路径：从 CV/ML 到 Robotaxi，再到主机厂	3
2.1 Cruise 学到的两件事	4
2.2 为什么去主机厂	4
2.3 真实世界问题带来的压力	5
2.4 从旧金山到广州：场景改变问题结构	5
2.5 本章小结	5
3 自动驾驶软件栈：从规则到云端模型工厂	6
3.1 Software 1.0 到 2.0	6
3.2 云端模型工厂	7
3.3 本章小结	7
4 拆掉 Language：为什么 Language 是毒药	7
4.1 语言为什么会变成瓶颈	8
4.2 “拆掉 L”与自监督学习	8
4.3 本章小结	9
5 拆 L 与 Software 3.0：不是换名词，而是换数据路径	9
5.1 为什么中间结构会反复出现	9
5.2 拆 L 的真正目标：让数据自己说话	9
5.3 本章小结	10
6 小鹏 Physical AI 转型：主机厂数据闭环与 Robotaxi 目标	10
6.1 主机厂的数据优势	11
6.2 Robotaxi 作为阶段性里程碑	11
6.3 Physical AI 为什么不只是自动驾驶	12
6.4 本章小结	12
7 简单即美：拆掉中间层，也拆掉组织层级	12
7.1 扁平工程组织	13
7.2 工程文化：Deep Dive、共享失败和减少重复	14

7.3 切换时机：机会与风险	14
7.4 本章小结	15
8 量产视角：技术、质量、成本和责任要一起算	15
8.1 量产不是研究的尾声，而是问题来源	15
8.2 为什么“简单即美”不是粗暴删除	16
8.3 本章小结	16
9 换帅背后：不同阶段的历史使命	16
9.1 何小鹏的角色	17
9.2 预算、风险和 CEO 的问题	17
9.3 Meta 与 Google 的组织启发	18
9.4 未来一到五年	18
9.5 本章小结	18
10 术语消化：本期关键词索引	18
10.1 本章小结	19
11 总结与延伸	19
11.1 核心结论	19
11.2 开放问题	20
11.3 拓展阅读	20

1 导读：一家车企为什么要从自动驾驶转向 Physical AI

本节先说明这期的核心问题。刘先明接任小鹏自动驾驶中心负责人，外界关注的是换帅；但访谈真正值得整理的，是他把自动驾驶放进 Physical AI 的框架中重新理解：车不只是交通工具，也是一个真实世界智能体；自动驾驶不只是感知、规控和地图系统，而是数据、模型、云端工厂、车端部署和量产反馈共同构成的智能闭环。

这期最锋利的判断是“Language 是毒药”。它并不是说语言没有价值，而是说在自动驾驶/物理 AI 的训练链路中，如果把传感器信号先翻译成中间语言 token，再从语言解码轨迹，就会引入人工监督、压缩瓶颈和 data scaling 障碍。刘先明的路线是不断拆掉中间层：拆激光雷达依赖、拆规控规则、拆端到端中间结构，最后连 language bottleneck 也拆掉。

本期核心命题

小鹏的 AI 转型不是“给汽车加大模型”，而是把自动驾驶重写成 Physical AI：用更大模型、更大数据、更少人工中间层和更强工程闭环，让车在真实世界中持续学习、部署和迭代。

视觉策略说明

本视频是固定访谈画面，没有 slides、白板或产品演示。正文只用封面做来源识别，正文图像全部为自制概念图，用来解释自动驾驶软件栈演化、拆掉 Language、云端模型工厂、主机厂数据闭环、组织扁平化和换帅使命。

1.1 本章小结

EP120 的主线是“简化”：技术上拆掉中间层，组织上减少层级，战略上把自动驾驶放进 Physical AI。它不是单纯人事访谈，而是一份车企 AI 转型方法论。

2 刘先明的路径：从 CV/ML 到 Robotaxi，再到主机厂

本章先看刘先明为什么会走到小鹏。他的路径包括 UIUC 博士、Facebook Connectivity Lab、地平线北美、Cruise Robotaxi，再到小鹏。贯穿这条线的不是“跳槽履历”，而是 mission driven 的技术选择：从卫星图像做救灾和世界人口分布，到自动驾驶减少司机疲劳和交通风险，再到主机厂里做可控数据闭环。

刘先明的 Physical AI 路径

从 CV、卫星图像、Robotaxi 到小鹏自动驾驶



读图：从左到右看依赖关系；正文负责展开细节，图只保留骨架。

图 1: 刘先明的 Physical AI 路径: CV/ML、Facebook、Cruise、小鹏和 Physical AI。自制概念图, 依据 00:02:16–00:19:00 对谈内容整理。

读图：这条路径的主线是真实世界问题

从卫星图像救灾，到 Robotaxi，再到小鹏量产车队，刘先明一直在处理“AI 如何进入真实世界”。这解释了他为什么不把自动驾驶只看作车企功能，而看作 Physical AI 的一部分。

2.1 Cruise 学到的两件事

刘先明在 Cruise 学到的两件事影响了他后续路线。第一是极致简化和大规模 Infra。Robotaxi 要从 demo 变成产品，需要 Data Infrastructure、Training Infrastructure、问题分析链路和软件发布体系。第二是 Continuous Learning Machine，即用数据迭代持续解决问题。所谓“躺在夏威夷等金币掉下来”只是玩笑，背后是数据闭环可以让系统持续变好。

Cruise 经验的迁移

从 Robotaxi 到主机厂，关键不是换一个场景，而是把“数据回流 + Infra + 快速迭代”迁到更大车队和更可控数据链路中。

2.2 为什么去主机厂

如果自动驾驶和 Physical AI 的未来依赖大规模数据、可控数据链路和快速反馈，主机厂就有天然优势。Robotaxi 公司能控制车队，但规模有限；主机厂有量产车辆、真实用户、不同城市道路和完整车端数据链路。刘先明选择小鹏，是因为他和何小鹏都在问同一个问题：下一代技术路线怎样远远甩开当前对手？

主机厂相对 Robotaxi 公司的不同优势

维度	Robotaxi 公司	主机厂
车队控制	控制运营车队, 数据质量高但规模较慢	量产车规模大, 覆盖城市和场景更广。
商业目标	直接提供出行服务	卖车、智驾订阅、Robotaxi 和品牌体验并行。
数据链路	运营闭环强	用户车队回流和量产问题更复杂。
风险约束	服务区和运营范围可控	面向普通用户, 安全 and 质量责任更重。

2.3 真实世界问题带来的压力

刘先明比较了 Facebook、Cruise 和小鹏的工作压力。Facebook 的研究问题更多是技术和资源问题; Cruise 的车在路上, 事故、故障和安全都是真实压力; 到小鹏之后节奏更快, 因为量产车企要同时处理 AI、产品、业务、质量、硬件和用户责任。这种压力解释了为什么 Physical AI 不是纯 research, 而是要在真实系统中不断做取舍。

真实世界 AI 的压力来源

数字世界模型出错, 通常可以回滚、重试或隐藏失败; 车在路上出错, 关系到安全、责任、品牌和监管。因此物理 AI 的迭代必须比纯软件更谨慎, 也更依赖工程闭环。

2.4 从旧金山到广州: 场景改变问题结构

刘先明提到, 在旧金山做自动驾驶时, 流浪者、垃圾、宠物、鸟等 corner case 很密集, 让人觉得问题很难; 而在广州, 某些曾经难以处理的问题不是同一个量级。这个观察很重要: 自动驾驶不是抽象算法题, 城市道路结构、交通参与者、基础设施和人群行为都会改变问题难度。

场景不是背景, 而是模型的一部分

同一套算法在不同城市会面对不同 corner case。场景选择会影响数据分布、模型训练、上线节奏和用户体验, 因此 Robotaxi 和量产智驾都不能只谈模型, 不谈城市和运营环境。

2.5 本章小结

刘先明的路径说明, 小鹏这次换帅不只是组织任命, 而是把自动驾驶经验、Robotaxi 数据闭环和主机厂量产资源重新组合。

3 自动驾驶软件栈：从规则到云端模型工厂

上一章讲人和组织，本章进入技术栈。刘先明把自动驾驶演进拆成几个阶段：Software 1.0 是规则和优化；Software 1.5 是模型加规则；Software 2.0 是端到端；Software 3.0 或 VLA/VLM 路线则是在更大算力和更大数据下，用更大模型做数据 scaling。最终，车端硬件无法承载全部训练和大模型，于是需要云端模型工厂。



图 2：自动驾驶软件栈演化：从规则、半模型、端到端，到更大模型和云端工厂。自制概念图，依据 00:02:16–00:19:00 对话内容整理。

读图：每一代都在拆掉旧上限

Software 1.0 被规则和优化约束；Software 1.5 的上限仍在规控代码；Software 2.0 用端到端减少人工结构；Software 3.0/VLA/VLM 用更大模型和更多数据继续 scaling；云端工厂负责训练、蒸馏、量化、剪枝和部署。

3.1 Software 1.0 到 2.0

Software 1.0 使用激光雷达聚类、传统检测、手写规则和数学优化来做感知与规控。这一代系统可解释、工程可控，但会被规则上限卡住。Software 1.5 把模型引入感知，例如检测和分割，但规划控制仍依赖大量规则。Software 2.0 则试图让神经网络从数据中学习更完整的输入输出关系，用数据迭代代替越来越复杂的手写规则。

规则不是错，规则是阶段性上限

规则系统在早期非常重要，因为它可控、可调、可解释。但当场景复杂度超过人工规则维护能力时，规则会变成上限。拆规则不是否定工程，而是承认规模化问题需要数据驱动。

3.2 云端模型工厂

车端芯片无法直接训练超大模型，也不适合直接运行所有云端能力。因此，刘先明提出“云端工厂”思路：在云端训练巨大模型，再通过蒸馏、量化、剪枝等方式压缩能力，部署到不同车端硬件上。这个模式类似模型生产线，训练好一个云端母模型后，可以持续生成适配不同平台的车端模型。



图 3: 云端模型工厂：大模型在云端训练，再蒸馏、量化、剪枝到车端。自制概念图，依据 00:02:16–00:19:00 对谈内容整理。

读图：云端负责能力，车端负责部署

云端大模型吃大参数和大数据，训练后通过蒸馏把能力迁到小模型，再量化剪枝适配车端算力。这样既能利用 scaling，又能满足量产车硬件约束。

3.3 本章小结

自动驾驶软件栈演化的核心，是不断拆掉人工中间层，扩大数据和模型规模，再用工程体系把云端能力压缩到车端。云端模型工厂是连接大模型和量产部署的关键结构。

4 拆掉 Language: 为什么 Language 是毒药

本章进入节目标题里的核心技术判断。很多 VLA 路线会把传感器信号先翻译成 language token，再用 language token 解码 trajectory。刘先明认为这会产生瓶颈，因为中间语言表示引入人工监督和人工语义压缩，不利于 data scaling。小鹏的做法是拆掉这个中间 language 层，让 vision 和 language 作为输入，直接解码 action。




图 4: 拆掉 Language Bottleneck: 中间语言 token 会限制数据 scaling。自制概念图，依据 00:19:00–00:33:53 对谈内容整理。

读图：保留语言作为输入，拆掉语言作为中间瓶颈

左侧路线把传感器信号翻译成语言，再从语言解码轨迹；右侧路线让 Vision+Language 直接进入模型，Action 直接输出。这里不是不要语言，而是不要把语言当成强制中间监督信号。

4.1 语言为什么会变成瓶颈

本节先把“毒药”这个强表达拆开看。语言的问题不是语义无用，而是它一旦成为低层驾驶信号的必经中介，就会把连续世界压成离散标签。

语言是人类高层抽象，非常适合指令、解释和常识，但自动驾驶的传感器信号包含大量连续、几何、动态和细粒度信息。如果必须先翻译成语言，就会丢掉许多连续信息，并把训练过程变成人工标注或人工 refinement。对需要海量数据 scaling 的自动驾驶来说，这会限制数据使用效率。

Language 是毒药的准确含义

语言作为输入很有价值，语言作为强制中间表示可能有毒。毒性来自过度依赖人工语义、降低连续数据利用率、形成 bottleneck，并阻碍自监督或大规模数据训练。

4.2 “拆掉 L”与自监督学习

过去 AI 成功的重要经验之一，是使用数据做 unsupervised/self-supervised learning。自监督学习利用数据自身结构构造训练信号，减少人工标注依赖。自动驾驶如果要走这条路，就要尽量减少中间人工监督层，让模型从海量视觉、传感器和驾驶轨迹中直接学习。

不要把“拆掉语言”理解成“不要语言能力”

自动驾驶仍需要理解导航指令、交通语义和人类意图。拆掉的是中间瓶颈，不是人机交互里的语言输入，也不是模型中的语义理解。

4.3 本章小结

“Language 是毒药”是对中间表示的警惕。物理 AI 要充分利用连续传感器数据，语言不能成为所有信息的窄口。更直接的 VLA/Action decoding，是为了提升数据使用效率和 scaling 能力。

5 拆 L 与 Software 3.0：不是换名词，而是换数据路径

前面分别讲了软件栈演化和拆 Language，本章把两者放在一起看。刘先明反复提醒，很多新名词本质上做的是类似事情：更大模型、更大数据、更少人工规则、更直接地从输入到动作。所谓 Software 3.0、VLA、VLM、端到端，并不是为了制造概念，而是在寻找更可 scaling 的数据路径。

5.1 为什么中间结构会反复出现

本节解释一个工程悖论：中间结构往往是为了解决可控性而加入的，但系统复杂到一定程度后，它们又会反过来限制学习系统的上限。

自动驾驶系统里，中间结构很诱人：感知结果、车道线、目标框、轨迹候选、go point、meta action、language token。它们让系统更可解释、更容易 debug，也更符合传统工程分工。但每增加一个中间结构，就可能增加一个人工设计瓶颈：数据被压缩成某种人为格式，模型只能在这个格式内学习。

中间结构的利弊

维度	好处	代价
可解释性	人能看懂模块输出，便于定位问题	可能牺牲原始连续信息。
工程分工	感知、预测、规控可分团队推进	模块接口成为系统上限。
安全上线	更容易做规则保护和人工兜底	规则越多，数据 scaling 越慢。
数据利用	中间标签可以做监督学习	人工标签会限制规模和表达力。

5.2 拆 L 的真正目标：让数据自己说话

接下来回到小鹏的选择：拆 L 不是为了显得激进，而是为了让更大规模、更原始、更连续的数据进入训练链路。

拆掉 Language Bottleneck 的目标，不是让系统更神秘，而是让传感器、驾驶轨迹和动作反馈能以更少人工变换进入训练。语言可以用于指令和高层语义，但如果每个低层动作都要经过语言 token，

它就会把连续世界离散化，阻碍自监督学习和大规模数据利用。

Software 3.0 的最小定义

在本讲义中，Software 3.0 指用大模型、大数据、自监督信号和云端模型工厂，把物理世界任务从人工规则系统推进到可持续 scaling 的学习系统。

5.3 本章小结

Software 3.0 的关键不是术语，而是数据路径更短。越少人工中间层，越有机会让模型直接从真实数据中学习；但越少中间层，也越需要更强评测、安全和工程治理。

6 小鹏 Physical AI 转型：主机厂数据闭环与 Robotaxi 目标

前面讲技术栈和拆 Language，本章看小鹏为什么把自动驾驶上升为 Physical AI。刘先明说“小鹏本质上是一家 AI 企业”。这句话的含义不是营销口号，而是：车是物理世界中最大规模、最可控、最有商业闭环的智能体之一；主机厂拥有真实用户、真实道路、真实反馈和可控硬件链路。




图 5: 小鹏 Physical AI 转型: 从自动驾驶能力走向物理世界智能。自制概念图, 依据 00:33:53–00:54:30 对谈内容整理。

读图：车是 Physical AI 的最大本体之一

图中 Physical AI 不只包括模型，还包括车、数据、Robotaxi、组织和量产。小鹏的优势不只是算法，而是主机厂能把真实车队数据和量产反馈接进模型迭代。

6.1 主机厂的数据优势

主机厂最大的优势是可控数据链路。车队在真实城市运行，产生传感器数据、驾驶决策、用户反馈、异常 corner case、接管和问题工单。只要数据回流和训练基础设施足够好，主机厂可以形成“真实世界数据 -> 云端训练 -> 车端部署 -> 真实反馈”的闭环。



图 6: 数据与 Infra 闭环: 主机厂优势在可控数据链路和量产反馈。自制概念图, 依据 00:02:16–00:19:00 与 00:33:53–00:54:30 对谈内容整理。

读图：数据闭环不是“有车就行”

车队只是数据入口；真正的闭环还需要 corner case 挖掘、训练/分析 infra、模型更新、车端部署和量产验证。没有这套体系，数据不会自动变成能力。

6.2 Robotaxi 作为阶段性里程碑

刘先明提到希望未来一到三年在广州把 Robotaxi 运行得很好。这个目标的意义，是把技术争论转成真实服务：它不再是新闻热点、玩具或景点，而是用户每天出门默认会用的一部分。Waymo 在旧金山从景点变成生活服务，是他很在意的参照。

从景点到生活服务

刘先明带孩子在旧金山坐 Waymo 时，孩子会把它叫作 Robot Car。早期很多人去旧金山只是为了尝鲜；但当它开始承担大量日常订单，从 Caltrain Station 出来就有人等车时，它就不再只是技术展示，而是城市生活的一部分。小鹏的 Robotaxi 目标，也需要越过这个心智门槛。

6.3 Physical AI 为什么不只是自动驾驶

本节把 Robotaxi 目标放回更大的 Physical AI。自动驾驶是物理 AI 中最成熟、数据最多、商业闭环最清晰的场景之一，但它不是终点。车端系统已经包含感知、预测、规划、控制、用户交互、地图、云端训练和安全机制；这些模块未来会迁移到更多物理智能体上。小鹏若能在车这个本体上证明 scaling，就有机会把同一套方法论延伸到更广的物理世界任务。

车是 Physical AI 的训练场

车是高价值、高频、真实世界约束强的智能体。它让 AI 不只在屏幕里回答问题，而是在道路、交通和安全责任中学习行动。

6.4 本章小结

小鹏 Physical AI 转型的关键，是把自动驾驶放进真实世界智能闭环：主机厂数据、云端训练、车端部署、Robotaxi 验证和组织执行共同构成新的战略。


7 简单即美：拆掉中间层，也拆掉组织层级

前面讲的是技术层面的拆，本章转到组织层面的拆。刘先明的“简单即美”不是审美口号，而是工程管理原则：复杂系统要想迭代快，就必须减少不必要的中间层。

本章从技术上的“拆”转向组织上的“简化”。刘先明说自己喜欢简单，上任后最重要的决策就是简化流程、简化研发工序、合并重复事项、降低不必要事项优先级。他不喜欢只听汇报，而是直接看前线问题、代码和实验结果。

简单即美

不断拆掉浓郁中间层，让数据直接训练能力



读图：从左到右看依赖关系；正文负责展开细节，图只保留骨架。

图 7：简单即美：不断拆掉浓郁中间层，让数据直接训练能力。自制概念图，依据 00:00:00–00:02:16 与 00:54:30–01:48:46 对谈内容整理。

读图：技术简化和组织简化是同一件事

拆激光雷达依赖、拆规控规则、拆中间层、拆 Language，都是为了减少瓶颈；组织上减少层级、直接看问题、合并重复工作，也是为了减少信息瓶颈。

7.1 扁平工程组织

在物理 AI 和量产结合的场景里，决策速度很重要。刘先明希望层级被拍平，一线 engineer 能直接暴露问题，团队 lead 也能直接写代码、看实验、做 deep dive。组织内部不设置太多部门墙，避免 duplicate work，通过共享实验和失败来提高整体速度。



图 8：扁平工程组织：前沿 AI 与量产结合，需要一线问题快速决策。自制概念图，依据 00:54:30–01:48:46 对谈内容整理。

读图：扁平不是无管理，而是短链路

一线工程师暴露代码和实验，负责人直接看问题，deep dive 复盘好坏实验，资源整合减少重复，最终支持模型超越规则后的快速切换。

7.2 工程文化：Deep Dive、共享失败和减少重复

本节把“扁平”进一步落成日常机制。没有 deep dive 和失败共享，扁平组织很容易只是少几层汇报线，而不是真正提高学习速度。

访谈中提到团队会做 deep dive，把好的实验、坏的实验、最近看到的東西、自己做挂的东西拿出来分享。这个做法服务于两个目标：一是让团队快速形成共同上下文，二是避免不同小组重复造轮子。Physical AI 的研发需要大量实验，如果失败不能共享，组织会反复踩同一个坑。

工程组织的知识复用

前沿 AI 团队的核心资产不只是模型权重，还包括失败实验、调参经验、数据处理方法和对问题的共同理解。Deep Dive 是把这些隐性知识显性化。

7.3 切换时机：机会与风险

接下来讨论简化最危险的一步：什么时候可以把旧路线切掉。对车企来说，这不是研究组内部开关，而是直接影响用户安全和量产质量的决策。

车企不能因为技术酷就上线。模型要真正替代规则，需要等到某个时间点：模型性能明显超过规

则，坏处可控，好处明显，安全责任和量产质量能承受。刘先明提到测试员鼓掌的时刻，就是模型超越旧规则的一种组织信号。




图 9: 切换时机：机会 vs 风险。车企必须等模型超过规则，而不是只因技术酷就上线。

技术路线切换不能靠信仰硬推

在车企里，技术路线切换必须对安全、质量和用户负责。正确做法不是“模型很酷所以全量上线”，而是让模型在关键指标上超过旧系统，并逐步扩大部署。

7.4 本章小结

小鹏这次转型同时发生在技术和组织两层：技术上拆掉中间层，组织上缩短信息链路。两者都服务于同一个目标：让数据和真实问题更快进入模型迭代。

8 量产视角：技术、质量、成本和责任要一起算

前面讲了技术路线和组织简化，本章补上量产视角。刘先明多次强调，他更喜欢从真实问题里找下一阶段要做的事情。自动驾驶负责人不只是研究负责人，还要面对产品、业务、质量、硬件、成本和用户安全。这个视角解释了为什么车企不能简单照搬研究团队的节奏。

8.1 量产不是研究的尾声，而是问题来源

研究团队常常先定义任务，再找数据和模型；量产团队面对的是真实用户每天遇到的问题。车在路上出现的每个接管、每个不舒适动作、每个误判、每个用户投诉，都会变成下一轮模型和工程要解决的问题。量产不是研究结束后的部署环节，而是持续产生研究问题的入口。

量产问题如何反哺模型

量产信号	进入模型前要做什么	反哺价值
接管	定位接管原因、切出片段、标注上下文	找到模型盲区和规则上限。
用户不适	关联驾驶动作、速度、车距和环境	优化舒适性和风格。
事故/风险	做责任归因、复盘感知/预测/规划链路	形成安全样本和评测集。
硬件约束	记录算力、传感器、延迟和成本限制	指导蒸馏、量化和剪枝。

8.2 为什么“简单即美”不是粗暴删除

简单不是把所有保护都删掉，而是把重复、过时、阻碍 scaling 的结构删掉。车企仍然必须保留安全冗余、质量验证和上线流程。刘先明强调的简单，是让研发工序更短、目标更少、问题暴露更快，而不是牺牲安全边界。

简化不等于冒进

如果为了追求端到端而忽略安全、测试和量产质量，简化会变成冒进。真正的简化，是减少无效复杂度，同时保留必要安全约束。

8.3 本章小结

Physical AI 的量产路线要求技术和责任一起前进。模型要更大、数据要更多，但上线必须经受安全、质量、成本和用户体验检验。

9 换帅背后：不同阶段的历史使命

前面讲技术和组织，本章回到换帅。小鹏自动驾驶经历多任负责人：谷俊丽、吴新宙、李力耘、刘先明。刘先明没有直接定义每个人的历史使命，但可以从技术阶段看：早期需要探索和搭建能力，中期需要规则/量产体系，之后需要端到端转型，而现在进入 Physical AI 和更大模型/数据 scaling 阶段。



图 10: 小鹏智驾负责人使命：不同阶段对应不同技术路线和组织任务。自制概念图，依据 00:54:30–01:48:46 对谈内容整理。

读图：换帅不是孤立人事，而是阶段变化

每一任负责人面对的主问题不同：早期探索、规则量产、端到端转型、Physical AI 和下一阶段生活服务化。组织换帅往往伴随技术栈和公司战略变化。

9.1 何小鹏的角色

刘先明描述何小鹏是坦诚、技术宅、问题很 sharp 的老板。他们最初聊的不是普通面试，而是“下一代怎样甩开对手”。在技术规划上，何小鹏会在机会与风险之间动态平衡；当模型性能和机会足够清晰时，他会调整判断。这个过程不是靠“说服老板”，而是靠把事情做出来，让技术涌现改变决策。

技术涌现改变决策

在高不确定技术路线里，最有说服力的不是口头争论，而是模型性能突然跨过某个阈值。组织应该保留足够空间，让正确技术在指标和体验上自然显现。

9.2 预算、风险和 CEO 的问题

何小鹏会问非常直接的问题，例如“为什么花这么多钱”。这个问题不是简单压预算，而是在逼团队说明：更大模型、更大数据、更大 infra 的投入，如何变成可部署能力、用户体验和商业结果。Physical AI 的 scaling 很贵，CEO 的角色不是只批准预算，而是持续追问机会、风险和时间窗口。

Scaling 不是免费午餐

更大模型和更多数据会带来能力，但也会带来训练成本、车端部署成本、组织复杂度和质量风险。车企必须把技术路线和财务、量产、安全一起算。

9.3 Meta 与 Google 的组织启发

刘先明提到 Meta 的半年节奏和 reorg 文化适合互联网快速试错，但 AI 时代很多事情需要从头建体系，半年一次的大调整未必友好。Google 在 Larry Page / Sergey Brin 回归后也发生变化。这个比较说明，公司文化会影响长线 AI 项目：如果考核周期太短，团队可能很难做需要一年以上才能验证的底层系统。

AI 时代的组织时间尺度

互联网产品可以高频试错、快速砍掉；Physical AI 和大模型基础设施往往需要长周期验证。组织如果只接受短周期收益，就会伤害底层能力建设。

9.4 未来一到五年

刘先明对一年、三年、五年的判断很有层次：一年后，智能化会更全面地接触生活，可能仍以数字 AI 为主；三年后，物理 AI 可能真正进入生活；五年后难以预测，因为世界发展太快。对个人和组织来说，能做的是持续学习，识别思维惯性，把当前认知下最正确的事情做好。

9.5 本章小结

换帅背后，是小鹏智驾从规则、端到端走向 Physical AI 的阶段切换。领导者的任务不只是管理团队，而是用工程和组织让正确技术路线跑出来。

10 术语消化：本期关键词索引

术语	一句话解释	在本期中的作用
Physical AI	物理世界中的 AI, 能感知、决策并执行动作	小鹏从自动驾驶升级到 AI 战略的核心框架。
Robotaxi	自动驾驶出租车服务	刘先明希望在广州跑好的阶段性目标。
Software 1.0	规则、优化和手写逻辑主导的软件栈	早期自动驾驶路线。
Software 2.0	神经网络和数据驱动的软件栈	端到端自动驾驶的基础概念。
VLM	Vision-Language Model, 视觉语言模型	理解视觉和语言, 但不一定直接输出 action。

VLA	Vision-Language-Action, 视觉语言动作模型	小鹏 Physical AI 技术栈的重要方向。
Language Bottleneck	把连续传感器信息压成语言 token 的中间瓶颈	刘先明主张拆掉的关键中间层。
Self-supervised Learning	自监督学习, 用数据自身构造训练信号	支撑大规模数据利用, 减少人工标注依赖。
Scaling	通过更大模型、更多数据、更多算力提升能力	刘先明认为 Physical AI 的关键 bet。
云端模型工厂	云端训练大模型, 再压缩部署到车端	连接 scaling 和车端量产的工程结构。
蒸馏	用大模型训练小模型, 让小模型继承能力	云端到车端部署的重要手段。
量化/剪枝	降低模型精度或裁剪参数以适配硬件	车端部署和成本控制需要。
Infra	数据、训练、分析和部署基础设施	Cruise 和小鹏路线共同强调的底座。
Corner Case	长尾边界场景	自动驾驶数据闭环要持续挖掘的对象。

10.1 本章小结

本期术语围绕一个问题展开: 如何把自动驾驶从规则工程升级为可 scaling 的 Physical AI 系统。关键词不是孤立名词, 而是训练、压缩、部署和量产反馈的一条链。

11 总结与延伸

11.1 核心结论

1. 小鹏转向 Physical AI, 不是给车加大模型, 而是重写自动驾驶的数据和模型闭环。
2. 刘先明的路径说明, 真实世界问题和使命感会持续牵引技术选择。
3. 自动驾驶软件栈从规则、半模型、端到端, 走向更大模型和云端工厂。
4. “Language 是毒药”的准确含义, 是语言作为中间监督瓶颈会限制 data scaling。
5. 拆掉中间层的目标, 是让连续传感器数据和动作输出更直接地进入训练。
6. 主机厂优势在真实车队、可控数据链路和量产反馈。
7. 云端模型工厂负责训练大模型, 再蒸馏、量化、剪枝到车端部署。
8. 技术简化和组织扁平化是同一件事: 都在减少瓶颈。
9. 换帅背后是技术阶段切换, 刘先明的任务是吧 Physical AI 路线跑成生活服务。

10. 未来关键 bet 是 Physical AI 中的 scaling, 以及持续识别自己的思维误区。

11.2 开放问题

最后保留开放问题, 是因为小鹏这条路线仍在高速展开。真正要观察的, 不只是“拆掉了什么”, 还包括拆掉之后系统是否更稳、更可控、更能 scale。

- 拆掉 Language 后, 模型如何保留足够高层语义和可解释性?
- 云端大模型到车端模型的蒸馏, 会不会成为体验上限?
- 主机厂数据闭环能否追上 Robotaxi 专用车队的高质量闭环?
- Robotaxi 在广州跑好, 距离全国规模化还有哪些非技术阻力?
- 扁平工程组织在规模化量产和质量体系中能保持多久?
- Physical AI 的 scaling 会先在车上验证, 还是在机器人/其他本体上验证?

11.3 拓展阅读

- EP121 谭杰访谈: 机器人、世界模型、跨本体和 Gemini Robotics 1.5。
- EP132 高继扬访谈: Waymo、Momenta 和星海图的具身智能生产化。
- EP134 数据综述: Data Recipe、机器人数据和数据定价。
- Software 2.0、VLA、VLM、自监督学习和模型蒸馏相关资料。

最后的判断

EP120 最值得保留的不是一句“拆掉 L”, 而是一套工程哲学: 当中间层成为数据 scaling 的瓶颈, 就要拆; 当组织层级成为问题反馈的瓶颈, 也要拆。Physical AI 的进步, 来自更直接的数据、更大的模型、更短的工程链路和更坚决的量产验证。